



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

NGHIÊN CỨU PHƯƠNG PHÁP XÂY DỰNG NEOBERT CHO TIẾNG VIỆT

1 THÔNG TIN CHUNG

Người hướng dẫn:

- TS. Nguyễn Hồng Bửu Long (Khoa Công nghệ Thông tin)
- TS. Lương An Vinh (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Bùi Khắc Trung (MSSV: 22120396)
2. Trần Anh Tú (MSSV: 22120400)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 1/2026 đến 7/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong lịch sử phát triển của lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), các mô hình dạng Encoder-only như BERT và RoBERTa từng giữ vai trò nền tảng trong các bài toán hiểu ngôn ngữ. Tuy nhiên, trong khi các dòng mô hình Decoder-only (LLMs) liên tục tiến hóa với quy mô dữ liệu và kiến trúc đột phá, các bộ Encoder gần như không có sự cải thiện đáng kể trong suốt vài năm qua. Phải đến năm 2025, sự ra đời của NeoBERT [1] mới thực sự thu hẹp khoảng cách này. NeoBERT tái định nghĩa khả năng của mô hình bằng cách tích hợp các cải tiến kiến trúc tiên tiến nhất như hàm kích hoạt SwiGLU, vị trí tương đối Rotary Position Embeddings (RoPE), và chuẩn hóa Pre-RMSNorm. Đặc biệt, NeoBERT tối ưu hóa tỷ lệ chiều sâu trên chiều rộng (optimal depth-to-width ratio) với 28 lớp ẩn trên kích thước 768, cho phép mô hình đạt hiệu suất vượt trội trên chuẩn đánh giá MTEB so với các dòng BERT-large dù chỉ sở hữu 250 triệu tham số.

Mặc dù sở hữu sức mạnh suy luận vượt trội và hỗ trợ độ dài ngữ cảnh lên tới 4.096 tokens, việc thích nghi NeoBERT cho ngôn ngữ tiếng Việt vẫn đối mặt với những thách thức lớn. Việc huấn luyện lại từ đầu (from scratch) trên quy mô hàng nghìn tỷ tokens như NeoBERT gốc là điều bất khả thi về mặt tài nguyên. Bên cạnh đó, các phương pháp tiếp tục tiền huấn luyện (Continued Pre-training) thông thường dễ dẫn đến hiện tượng quên lãng thảm họa (catastrophic forgetting), làm phá vỡ các đặc trưng biểu diễn quý giá mà mô hình đã học từ dữ liệu ban đầu.

Xuất phát từ bối cảnh trên, đề tài tập trung nghiên cứu phương pháp thích nghi ngôn ngữ cho NeoBERT bằng kỹ thuật SALT (Semantic Aware Linear Transfer) [2]. Ý tưởng cốt lõi của nghiên cứu là tái sử dụng (recycling) bộ nhúng từ các mô hình tiền huấn luyện tiếng Việt chất lượng cao như ViDeBERTa [3]. Thay vì khởi tạo ngẫu nhiên, phương pháp thực hiện chuyển đổi tuyến tính dựa trên nhận thức ngữ nghĩa: đối với mỗi token không trùng lặp, thuật toán sẽ thiết lập các đường

hồi quy tuyến tính riêng biệt dựa trên tập từ vựng chung. Quá trình này giúp ánh xạ chính xác các thành phần ngữ nghĩa từ không gian của ViDeBERTa sang không gian của NeoBERT.

Thông qua đó, nghiên cứu hướng tới việc xây dựng mô hình Vietnamese NeoBERT có khả năng xử lý ngữ cảnh dài, tốc độ suy luận nhanh và độ chính xác cao. Kết quả của đề tài không chỉ mang ý nghĩa về mặt hiệu suất mà còn khẳng định tính khả thi của việc tối ưu hóa tài nguyên huấn luyện. Cụ thể, việc linh hoạt tái sử dụng không gian biểu diễn (embedding) từ các mô hình ngôn ngữ mạnh mẽ sẵn có mở ra một hướng tiếp cận tiết kiệm và hiệu quả để chuyển đổi ngôn ngữ cho các kiến trúc LLM thế hệ mới, thay vì phải đầu tư chi phí khổng lồ cho việc huấn luyện lại từ đầu.

2.2 Mục tiêu đề tài

Trong bối cảnh các mô hình ngôn ngữ lớn đang đạt được những bước tiến vượt bậc về khả năng suy luận, các kiến trúc Encoder-only vẫn đóng vai trò nền tảng không thể thay thế trong các tác vụ trích xuất đặc trưng và biểu diễn ngữ nghĩa văn bản. Tuy nhiên, các mô hình Encoder dành cho tiếng Việt hiện nay chủ yếu dựa trên những kiến trúc cũ, thiếu đi sự tối ưu từ các kỹ thuật hiện đại và bị giới hạn ở độ dài ngữ cảnh ngắn. Việc huấn luyện lại các kiến trúc thế hệ mới như NeoBERT từ đầu cho tiếng Việt đòi hỏi nguồn lực tính toán khổng lồ. Do đó, việc nghiên cứu một phương pháp thích nghi ngôn ngữ hiệu quả, ít tốn kém nhưng vẫn bảo toàn được sức mạnh của mô hình gốc là một nhu cầu cấp thiết.

Đề tài tập trung nghiên cứu việc khai thác và chuyển đổi tri thức từ các mô hình ngôn ngữ tiền huấn luyện tiếng Việt sẵn có vào kiến trúc NeoBERT thông qua kỹ thuật SALT. Mục tiêu cụ thể là sử dụng các tập neo (anchor tokens) để tính toán các đường hồi quy tuyến tính riêng biệt, từ đó ánh xạ chính xác không gian biểu diễn (embedding) của mô hình nguồn (tiêu biểu như ViDeBERTa) sang không gian vector của NeoBERT. Thông qua cách tiếp cận này, nghiên cứu hướng

đến việc xây dựng một mô hình Vietnamese NeoBERT có khả năng xử lý ngữ cảnh dài (lên tới 4.096 tokens) với tốc độ hội tụ nhanh và chi phí huấn luyện thấp hơn đáng kể so với các phương pháp truyền thống.

Kết quả của đề tài sẽ góp phần chứng minh hiệu quả của việc linh hoạt tái sử dụng không gian biểu diễn từ các mô hình ngôn ngữ mạnh mẽ sẵn có để chuyển giao tri thức, giúp rút ngắn thời gian hội tụ và tránh hiện tượng quên lãng thảm họa (catastrophic forgetting). Nghiên cứu không chỉ cung cấp một bộ Encoder tiên tiến cho các tác vụ xử lý ngôn ngữ thực tế tại Việt Nam, mà còn đề xuất một quy trình thích nghi ngôn ngữ tối ưu, tạo tiền đề cho việc cập nhật và ứng dụng các kiến trúc mô hình ngôn ngữ thế hệ mới một cách linh hoạt, tiết kiệm và bền vững.

2.3 Phạm vi của đề tài

Đề tài tập trung vào việc nghiên cứu thực nghiệm phương pháp thích nghi mô hình ngôn ngữ thế hệ mới NeoBERT cho ngôn ngữ tiếng Việt bằng cách tái sử dụng không gian biểu diễn từ các mô hình tiền huấn luyện sẵn có. Phạm vi cụ thể bao gồm các thành phần sau:

Đối tượng nghiên cứu chính:

- *Kiến trúc mô hình NeoBERT*: Tập trung vào các cải tiến hiện đại như SwiGLU activation, RoPE, và cấu trúc Pre-RMSNorm với khả năng hỗ trợ ngữ cảnh lên đến 4.096 tokens.
- *Thuật toán SALT*: Nghiên cứu cơ chế trích xuất tập neo (anchor tokens) dựa trên độ tương đồng ngữ nghĩa và phương pháp hồi quy tuyến tính (Linear Least Squares Transform) để ánh xạ không gian vector.
- *Mô hình nguồn (Source Model)*: Sử dụng bộ nhúng đã được tối ưu cho tiếng Việt từ mô hình ViDeBERTa để làm cơ sở chuyển đổi tri thức.

Tập dữ liệu thực nghiệm:

- *Ngữ liệu tiền huấn luyện*: Sử dụng các tập dữ liệu văn bản tiếng Việt quy mô lớn, được trích xuất và làm sạch từ Wikipedia và các trang tin tức tổng hợp nhằm phục vụ giai đoạn huấn luyện thích nghi (Language Adaptive Continual Pre-training).
- *Dữ liệu đánh giá*: Sử dụng các bộ benchmark tiêu chuẩn cho tiếng Việt như VLSP (phân loại văn bản, nhận dạng thực thể) và các tập dữ liệu con trong MTEB (Massive Text Embedding Benchmark) để đo lường khả năng biểu diễn ngữ nghĩa.

Các giới hạn và ràng buộc:

- *Về phương pháp*: Nghiên cứu không thực hiện huấn luyện mô hình NeoBERT từ đầu do hạn chế về tài nguyên tính toán; thay vào đó, tập trung tối ưu hóa quá trình chuyển đổi không gian embedding.
- *Về tác vụ*: Đề tài tập trung vào các bài toán thuộc nhóm Hiểu ngôn ngữ tự nhiên (NLU) và Trích xuất đặc trưng (Feature Extraction), không bao gồm các bài toán sinh văn bản tự do (NLG) của các mô hình Decoder-only.

2.4 Cách tiếp cận dự kiến

Các nghiên cứu liên quan:

Trong những năm qua, hướng nghiên cứu về các mô hình Encoder-only đã đạt được nhiều thành tựu quan trọng. Điển hình là kiến trúc BERT [4] và các biến thể cải tiến như RoBERTa [5] đã thiết lập nền tảng vững chắc cho việc biểu diễn ngữ nghĩa. Tại Việt Nam, các mô hình như PhoBERT hay ViDeBERTa [3] đã tận dụng phương pháp huấn luyện tiếp tục (Continued Pre-training) trên quy mô dữ liệu lớn để tối ưu hóa khả năng xử lý tiếng Việt. Tuy nhiên, các mô hình này chủ yếu dựa trên kiến trúc Transformer cũ, gặp hạn chế về tốc độ huấn luyện và độ dài ngữ cảnh.

Gần đây, nghiên cứu về NeoBERT [1] đã tái định nghĩa sức mạnh của Encoder

bằng cách tích hợp các thành phần hiện đại. NeoBERT chứng minh rằng một mô hình quy mô 250 triệu tham số, nếu được tối ưu về tỷ lệ chiều sâu-chiều rộng và huấn luyện trên 2,1 nghìn tỷ tokens, có thể vượt qua hiệu suất của các mô hình lớn hơn gấp nhiều lần trên chuẩn đánh giá MTEB.

Bên cạnh đó, bài toán thích nghi ngôn ngữ (Cross-lingual Transfer) đã có bước đột phá với kỹ thuật SALT [2]. Thay vì thay thế tập từ vựng một cách máy móc, SALT đề xuất cơ chế tái sử dụng bộ nhúng từ các mô hình tiền huấn luyện của ngôn ngữ mục tiêu. Kết quả thực nghiệm cho thấy SALT giúp tăng tốc độ hội tụ nhanh hơn và đạt mức tổn thất (loss) thấp hơn so với các phương pháp khởi tạo truyền thống, đồng thời duy trì khả năng liên kết tri thức xuyên ngôn ngữ.

Phương pháp thực hiện dự kiến:

Dựa trên việc kế thừa sức mạnh kiến trúc của NeoBERT và phương pháp chuyển đổi hiệu quả của SALT, đề tài đề xuất quy trình xây dựng mô hình Vietnamese NeoBERT thông qua các bước sau:

1. **Căn chỉnh không gian (Alignment Stage):** Sử dụng bộ nhúng tiếng Việt từ ViDeBERTa làm nguồn. Thông qua các bộ nhúng tĩnh (như fastText), thuật toán sẽ trích xuất một tập neo (Anchor Extraction) gồm các token có sự tương đồng cao về ngữ nghĩa giữa từ điển của NeoBERT và ViDeBERTa.
2. **Chuyển đổi tuyến tính nhận thức ngữ nghĩa:** Đối với mỗi token không trùng lặp trong từ điển tiếng Việt, hệ thống thiết lập các đường hồi quy tuyến tính riêng biệt (unique regression lines) thông qua phương pháp Bình phương tối thiểu (Linear Least Squares). Bước này giúp chuyển đổi trực tiếp các biểu diễn ngữ nghĩa từ ViDeBERTa vào đúng hệ tọa độ không gian mà NeoBERT đã được học.
3. **Huấn luyện thích nghi có chọn lọc:** Tiến hành huấn luyện tiếp tục trên ngữ liệu tiếng Việt. Để ngăn chặn hiện tượng quên lãng thảm họa, mô hình áp dụng chiến lược đóng băng (freezing) một phần các lớp Transformer và sử

dùng bộ lập lịch tốc độ học (learning rate scheduler) tối ưu nhằm tinh chỉnh lớp nhúng mới sao cho tương thích hoàn toàn với các lớp ẩn phía trên.

Sự khác biệt so với các nghiên cứu trước đây:

So với các phương pháp xây dựng mô hình tiếng Việt truyền thống, cách tiếp cận này không yêu cầu huấn luyện lại từ đầu mà thực hiện ánh xạ toán học để tái sử dụng tri thức. Điểm đột phá của đề tài là việc áp dụng SALT lên kiến trúc NeoBERT - một kiến trúc hiện đại hỗ trợ ngữ cảnh dài 4.096 tokens và sử dụng FlashAttention-2, thay vì áp dụng trên các kiến trúc BERT cũ. Điều này kỳ vọng sẽ tạo ra một bộ Encoder mạnh mẽ, tối ưu tài nguyên và có tốc độ suy luận nhanh nhất cho tiếng Việt.

2.5 Kết quả dự kiến của đề tài

Đề tài dự kiến đạt được các kết quả cụ thể về mặt định lượng, sản phẩm và đóng góp khoa học như sau:

Số liệu định lượng:

- *Hiệu suất mô hình:* Vietnamese NeoBERT dự kiến đạt kết quả tương đương hoặc vượt trội so với các mô hình baseline hiện tại (như PhoBERT, ViDeBERTa) trên các bài toán NLU thuộc bộ benchmark VLSP và tập dữ liệu MTEB tiếng Việt.
- *Tốc độ hội tụ và chi phí:* Nhờ việc khởi tạo lớp nhúng bằng SALT, quá trình huấn luyện dự kiến có tốc độ hội tụ nhanh hơn, giảm từ 40% đến 50% số lượng token cần thiết so với việc huấn luyện lại từ đầu hoặc tiếp tục tiền huấn luyện không có định hướng.
- *Tốc độ thực thi (Throughput):* Nhờ kiến trúc tối ưu (optimal depth-to-width), mô hình dự kiến đạt tốc độ suy luận nhanh hơn khoảng 30% - 45% so với các mô hình Encoder-large truyền thống trên cùng một cấu hình phần cứng.

- *Khả năng xử lý ngữ cảnh*: Mô hình xử lý ổn định các văn bản có độ dài lên tới 4.096 tokens, khắc phục được rào cản 512 tokens của các kiến trúc tiền nhiệm.

Sản phẩm đầu ra:

- Trọng số mô hình (Model Weights) Vietnamese NeoBERT hoàn chỉnh (250M tham số), tương thích với thư viện Hugging Face Transformers.
- Bộ mã nguồn (Source Code) bao gồm thuật toán trích xuất tập neo, hàm chuyển đổi tuyến tính SALT và kịch bản huấn luyện.
- Báo cáo thực nghiệm chi tiết so sánh độ chính xác, tốc độ và biểu đồ tổn thất (loss curve) giữa các phương pháp.

Đóng góp khoa học:

- Khẳng định khả năng ứng dụng của kiến trúc NeoBERT kết hợp với kỹ thuật SALT trong việc giải quyết bài toán thiếu hụt tài nguyên tính toán cho các ngôn ngữ ít nguồn lực.
- Kết quả nghiên cứu có triển vọng phát triển thành bài báo khoa học công bố tại các hội nghị chuyên ngành uy tín trong nước và quốc tế.

2.6 Kế hoạch thực hiện

Thời gian	Nội dung công việc	Người thực hiện
03/01/2026 – 20/01/2026	Khảo sát các tài liệu nghiên cứu về kiến trúc NeoBERT, thuật toán SALT và các phương pháp Cross-lingual Transfer.	Trung, Tú
21/01/2026 – 16/02/2026	Thu thập và tiền xử lý ngữ liệu tiếng Việt; xây dựng pipeline; chuẩn bị môi trường huấn luyện.	Trung, Tú
16/02/2026 – 10/03/2026	Cài đặt thuật toán trích xuất tập neo; lập trình mô-đun hồi quy tuyến tính (Least Squares) cho các non-shared tokens.	Trung
	Huấn luyện mô hình NeoBert baseline trên dữ liệu tiếng Việt mà không dùng SALT.	Tú
11/03/2026 – 31/04/2026	Thực hiện giai đoạn ánh xạ không gian vector và tiến hành huấn luyện thích nghi (Language Adaptive Continual Pre-training). Bên cạnh đó thực nghiệm đánh giá mô hình NeoBert baseline về cả hiệu suất và chi phí huấn luyện.	Trung, Tú
01/04/2026 – 15/04/2026	Thực nghiệm đánh giá mô hình NeoBert có sử dụng SALT và so sánh kết quả với baseline. Đánh giá cả hai mô hình trên cả quá trình huấn luyện và hiệu suất của mô hình.	Trung, Tú
16/04/2026 – 15/05/2026	Thực hiện các thí nghiệm để so sánh mô hình NeoBert tiếng Việt với các mô hình khác. Đánh giá và phân tích kết quả của thí nghiệm.	Trung, Tú
16/05/2026 – 28/07/2026	Viết báo cáo khóa luận, trực quan hóa kết quả bằng biểu đồ và chuẩn bị slide bảo vệ.	Trung, Tú

Tài liệu

- [1] L. L. Breton, Q. Fournier, J. X. Morris, M. E. Mezouar, and S. Chandar, "NeoBERT: A Next-Generation BERT," *arXiv preprint arXiv:2502.19587v2*, 2025.
- [2] S. Lee, S. Hong, H. Moon, and H. Lim, "Semantic Aware Linear Transfer by Recycling Pre-trained Language Models for Cross-lingual Transfer," *arXiv preprint arXiv:2505.10945v2*, 2025.
- [3] V. D. Lai, C. V. Nguyen, N. T. Ngo, T. Nguyen, F. Dernoncourt, R. A. Rossi, and T. H. Nguyen, "ViDeBERTa: A Powerful Pre-trained Language Model

for Vietnamese," in *Findings of the Association for Computational Linguistics: EACL 2023*, pp. 1032–1043, 2023.

- [4] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, pp. 4171–4186, 2019.
- [5] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "RoBERTa: A Robustly Optimized BERT Pretraining Approach," *arXiv preprint arXiv:1907.11692*, 2019.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày... tháng... năm...
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)