

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Bùi Khắc Trung - Trần Anh Tú

NGHIÊN CỨU PHƯƠNG PHÁP XÂY
DỰNG NEOBERT CHO TIẾNG VIỆT

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Bùi Khắc Trung - Trần Anh Tú
22120396 - 22120400

NGHIÊN CỨU PHƯƠNG PHÁP XÂY
DỰNG NEOBERT CHO TIẾNG VIỆT

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

TS. Nguyễn Hồng Bửu Long - TS. Lương An Vinh

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Chúng tôi xin cam đoan khóa luận tốt nghiệp với đề tài “*Nghiên cứu phương pháp xây dựng NeoBERT cho tiếng Việt*” là công trình nghiên cứu của chính nhóm chúng tôi, được thực hiện dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long và TS. Lương An Vinh.

Các số liệu, kết quả thực nghiệm được trình bày trong khóa luận là trung thực, do chính nhóm thực hiện và chưa từng được công bố trong bất kỳ công trình nào khác trước đây. Tất cả các tài liệu, công trình nghiên cứu liên quan được kế thừa trong khóa luận đều đã được trích dẫn nguồn gốc rõ ràng, đầy đủ trong danh mục tài liệu tham khảo.

Chúng tôi xin chịu hoàn toàn trách nhiệm trước Bộ môn, Khoa và Nhà trường về lời cam đoan này.

Thành phố Hồ Chí Minh, tháng 07 năm 2026

Nhóm sinh viên thực hiện

Bùi Khắc Trung

Trần Anh Tú

Thuyết minh chỉnh sửa đề tài

Bản thuyết minh chỉnh sửa đề tài (nếu có thay đổi tên đề tài, nội dung báo cáo, ... trong cuốn báo cáo sau bảo vệ)

Nhận xét hướng dẫn

Bản nhận xét của giảng viên hướng dẫn (có chữ ký) do giáo vụ cung cấp.

Nhận xét phản biện

Bản nhận xét của giảng viên phản biện (có chữ ký) do giáo vụ cung cấp.

Lời cảm ơn

Lời đầu tiên, chúng tôi xin gửi lời cảm ơn sâu sắc đến thầy TS. Nguyễn Hồng Bửu Long và thầy TS. Lương An Vinh. Hai thầy đã cho phép nhóm thực hiện đề tài khóa luận này và dành nhiều thời gian, tận tâm hướng dẫn nhóm trong suốt quá trình nghiên cứu. Những kiến thức sâu rộng, những định hướng đúng đắn cùng các góp ý quý báu của các thầy đã giúp chúng tôi không chỉ hoàn thành tốt khóa luận mà còn trưởng thành hơn về tư duy nghiên cứu trong lĩnh vực Học sâu nói chung và Xử lý ngôn ngữ tự nhiên nói riêng.

Chúng tôi xin chân thành cảm ơn quý thầy cô Bộ môn Công nghệ tri thức đã tạo điều kiện thuận lợi về môi trường nghiên cứu trong quá trình nhóm thực hiện đề tài.

Đặc biệt, chúng tôi xin bày tỏ lòng biết ơn đến Khoa Công nghệ thông tin, Trường Đại học Khoa học tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh vì đã mang lại một môi trường học tập và phát triển tuyệt vời. Chúng tôi cũng xin gửi lời cảm ơn đến tất cả quý thầy cô đã tận tâm truyền đạt những kiến thức nền tảng và những bài học quý giá trong suốt quá trình chúng tôi học tập tại trường.

Chúng tôi cũng xin gửi lời cảm ơn đến gia đình, bạn bè và các anh chị khóa trên đã luôn đồng hành, động viên và giúp đỡ nhóm trong suốt quá trình học tập và nghiên cứu. Chính sự quan tâm và giúp đỡ này là nguồn động lực to lớn để chúng tôi luôn cố gắng phấn đấu hoàn thành thật tốt những mục tiêu đã đặt ra.

Mặc dù đã rất nỗ lực, khóa luận khó tránh khỏi những thiếu sót. Chúng

tôi rất mong nhận được sự thông cảm cùng những ý kiến đóng góp của quý thầy cô và các bạn để khóa luận được hoàn thiện hơn.

Một lần nữa, chúng tôi xin chân thành cảm ơn tất cả những người đã giúp đỡ nhóm trong quá trình thực hiện khóa luận tốt nghiệp này.

Thành phố Hồ Chí Minh, tháng 07 năm 2026

Nhóm sinh viên thực hiện

Bùi Khắc Trung – Trần Anh Tú



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP NGHIÊN CỨU PHƯƠNG PHÁP XÂY DỰNG NEOBERT CHO TIẾNG VIỆT

1 THÔNG TIN CHUNG

Người hướng dẫn:

- TS. Nguyễn Hồng Bửu Long (Khoa Công nghệ Thông tin)
- TS. Lương An Vinh (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Bùi Khắc Trung (MSSV: 22120396)
2. Trần Anh Tú (MSSV: 22120400)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 1/2026 đến 7/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong lịch sử phát triển của lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), các mô hình dạng Encoder-only như BERT và RoBERTa từng giữ vai trò nền tảng trong các bài toán hiểu ngôn ngữ. Tuy nhiên, trong khi các dòng mô hình Decoder-only (LLMs) liên tục tiến hóa với quy mô dữ liệu và kiến trúc đột phá, các bộ Encoder gần như không có sự cải thiện đáng kể trong suốt vài năm qua. Phải đến năm 2025, sự ra đời của NeoBERT [1] mới thực sự thu hẹp khoảng cách này. NeoBERT tái định nghĩa khả năng của mô hình bằng cách tích hợp các cải tiến kiến trúc tiên tiến nhất như hàm kích hoạt SwiGLU, vị trí tương đối Rotary Position Embeddings (RoPE), và chuẩn hóa Pre-RMSNorm. Đặc biệt, NeoBERT tối ưu hóa tỷ lệ chiều sâu trên chiều rộng (optimal depth-to-width ratio) với 28 lớp ẩn trên kích thước 768, cho phép mô hình đạt hiệu suất vượt trội trên chuẩn đánh giá MTEB so với các dòng BERT-large dù chỉ sở hữu 250 triệu tham số.

Mặc dù sở hữu sức mạnh suy luận vượt trội và hỗ trợ độ dài ngữ cảnh lên tới 4.096 tokens, việc thích nghi NeoBERT cho ngôn ngữ tiếng Việt vẫn đối mặt với những thách thức lớn. Việc huấn luyện lại từ đầu (from scratch) trên quy mô hàng nghìn tỷ tokens như NeoBERT gốc là điều bất khả thi về mặt tài nguyên. Bên cạnh đó, các phương pháp tiếp tục tiền huấn luyện (Continued Pre-training) thông thường dễ dẫn đến hiện tượng quên lãng thảm họa (catastrophic forgetting), làm phá vỡ các đặc trưng biểu diễn quý giá mà mô hình đã học từ dữ liệu ban đầu.

Xuất phát từ bối cảnh trên, đề tài tập trung nghiên cứu phương pháp thích nghi ngôn ngữ cho NeoBERT bằng kỹ thuật SALT (Semantic Aware Linear Transfer) [2]. Ý tưởng cốt lõi của nghiên cứu là tái sử dụng (recycling) bộ nhúng từ các mô hình tiền huấn luyện tiếng Việt chất lượng cao như ViDeBERTa [3]. Thay vì khởi tạo ngẫu nhiên, phương pháp thực hiện chuyển đổi tuyến tính dựa trên nhận thức ngữ nghĩa: đối với mỗi token không trùng lặp, thuật toán sẽ thiết lập các đường

hồi quy tuyến tính riêng biệt dựa trên tập từ vựng chung. Quá trình này giúp ánh xạ chính xác các thành phần ngữ nghĩa từ không gian của ViDeBERTa sang không gian của NeoBERT.

Thông qua đó, nghiên cứu hướng tới việc xây dựng mô hình Vietnamese NeoBERT có khả năng xử lý ngữ cảnh dài, tốc độ suy luận nhanh và độ chính xác cao. Kết quả của đề tài không chỉ mang ý nghĩa về mặt hiệu suất mà còn khẳng định tính khả thi của việc tối ưu hóa tài nguyên huấn luyện. Cụ thể, việc linh hoạt tái sử dụng không gian biểu diễn (embedding) từ các mô hình ngôn ngữ mạnh mẽ sẵn có mở ra một hướng tiếp cận tiết kiệm và hiệu quả để chuyển đổi ngôn ngữ cho các kiến trúc LLM thế hệ mới, thay vì phải đầu tư chi phí khổng lồ cho việc huấn luyện lại từ đầu.

2.2 Mục tiêu đề tài

Trong bối cảnh các mô hình ngôn ngữ lớn đang đạt được những bước tiến vượt bậc về khả năng suy luận, các kiến trúc Encoder-only vẫn đóng vai trò nền tảng không thể thay thế trong các tác vụ trích xuất đặc trưng và biểu diễn ngữ nghĩa văn bản. Tuy nhiên, các mô hình Encoder dành cho tiếng Việt hiện nay chủ yếu dựa trên những kiến trúc cũ, thiếu đi sự tối ưu từ các kỹ thuật hiện đại và bị giới hạn ở độ dài ngữ cảnh ngắn. Việc huấn luyện lại các kiến trúc thế hệ mới như NeoBERT từ đầu cho tiếng Việt đòi hỏi nguồn lực tính toán khổng lồ. Do đó, việc nghiên cứu một phương pháp thích nghi ngôn ngữ hiệu quả, ít tốn kém nhưng vẫn bảo toàn được sức mạnh của mô hình gốc là một nhu cầu cấp thiết.

Đề tài tập trung nghiên cứu việc khai thác và chuyển đổi tri thức từ các mô hình ngôn ngữ tiền huấn luyện tiếng Việt sẵn có vào kiến trúc NeoBERT thông qua kỹ thuật SALT. Mục tiêu cụ thể là sử dụng các tập neo (anchor tokens) để tính toán các đường hồi quy tuyến tính riêng biệt, từ đó ánh xạ chính xác không gian biểu diễn (embedding) của mô hình nguồn (tiêu biểu như ViDeBERTa) sang không gian vector của NeoBERT. Thông qua cách tiếp cận này, nghiên cứu hướng

đến việc xây dựng một mô hình Vietnamese NeoBERT có khả năng xử lý ngữ cảnh dài (lên tới 4.096 tokens) với tốc độ hội tụ nhanh và chi phí huấn luyện thấp hơn đáng kể so với các phương pháp truyền thống.

Kết quả của đề tài sẽ góp phần chứng minh hiệu quả của việc linh hoạt tái sử dụng không gian biểu diễn từ các mô hình ngôn ngữ mạnh mẽ sẵn có để chuyển giao tri thức, giúp rút ngắn thời gian hội tụ và tránh hiện tượng quên lãng thảm họa (catastrophic forgetting). Nghiên cứu không chỉ cung cấp một bộ Encoder tiên tiến cho các tác vụ xử lý ngôn ngữ thực tế tại Việt Nam, mà còn đề xuất một quy trình thích nghi ngôn ngữ tối ưu, tạo tiền đề cho việc cập nhật và ứng dụng các kiến trúc mô hình ngôn ngữ thế hệ mới một cách linh hoạt, tiết kiệm và bền vững.

2.3 Phạm vi của đề tài

Đề tài tập trung vào việc nghiên cứu thực nghiệm phương pháp thích nghi mô hình ngôn ngữ thế hệ mới NeoBERT cho ngôn ngữ tiếng Việt bằng cách tái sử dụng không gian biểu diễn từ các mô hình tiền huấn luyện sẵn có. Phạm vi cụ thể bao gồm các thành phần sau:

Đối tượng nghiên cứu chính:

- *Kiến trúc mô hình NeoBERT*: Tập trung vào các cải tiến hiện đại như SwiGLU activation, RoPE, và cấu trúc Pre-RMSNorm với khả năng hỗ trợ ngữ cảnh lên đến 4.096 tokens.
- *Thuật toán SALT*: Nghiên cứu cơ chế trích xuất tập neo (anchor tokens) dựa trên độ tương đồng ngữ nghĩa và phương pháp hồi quy tuyến tính (Linear Least Squares Transform) để ánh xạ không gian vector.
- *Mô hình nguồn (Source Model)*: Sử dụng bộ nhúng đã được tối ưu cho tiếng Việt từ mô hình ViDeBERTa để làm cơ sở chuyển đổi tri thức.

Tập dữ liệu thực nghiệm:

- *Ngữ liệu tiền huấn luyện*: Sử dụng các tập dữ liệu văn bản tiếng Việt quy mô lớn, được trích xuất và làm sạch từ Wikipedia và các trang tin tức tổng hợp nhằm phục vụ giai đoạn huấn luyện thích nghi (Language Adaptive Continual Pre-training).
- *Dữ liệu đánh giá*: Sử dụng các bộ benchmark tiêu chuẩn cho tiếng Việt như VLSP (phân loại văn bản, nhận dạng thực thể) và các tập dữ liệu con trong MTEB (Massive Text Embedding Benchmark) để đo lường khả năng biểu diễn ngữ nghĩa.

Các giới hạn và ràng buộc:

- *Về phương pháp*: Nghiên cứu không thực hiện huấn luyện mô hình NeoBERT từ đầu do hạn chế về tài nguyên tính toán; thay vào đó, tập trung tối ưu hóa quá trình chuyển đổi không gian embedding.
- *Về tác vụ*: Đề tài tập trung vào các bài toán thuộc nhóm Hiểu ngôn ngữ tự nhiên (NLU) và Trích xuất đặc trưng (Feature Extraction), không bao gồm các bài toán sinh văn bản tự do (NLG) của các mô hình Decoder-only.

2.4 Cách tiếp cận dự kiến

Các nghiên cứu liên quan:

Trong những năm qua, hướng nghiên cứu về các mô hình Encoder-only đã đạt được nhiều thành tựu quan trọng. Điển hình là kiến trúc BERT [4] và các biến thể cải tiến như RoBERTa [5] đã thiết lập nền tảng vững chắc cho việc biểu diễn ngữ nghĩa. Tại Việt Nam, các mô hình như PhoBERT hay ViDeBERTa [3] đã tận dụng phương pháp huấn luyện tiếp tục (Continued Pre-training) trên quy mô dữ liệu lớn để tối ưu hóa khả năng xử lý tiếng Việt. Tuy nhiên, các mô hình này chủ yếu dựa trên kiến trúc Transformer cũ, gặp hạn chế về tốc độ huấn luyện và độ dài ngữ cảnh.

Gần đây, nghiên cứu về NeoBERT [1] đã tái định nghĩa sức mạnh của Encoder

bằng cách tích hợp các thành phần hiện đại. NeoBERT chứng minh rằng một mô hình quy mô 250 triệu tham số, nếu được tối ưu về tỷ lệ chiều sâu-chiều rộng và huấn luyện trên 2,1 nghìn tỷ tokens, có thể vượt qua hiệu suất của các mô hình lớn hơn gấp nhiều lần trên chuẩn đánh giá MTEB.

Bên cạnh đó, bài toán thích nghi ngôn ngữ (Cross-lingual Transfer) đã có bước đột phá với kỹ thuật SALT [2]. Thay vì thay thế tập từ vựng một cách máy móc, SALT đề xuất cơ chế tái sử dụng bộ nhúng từ các mô hình tiền huấn luyện của ngôn ngữ mục tiêu. Kết quả thực nghiệm cho thấy SALT giúp tăng tốc độ hội tụ nhanh hơn và đạt mức tổn thất (loss) thấp hơn so với các phương pháp khởi tạo truyền thống, đồng thời duy trì khả năng liên kết tri thức xuyên ngôn ngữ.

Phương pháp thực hiện dự kiến:

Dựa trên việc kế thừa sức mạnh kiến trúc của NeoBERT và phương pháp chuyển đổi hiệu quả của SALT, đề tài đề xuất quy trình xây dựng mô hình Vietnamese NeoBERT thông qua các bước sau:

- 1. Căn chỉnh không gian (Alignment Stage):** Sử dụng bộ nhúng tiếng Việt từ ViDeBERTa làm nguồn. Thông qua các bộ nhúng tĩnh (như fastText), thuật toán sẽ trích xuất một tập neo (Anchor Extraction) gồm các token có sự tương đồng cao về ngữ nghĩa giữa từ điển của NeoBERT và ViDeBERTa.
- 2. Chuyển đổi tuyến tính nhận thức ngữ nghĩa:** Đối với mỗi token không trùng lặp trong từ điển tiếng Việt, hệ thống thiết lập các đường hồi quy tuyến tính riêng biệt (unique regression lines) thông qua phương pháp Bình phương tối thiểu (Linear Least Squares). Bước này giúp chuyển đổi trực tiếp các biểu diễn ngữ nghĩa từ ViDeBERTa vào đúng hệ tọa độ không gian mà NeoBERT đã được học.
- 3. Huấn luyện thích nghi có chọn lọc:** Tiến hành huấn luyện tiếp tục trên ngữ liệu tiếng Việt. Để ngăn chặn hiện tượng quên lãng thảm họa, mô hình áp dụng chiến lược đóng băng (freezing) một phần các lớp Transformer và sử

dụng bộ lập lịch tốc độ học (learning rate scheduler) tối ưu nhằm tinh chỉnh lớp nhúng mới sao cho tương thích hoàn toàn với các lớp ẩn phía trên.

Sự khác biệt so với các nghiên cứu trước đây:

So với các phương pháp xây dựng mô hình tiếng Việt truyền thống, cách tiếp cận này không yêu cầu huấn luyện lại từ đầu mà thực hiện ánh xạ toán học để tái sử dụng tri thức. Điểm đột phá của đề tài là việc áp dụng SALT lên kiến trúc NeoBERT - một kiến trúc hiện đại hỗ trợ ngữ cảnh dài 4.096 tokens và sử dụng FlashAttention-2, thay vì áp dụng trên các kiến trúc BERT cũ. Điều này kỳ vọng sẽ tạo ra một bộ Encoder mạnh mẽ, tối ưu tài nguyên và có tốc độ suy luận nhanh nhất cho tiếng Việt.

2.5 Kết quả dự kiến của đề tài

Đề tài dự kiến đạt được các kết quả cụ thể về mặt định lượng, sản phẩm và đóng góp khoa học như sau:

Số liệu định lượng:

- *Hiệu suất mô hình:* Vietnamese NeoBERT dự kiến đạt kết quả tương đương hoặc vượt trội so với các mô hình baseline hiện tại (như PhoBERT, ViDeBERTa) trên các bài toán NLU thuộc bộ benchmark VLSP và tập dữ liệu MTEB tiếng Việt.
- *Tốc độ hội tụ và chi phí:* Nhờ việc khởi tạo lớp nhúng bằng SALT, quá trình huấn luyện dự kiến có tốc độ hội tụ nhanh hơn, giảm từ 40% đến 50% số lượng token cần thiết so với việc huấn luyện lại từ đầu hoặc tiếp tục tiền huấn luyện không có định hướng.
- *Tốc độ thực thi (Throughput):* Nhờ kiến trúc tối ưu (optimal depth-to-width), mô hình dự kiến đạt tốc độ suy luận nhanh hơn khoảng 30% - 45% so với các mô hình Encoder-large truyền thống trên cùng một cấu hình phần cứng.

- *Khả năng xử lý ngữ cảnh:* Mô hình xử lý ổn định các văn bản có độ dài lên tới 4.096 tokens, khắc phục được rào cản 512 tokens của các kiến trúc tiền nhiệm.

Sản phẩm đầu ra:

- Trọng số mô hình (Model Weights) Vietnamese NeoBERT hoàn chỉnh (250M tham số), tương thích với thư viện Hugging Face Transformers.
- Bộ mã nguồn (Source Code) bao gồm thuật toán trích xuất tập neo, hàm chuyển đổi tuyến tính SALT và kịch bản huấn luyện.
- Báo cáo thực nghiệm chi tiết so sánh độ chính xác, tốc độ và biểu đồ tổn thất (loss curve) giữa các phương pháp.

Đóng góp khoa học:

- Khẳng định khả năng ứng dụng của kiến trúc NeoBERT kết hợp với kỹ thuật SALT trong việc giải quyết bài toán thiếu hụt tài nguyên tính toán cho các ngôn ngữ ít nguồn lực.
- Kết quả nghiên cứu có triển vọng phát triển thành bài báo khoa học công bố tại các hội nghị chuyên ngành uy tín trong nước và quốc tế.

2.6 Kế hoạch thực hiện

Thời gian	Nội dung công việc	Người thực hiện
03/01/2026 – 20/01/2026	Khảo sát các tài liệu nghiên cứu về kiến trúc NeoBERT, thuật toán SALT và các phương pháp Cross-lingual Transfer.	Trung, Tú
21/01/2026 – 16/02/2026	Thu thập và tiền xử lý ngữ liệu tiếng Việt; xây dựng pipeline; chuẩn bị môi trường huấn luyện.	Trung, Tú
16/02/2026 – 10/03/2026	Cài đặt thuật toán trích xuất tập neo; lập trình mô-đun hồi quy tuyến tính (Least Squares) cho các non-shared tokens.	Trung
	Huấn luyện mô hình NeoBert baseline trên dữ liệu tiếng Việt mà không dùng SALT.	Tú
11/03/2026 – 31/04/2026	Thực hiện giai đoạn ánh xạ không gian vector và tiến hành huấn luyện thích nghi (Language Adaptive Continual Pre-training). Bên cạnh đó thực nghiệm đánh giá mô hình NeoBert baseline về cả hiệu suất và chi phí huấn luyện.	Trung, Tú
01/04/2026 – 15/04/2026	Thực nghiệm đánh giá mô hình NeoBert có sử dụng SALT và so sánh kết quả với baseline. Đánh giá cả hai mô hình trên cả quá trình huấn luyện và hiệu suất của mô hình.	Trung, Tú
16/04/2026 – 15/05/2026	Thực hiện các thí nghiệm để so sánh mô hình NeoBert tiếng Việt với các mô hình khác. Đánh giá và phân tích kết quả của thí nghiệm.	Trung, Tú
16/05/2026 – 28/07/2026	Viết báo cáo khóa luận, trực quan hóa kết quả bằng biểu đồ và chuẩn bị slide bảo vệ.	Trung, Tú

Tài liệu

- [1] L. L. Breton, Q. Fournier, J. X. Morris, M. E. Mezouar, and S. Chandar, "NeoBERT: A Next-Generation BERT," *arXiv preprint arXiv:2502.19587v2*, 2025.
- [2] S. Lee, S. Hong, H. Moon, and H. Lim, "Semantic Aware Linear Transfer by Recycling Pre-trained Language Models for Cross-lingual Transfer," *arXiv preprint arXiv:2505.10945v2*, 2025.
- [3] V. D. Lai, C. V. Nguyen, N. T. Ngo, T. Nguyen, F. Dernoncourt, R. A. Rossi, and T. H. Nguyen, "ViDeBERTa: A Powerful Pre-trained Language Model

for Vietnamese," in *Findings of the Association for Computational Linguistics: EACL 2023*, pp. 1032–1043, 2023.

- [4] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, pp. 4171–4186, 2019.
- [5] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "RoBERTa: A Robustly Optimized BERT Pretraining Approach," *arXiv preprint arXiv:1907.11692*, 2019.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày... tháng... năm...
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Danh sách các từ viết tắt

KÝ HIỆU	TÊN TIẾNG ANH
NLP	Natural Language Processing
NLU	Natural Language Understanding
LLM	Large Language Model
PLM	Pre-trained Language Model
MLM	Masked Language Modeling
NSP	Next Sentence Prediction
CPT	Continued Pre-training
WSD	Warmup–Stable–Decay
RoPE	Rotary Position Embeddings
FFN	Feed-Forward Network
GLU	Gated Linear Unit
GELU	Gaussian Error Linear Unit
SiLU	Sigmoid Linear Unit
RMSNorm	Root Mean Square Normalization
SALT	Semantic Aware Linear Transfer
MRC	Machine Reading Comprehension
EM	Exact Match
PPL	Perplexity
MTEB	Massive Text Embedding Benchmark
OOV	Out-Of-Vocabulary

Mục lục

Lời cam đoan	i
Thuyết minh chỉnh sửa đề tài	ii
Nhận xét của GV hướng dẫn	iii
Nhận xét của GV phản biện	iv
Lời cảm ơn	v
Đề cương	vii
Danh sách các từ viết tắt	xvii
Mục lục	xvii
Danh sách hình	xxii
Danh sách bảng	xxiii
Tóm tắt	xxiii
1 Tổng quan	1
1.1 Bối cảnh và sự cần thiết của đề tài	1
1.2 Mục tiêu nghiên cứu	3
1.3 Phạm vi nghiên cứu	4

1.4	Đóng góp của đề tài	5
1.5	Cấu trúc đề tài	6
2	Cơ sở lý thuyết và các công trình liên quan	7
2.1	Kiến trúc Transformer và mô hình Encoder-only	8
2.1.1	Cơ chế tự chú ý trong kiến trúc Transformer	8
2.1.2	BERT và mô hình hóa ngôn ngữ có mặt nạ	9
2.1.3	Giới hạn của các mô hình Encoder thế hệ cũ	10
2.2	Kiến trúc NeoBERT	11
2.2.1	Tổng quan	11
2.2.2	Tỷ lệ chiều sâu trên chiều rộng tối ưu	12
2.2.3	Mã hóa vị trí quay (Rotary Position Embeddings)	13
2.2.4	Hàm kích hoạt SwiGLU	14
2.2.5	Chuẩn hóa Pre-RMSNorm	15
2.2.6	Dữ liệu và chiến lược tiền huấn luyện	17
2.3	Chuyển giao không gian nhúng và thích nghi ngôn ngữ	17
2.3.1	Hình học của không gian biểu diễn	17
2.3.2	Thích nghi ngôn ngữ và rủi ro quên lãng	18
2.3.3	Khởi tạo nhúng có thông tin	19
2.3.4	Semantic Aware Linear Transfer (SALT)	19
2.4	Nhận xét định hướng	20
3	Phương pháp xây dựng Vietnamese NeoBERT	21
3.1	Tổng quan phương pháp	21
3.1.1	Đặt vấn đề	21
3.1.2	Mô hình nguồn và mô hình hiển tặng	22
3.1.3	Quy trình ba giai đoạn	22
3.2	Cắt tỉa và đồng bộ từ vựng	23
3.3	Trích xuất tập neo (anchor set)	24
3.3.1	Vai trò của tập neo	24
3.3.2	Neo trùng lặp bề mặt và neo số	25
3.3.3	Mở rộng tập neo bằng cặp dịch ba tầng	26

3.4	Phép chiếu SALT cho lớp nhúng và lớp đầu ra	27
3.4.1	Lựa chọn neo bằng Sparsemax	27
3.4.2	Ánh xạ tuyến tính cục bộ theo từng token	28
3.4.3	Áp dụng cho cả lớp nhúng đầu vào và lớp đầu ra	29
3.4.4	Hiệu chỉnh chuẩn của lớp nhúng	29
3.4.5	Khởi tạo độ chệch đầu ra theo tần suất	30
3.4.6	Co trọng số đầu ra để tiên nghiệm dẫn dắt giai đoạn đầu	31
3.5	Giai đoạn căn chỉnh đóng băng	32
3.6	Tiếp tục tiền huấn luyện thích nghi	32
3.7	Tổng kết phương pháp	34
4	Thực nghiệm và Đánh giá	35
4.1	Môi trường và dữ liệu thực nghiệm	35
4.1.1	Môi trường thực nghiệm	35
4.1.2	Dữ liệu tiền huấn luyện	36
4.1.3	Dữ liệu đánh giá hạ nguồn	36
4.2	Cấu hình huấn luyện	37
4.3	Độ đo đánh giá	38
4.4	So sánh các phương án khởi tạo	39
4.4.1	Các phương án so sánh	39
4.4.2	Kết quả mô hình hóa ngôn ngữ	39
4.4.3	Ảnh hưởng tới tác vụ hạ nguồn	41
4.5	Kết quả của mô hình cuối	42
4.5.1	Diễn tiến theo ngân sách huấn luyện	42
4.5.2	Đánh giá đa nhiệm tại mốc 5 triệu tài liệu	43
4.6	Thảo luận	45
5	Kết luận và Hướng phát triển	46
5.1	Kết luận	46
5.2	Hạn chế của đề tài	48
5.3	Hướng phát triển	48

Tài liệu tham khảo	50
Phụ lục	55
A Bộ lọc chính tả tiếng Việt cho khai thác neo	56

Danh sách hình

2.1	Luồng xử lý của một mô hình Encoder-only kiểu BERT.	9
2.2	Kiến trúc NeoBERT.	12
2.3	Sơ đồ tổng quan SALT	20
3.1	Quy trình ba giai đoạn xây dựng ViNeoBERT.	23
3.2	Lịch tốc độ học Warmup–Stable–Decay theo Công thức (3.8).	33
4.1	Mất mát MLM trên tập đánh giá của tám phương án khởi tạo.	40
4.2	Điểm F1 trên UIT-ViQuAD của tám phương án khởi tạo sau 100 nghìn tài liệu CPT.	42
4.3	Điểm F1 trên UIT-ViQuAD theo ngân sách tiếp tục tiền huấn luyện.	43

Danh sách bảng

4.1	Thống kê dữ liệu sử dụng trong thực nghiệm.	36
4.2	Siêu tham số của các giai đoạn huấn luyện.	37
4.3	Các phương án khởi tạo trong thí nghiệm so sánh.	39
4.4	Kết quả đánh giá đa nhiệm tại mốc 5 triệu tài liệu (trung bình $\pm$ độ lệch chuẩn qua 5 lần chạy; kết quả tốt nhất mỗi hàng in đậm; ô “—” chưa được đo).	44

Tóm tắt

Các mô hình Encoder-only như BERT giữ vai trò nền tảng cho các bài toán hiểu ngôn ngữ tự nhiên, nhưng trong nhiều năm gần như không được cập nhật về kiến trúc. NeoBERT (2025) thu hẹp khoảng cách này bằng cách tích hợp các cải tiến từ thế hệ mô hình ngôn ngữ lớn – RoPE, SwiGLU, Pre-RMSNorm, tỷ lệ sâu–hẹp tối ưu và ngữ cảnh 4.096 token – song chỉ được tiền huấn luyện trên tiếng Anh, trong khi các Encoder tiếng Việt hiện có vẫn dựa trên kiến trúc thế hệ cũ.

Khóa luận xây dựng **ViNeoBERT** – mô hình NeoBERT cho tiếng Việt – bằng quy trình thích nghi ngôn ngữ ba giai đoạn thay vì huấn luyện lại từ đầu: (1) khởi tạo lớp nhúng và lớp đầu ra bằng kỹ thuật Semantic Aware Linear Transfer (SALT), tái sử dụng không gian nhúng của mô hình tiếng Việt ViDeBERTa thông qua các ánh xạ tuyến tính cục bộ theo từng token; (2) căn chỉnh đóng băng: chỉ huấn luyện hai ma trận vừa khởi tạo trên phần thân cố định; và (3) tiếp tục tiền huấn luyện trên ngữ liệu CulturaX tiếng Việt theo lịch tốc độ học Warmup–Stable–Decay. So với SALT gốc, đề tài đưa ra ba cải tiến: mở rộng tập neo bằng cặp dịch Anh–Việt khai thác tự động (kèm cơ chế lọc từ đồng tự khác nghĩa), khởi tạo riêng lớp đầu ra tách rời với độ chệch theo tần suất từ đơn và hệ số co trọng số, cùng giai đoạn căn chỉnh đóng băng.

Thực nghiệm so sánh tám phương án khởi tạo ở cùng ngân sách huấn luyện xác nhận từng lựa chọn thiết kế: nhóm khởi tạo SALT vượt mọi đối chứng ngẫu nhiên ở cả mô hình hóa ngôn ngữ lẫn tác vụ hạ nguồn. Trên bộ đánh giá gồm mười tác vụ hiểu tiếng Việt, ViNeoBERT sau 5 triệu tài

liệu dẫn đầu 4/10 tác vụ (trong đó có đọc hiểu UIT-ViQuAD với 76,2 điểm F1) và bằng hoặc vượt XLM-R-base ở 8/10 tác vụ, dù lượng tiếng Việt tiếp xúc ít hơn các mô hình đối sánh một đến hai bậc – cho thấy tái sử dụng không gian biểu diễn sẵn có là con đường tiết kiệm và hiệu quả để đưa các kiến trúc Encoder thế hệ mới đến với tiếng Việt.

Từ khóa: NeoBERT, tiếng Việt, thích nghi ngôn ngữ, khởi tạo nhúng xuyên ngôn ngữ, SALT, tiếp tục tiền huấn luyện.

Chương 1

Tổng quan

1.1 Bối cảnh và sự cần thiết của đề tài

Trong lịch sử phát triển của lĩnh vực Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing – NLP), các mô hình dạng Encoder-only như BERT [1] và RoBERTa [2] từng đóng vai trò nền tảng không thể thiếu cho các bài toán hiểu ngôn ngữ (Natural Language Understanding – NLU) như phân loại văn bản, nhận dạng thực thể có tên, suy luận ngôn ngữ tự nhiên và trả lời câu hỏi. Nhờ cơ chế mã hóa hai chiều (bidirectional encoding), các mô hình này có khả năng nắm bắt ngữ cảnh từ cả hai phía của một chuỗi đầu vào, tạo ra biểu diễn ngữ nghĩa phong phú và được ứng dụng rộng rãi trong thực tế.

Tuy nhiên, trong khi các dòng mô hình Decoder-only – hay còn gọi là các Mô hình Ngôn ngữ Lớn (Large Language Models – LLMs) như LLaMA [3] và DeepSeek [4] – liên tục tiến hóa với quy mô dữ liệu và những đột phá về kiến trúc, các bộ Encoder-only lại gần như không có sự cải thiện đáng kể trong suốt nhiều năm qua. BERT và RoBERTa vẫn tiếp tục được sử dụng rộng rãi dù kiến thức của chúng ngày càng trở nên lỗi thời, đặc biệt trong các ứng dụng đòi hỏi hiểu ngữ cảnh dài hoặc tốc độ suy luận cao.

Sự ra đời của NeoBERT [5] vào năm 2025 đã thu hẹp đáng kể khoảng cách này. NeoBERT tái định nghĩa khả năng của các mô hình Encoder

bằng cách tích hợp các cải tiến kiến trúc tiên tiến nhất từ thế giới LLM: hàm kích hoạt SwiGLU, cơ chế mã hóa vị trí tương đối Rotary Position Embeddings (RoPE), chuẩn hóa Pre-RMSNorm, và tỷ lệ chiều sâu trên chiều rộng tối ưu (28 lớp ẩn với kích thước ẩn 768). Với khoảng 250 triệu tham số và được huấn luyện trên 2,1 nghìn tỷ token, NeoBERT vượt trội BERT_{large} và RoBERTa_{large} trên chuẩn đánh giá MTEB (Massive Text Embedding Benchmark), đồng thời hỗ trợ ngữ cảnh lên tới 4.096 token – gấp 8 lần so với các mô hình tiền nhiệm.

Tuy nhiên, NeoBERT chỉ được huấn luyện trên ngữ liệu tiếng Anh. Đối với tiếng Việt, nhu cầu về một bộ Encoder mạnh mẽ và hiện đại ngày càng cấp thiết khi các ứng dụng NLP trong nước – từ hệ thống tìm kiếm ngữ nghĩa, phân tích cảm xúc, đến các hệ thống hỏi-đáp tự động – đòi hỏi chất lượng biểu diễn ngữ nghĩa ngày càng cao. Các mô hình Encoder tiếng Việt hiện có như PhoBERT [6] và ViDeBERTa [7] tuy hiệu quả nhưng vẫn dựa trên kiến trúc Transformer cũ, bị giới hạn ở độ dài ngữ cảnh 512 token và thiếu đi các tối ưu hóa kiến trúc hiện đại.

Việc huấn luyện lại NeoBERT từ đầu (from scratch) cho tiếng Việt trên quy mô hàng nghìn tỷ token là điều bất khả thi về mặt tài nguyên tính toán đối với hầu hết các nhóm nghiên cứu. Bên cạnh đó, phương pháp tiếp tục tiền huấn luyện (Continued Pre-training) thông thường – tức là khởi tạo ngẫu nhiên lớp nhúng mới rồi huấn luyện trực tiếp – thường dẫn đến hiện tượng *quên lãng thảm họa* (catastrophic forgetting), làm phá vỡ các đặc trưng biểu diễn quý giá mà mô hình đã học từ dữ liệu tiếng Anh.

Xuất phát từ những thách thức trên, đề tài nghiên cứu phương pháp thích nghi ngôn ngữ hiệu quả cho NeoBERT thông qua kỹ thuật Semantic Aware Linear Transfer (SALT) [8]. Thay vì huấn luyện từ đầu, SALT tái sử dụng (recycling) bộ nhúng từ mô hình tiền huấn luyện tiếng Việt chất lượng cao ViDeBERTa, chuyển đổi không gian biểu diễn sang không gian của NeoBERT thông qua các phép hồi quy tuyến tính có nhận thức ngữ nghĩa. Đây là một hướng tiếp cận tiết kiệm tài nguyên, vừa kế thừa tri thức ngôn ngữ học tiếng Việt sẵn có, vừa bảo toàn được sức mạnh kiến

trúc của NeoBERT.

1.2 Mục tiêu nghiên cứu

Đề tài đặt ra các mục tiêu nghiên cứu cụ thể như sau:

1. **Nghiên cứu và nắm vững kiến trúc NeoBERT:** Phân tích chi tiết các cải tiến kiến trúc của NeoBERT so với BERT/RoBERTa truyền thống, bao gồm SwiGLU, RoPE, Pre-RMSNorm và tỷ lệ depth-to-width tối ưu; từ đó xác định những điểm cần điều chỉnh khi thích nghi sang tiếng Việt.
2. **Áp dụng và cải tiến kỹ thuật SALT để chuyển giao không gian biểu diễn:** Nghiên cứu và triển khai thuật toán SALT – bao gồm trích xuất tập neo (anchor extraction) dựa trên độ tương đồng ngữ nghĩa và ánh xạ tuyến tính cục bộ theo phương pháp bình phương tối thiểu – nhằm ánh xạ không gian nhúng từ ViDeBERTa sang không gian véc-tơ của NeoBERT; đồng thời cải tiến cho cặp ngôn ngữ Anh–Việt: mở rộng tập neo bằng cặp dịch và khởi tạo riêng lớp đầu ra tách rời.
3. **Xây dựng mô hình Vietnamese NeoBERT (ViNeoBERT):** Kết hợp lớp nhúng và lớp đầu ra đã được khởi tạo bằng SALT với phần thân NeoBERT gốc, sau đó huấn luyện qua giai đoạn căn chỉnh đóng băng và tiếp tục tiền huấn luyện thích nghi (Continued Pre-training) trên ngữ liệu tiếng Việt quy mô lớn theo lịch tốc độ học Warmup–Stable–Decay.
4. **Đánh giá hiệu quả của phương pháp:** Đánh giá ViNeoBERT trên một bộ tác vụ hiểu ngôn ngữ tiếng Việt đa dạng – trọng tâm là hỏi đáp đọc hiểu (UIT-ViQuAD), cùng các nhóm suy luận, phân loại, gán nhãn chuỗi và tương đồng ngữ nghĩa – so sánh với các mô

hình tiếng Việt và đa ngữ hiện có (PhoBERT, XLM-R); đồng thời so sánh các phương án khởi tạo khác nhau ở cùng ngân sách huấn luyện để định lượng đóng góp của từng thành phần.

5. **Kiểm chứng tính hiệu quả của việc tái sử dụng tri thức:** Thông qua kết quả thực nghiệm, xác minh rằng SALT giúp giảm đáng kể số lượng token huấn luyện cần thiết và ngăn chặn hiện tượng quên lãng thảm họa so với phương pháp khởi tạo ngẫu nhiên.

1.3 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu thực nghiệm trong các giới hạn sau:

Đối tượng nghiên cứu chính bao gồm: (1) kiến trúc NeoBERT với trọng số gốc được công bố công khai; (2) thuật toán SALT với cơ chế trích xuất tập neo và ánh xạ tuyến tính cục bộ; (3) mô hình hiến tặng (donor) ViDeBERTa cung cấp không gian nhúng tiếng Việt cho bước chuyển giao.

Dữ liệu thực nghiệm gồm phần tiếng Việt của kho ngữ liệu web đa ngữ CulturaX cho giai đoạn huấn luyện thích nghi, cùng một bộ tác vụ đánh giá tiếng Việt đa dạng cho bước tinh chỉnh hạ nguồn – từ hỏi đáp đọc hiểu (UIT-ViQuAD), suy luận ngôn ngữ tự nhiên (XNLI, ViANLI), phân loại văn bản (UIT-VSFC, UIT-VSMEC, UIT-ViCTSD) tới gán nhãn từ loại và tương đồng ngữ nghĩa.

Các ràng buộc và giới hạn: Nghiên cứu *không* thực hiện huấn luyện NeoBERT từ đầu do hạn chế tài nguyên tính toán. Phạm vi bài toán chỉ bao gồm các tác vụ NLU và trích xuất đặc trưng (Feature Extraction), không bao gồm các bài toán sinh văn bản tự do của các mô hình Decoder-only. Mô hình kế thừa kiến trúc hỗ trợ ngữ cảnh tới 4.096 token của NeoBERT, tuy nhiên việc kiểm chứng và tinh chỉnh chuyên biệt cho ngữ cảnh dài nằm ngoài phạm vi đề tài và được để lại như hướng phát triển.

1.4 Đóng góp của đề tài

Đề tài đưa ra các đóng góp cụ thể sau:

- **Mô hình Vietnamese NeoBERT (ViNeoBERT):** Cung cấp một bộ Encoder hiện đại khoảng 245 triệu tham số cho tiếng Việt, kế thừa các cải tiến kiến trúc của NeoBERT (RoPE, SwiGLU, Pre-RMSNorm, FlashAttention) cùng trần ngữ cảnh 4.096 token, tương thích với thư viện Hugging Face Transformers và sẵn sàng sử dụng cho các bài toán NLU thực tế.
- **Quy trình thích nghi ngôn ngữ cải tiến:** Đề xuất và kiểm chứng một quy trình chuyển giao ba giai đoạn áp dụng SALT lên kiến trúc NeoBERT – lần đầu tiên cho một kiến trúc Encoder thế hệ mới – với ba cải tiến so với nghiên cứu gốc: (1) mở rộng tập neo bằng cặp dịch Anh–Việt khai thác tự động; (2) khởi tạo riêng lớp đầu ra tách rời, kèm độ chệch theo tần suất từ đơn và hệ số co trọng số để tiên nghiệm dẫn dắt giai đoạn đầu; (3) bổ sung giai đoạn căn chỉnh đóng băng trước khi tiếp tục tiền huấn luyện.
- **Bộ mã nguồn công khai:** Bao gồm thuật toán trích xuất tập neo, các mô-đun chiếu SALT cho lớp nhúng và lớp đầu ra, cùng kịch bản huấn luyện thích nghi theo phiên, phục vụ cho cộng đồng nghiên cứu NLP tiếng Việt.
- **Đóng góp khoa học:** Kết quả thực nghiệm khẳng định tính khả thi của việc tái sử dụng không gian biểu diễn từ các mô hình sẵn có để chuyển giao tri thức cho các ngôn ngữ ít nguồn lực, mở ra một hướng tiếp cận tiết kiệm chi phí cho việc cập nhật và áp dụng các kiến trúc thế hệ mới.

1.5 Cấu trúc đề tài

Phần còn lại của khóa luận được tổ chức như sau:

- **Chương 1 – Tổng quan:** Giới thiệu bối cảnh và sự cần thiết của đề tài, mục tiêu nghiên cứu, phạm vi nghiên cứu và các đóng góp chính.
- **Chương 2 – Cơ sở lý thuyết và các công trình liên quan:** Trình bày kiến trúc Transformer và dòng mô hình Encoder-only, các đặc điểm chính của NeoBERT, cơ sở hình học của không gian biểu diễn, cùng các phương pháp khởi tạo nhúng xuyên ngôn ngữ dẫn tới kỹ thuật SALT.
- **Chương 3 – Phương pháp xây dựng Vietnamese NeoBERT:** Trình bày chi tiết quy trình ba giai đoạn của đề tài: cắt tỉa từ vựng và trích xuất tập neo, phép chiếu SALT cho cả lớp nhúng lẫn lớp đầu ra, giai đoạn căn chỉnh đóng băng và tiếp tục tiền huấn luyện theo lịch WSD.
- **Chương 4 – Thực nghiệm và Đánh giá:** Mô tả dữ liệu, cấu hình huấn luyện, các độ đo và phân tích kết quả thực nghiệm, bao gồm so sánh các phương án khởi tạo và đánh giá trên tác vụ hạ nguồn.
- **Chương 5 – Kết luận và Hướng phát triển:** Tổng kết các kết quả đạt được so với mục tiêu đề ra và đề xuất các hướng phát triển tiếp theo.

Chương 2

Cơ sở lý thuyết và các công trình liên quan

Chương này trình bày nền tảng lý thuyết và các công trình liên quan làm cơ sở cho phương pháp được đề xuất. Trước hết, chúng tôi khảo sát kiến trúc Transformer cùng dòng mô hình Encoder-only đã trở thành chuẩn mực cho các bài toán hiểu ngôn ngữ (Mục 2.1). Tiếp theo, chúng tôi trình bày các đặc điểm chính của NeoBERT – mô hình nền mà đề tài kế thừa – cùng những cải tiến có ảnh hưởng trực tiếp tới hướng chuyển giao tiếng Việt (Mục 2.2). Sau đó, chúng tôi trình bày cơ sở hình học của không gian biểu diễn, bài toán thích nghi ngôn ngữ và các phương pháp khởi tạo nhúng xuyên ngôn ngữ, dẫn tới kỹ thuật Semantic Aware Linear Transfer (SALT) mà đề tài áp dụng (Mục 2.3). Cuối cùng, chương đưa ra một số nhận xét định hướng cho phương pháp được trình bày ở chương tiếp theo.

2.1 Kiến trúc Transformer và mô hình Encoder-only

2.1.1 Cơ chế tự chú ý trong kiến trúc Transformer

Transformer được Vaswani và cộng sự [9] giới thiệu như một kiến trúc xử lý chuỗi không dùng hồi tiếp. Thay vì đọc token tuần tự như RNN/LSTM, Transformer cho phép mỗi vị trí quan sát trực tiếp các vị trí còn lại thông qua cơ chế tự chú ý (self-attention). Đây là lý do kiến trúc này vừa song song hóa tốt trên GPU, vừa học được các phụ thuộc xa trong câu.

Với ma trận trạng thái ẩn X , mô hình tạo ba phép chiếu tuyến tính gồm truy vấn Q , khóa K và giá trị V . Trọng số chú ý được tính bằng tích vô hướng có tỷ lệ:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \quad (2.1)$$

Trong đó, ma trận $QK^\top$ biểu diễn mức liên hệ giữa mọi cặp token. Vì ma trận này có kích thước $n \times n$, chi phí chú ý tăng theo $O(n^2)$ khi độ dài chuỗi tăng. Đây là một lý do các Encoder hiện đại cần kết hợp thêm kỹ thuật tối ưu bộ nhớ như FlashAttention khi mở rộng ngưỡng cảnh lên hàng nghìn token.

Transformer thường dùng tự chú ý đa đầu (Multi-Head Attention) để học nhiều kiểu quan hệ song song. Công thức tổng quát được viết gọn như sau:

$$\begin{aligned} \text{MultiHead}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \\ \text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V). \end{aligned} \quad (2.2)$$


Sau attention, mỗi khối Transformer còn có mạng truyền thẳng theo vị trí, kết nối tắt và lớp chuẩn hóa. Các biến thể hiện đại chủ yếu khác nhau ở cách mã hóa vị trí, loại chuẩn hóa và hàm kích hoạt. Những điểm này sẽ

được dùng để giải thích NeoBERT ở Mục 2.2.

2.1.2 BERT và mô hình hóa ngôn ngữ có mặt nạ

Từ phần encoder của Transformer, Devlin và cộng sự [1] đề xuất BERT (Bidirectional Encoder Representations from Transformers). BERT là mô hình Encoder-only: nó không có bộ giải mã tự hồi quy và không dùng mặt nạ nhân quả, nên mỗi token có thể khai thác đồng thời ngữ cảnh bên trái lẫn bên phải. Đầu ra của BERT là một chuỗi biểu diễn theo ngữ cảnh, phù hợp với các tác vụ hiểu ngôn ngữ như phân loại văn bản, gán nhãn chuỗi, hỏi đáp trích xuất và truy hồi.

Hình 2.1 minh họa luồng xử lý điển hình của một mô hình Encoder-only kiểu BERT.



Hình 2.1: Luồng xử lý của một mô hình Encoder-only kiểu BERT.

Khác với các mô hình ngôn ngữ tự hồi quy chỉ mô hình hóa xác suất từ trái sang phải, BERT được tiền huấn luyện bằng tác vụ mô hình hóa ngôn ngữ có mặt nạ (Masked Language Modeling – MLM). Một số token trong chuỗi bị che hoặc thay đổi, sau đó mô hình dự đoán lại token gốc

dựa trên ngữ cảnh còn lại:

$$\mathcal{L}_{\text{MLM}} = - \sum_{i \in \mathcal{M}} \log P(x_i \mid x_{\setminus \mathcal{M}}) \quad (2.3)$$

Trong đó $\mathcal{M}$ là tập vị trí bị che. Cách huấn luyện này buộc mô hình học biểu diễn hai chiều thay vì chỉ dự đoán token kế tiếp.

Tiếp nối BERT, Liu và cộng sự [2] đề xuất RoBERTa với các cải tiến về quy trình tiền huấn luyện, nổi bật là loại bỏ NSP, dùng mặt nạ động và tăng quy mô dữ liệu. Các mô hình tiếng Việt như PhoBERT [6] và ViDeBERTa [7] cũng kế thừa hướng Encoder-only này. Do đó, khi xây dựng NeoBERT cho tiếng Việt, bài toán trọng tâm không phải thay đổi bản chất Encoder-only, mà là chuyển giao một phần thân Encoder hiện đại sang không gian từ vựng tiếng Việt.

2.1.3 Giới hạn của các mô hình Encoder thế hệ cũ

BERT và RoBERTa vẫn rất quan trọng, nhưng chúng mang nhiều giả định của giai đoạn đầu: ngữ cảnh thường giới hạn ở 512 token, mã hóa vị trí tuyệt đối khó mở rộng, và kiến trúc chưa có các thành phần hiện đại như RoPE, SwiGLU, RMSNorm hay FlashAttention. Khi độ dài chuỗi tăng từ 512 lên 4.096 token, riêng ma trận chú ý đã tăng 64 lần về số phần tử, nên việc mở rộng ngữ cảnh không thể chỉ dựa vào tăng độ dài đầu vào.

Ngoài kiến trúc, quy mô dữ liệu cũng thay đổi mạnh. BERT được huấn luyện trên BooksCorpus và Wikipedia với khoảng 13GB dữ liệu, RoBERTa tăng lên khoảng 160GB, trong khi các Encoder gần đây như NomicBERT [10], ModernBERT [11] và NeoBERT [5] chuyển sang dữ liệu web lớn hơn, ngữ cảnh dài hơn và quy trình huấn luyện tối ưu hơn. Vì vậy, NeoBERT được chọn trong đề tài như một phần thân Encoder hiện đại để thích nghi sang tiếng Việt thay vì tiếp tục dựa trên thế hệ BERT cũ.


2.2 Kiến trúc NeoBERT

2.2.1 Tổng quan

Về bản chất, NeoBERT [5] vẫn là một mô hình thuộc dòng BERT: mã hóa hai chiều toàn chuỗi và được tiền huấn luyện bằng tác vụ MLM. Điều làm nó khác biệt là toàn bộ “phần cứng” bên trong đã được thay mới theo những gì thế hệ mô hình ngôn ngữ lớn gần đây chứng minh là hiệu quả. Mô hình có khoảng 250 triệu tham số, giữ kích thước ẩn 768 như BERT-base nhưng sâu 28 lớp, dùng 12 đầu chú ý (mỗi đầu 64 chiều), hỗ trợ ngữ cảnh 4.096 token, và được tiền huấn luyện trên khoảng 2,1 nghìn tỷ token văn bản web tiếng Anh (RefinedWeb) với tỷ lệ che 20%.

Kiến trúc của mô hình được minh họa trong Hình 2.2. So với BERT, có bốn thay đổi cốt lõi, cũng chính là bốn nội dung sẽ được phân tích trong các mục con tiếp theo: (1) tỷ lệ chiều sâu trên chiều rộng được chọn lại theo phân tích lý thuyết – sâu hơn nhưng không rộng hơn; (2) nhúng vị trí tuyệt đối bị loại bỏ hoàn toàn, thay bằng phép quay RoPE áp dụng trên truy vấn và khóa bên trong từng khối; (3) mạng truyền thẳng dùng cơ chế cổng SwiGLU thay cho GELU; và (4) chuẩn hóa RMSNorm đặt *trước* mỗi tầng con thay vì LayerNorm đặt sau. Ngoài ra, đầu MLM của NeoBERT là một lớp tuyến tính *tách rời* khỏi ma trận nhúng đầu vào – chi tiết tương nhỏ nhưng ảnh hưởng trực tiếp tới thiết kế phương pháp ở Chương 3.

Điểm cần chú ý khi đọc Hình 2.2: khác với sơ đồ BERT quen thuộc, *không có* khối nhúng vị trí cộng vào sau nhúng token – thông tin vị trí được đưa vào bên trong từng khối qua RoPE; chuẩn hóa nằm *trước* tầng tự chú ý và tầng truyền thẳng, còn hai kết nối tắt cộng thẳng vào luồng chính; và sau khối cuối cùng có một lớp RMSNorm khép lại trước khi tín hiệu đi vào các đầu tác vụ. Trong phạm vi đề tài, NeoBERT được xem là *kiến trúc đích*: phần thân Transformer đã được tiền huấn luyện mạnh trên tiếng Anh và sẽ được giữ nguyên, còn lớp nhúng và đầu MLM gắn với từ vựng tiếng Anh là phần phải thay thế. Mỗi cải tiến dưới đây đều để lại



Hình 2.2: Kiến trúc NeoBERT.

một ràng buộc hoặc một thuận lợi cụ thể cho việc thay thế đó.

2.2.2 Tỷ lệ chiều sâu trên chiều rộng tối ưu

Với một ngân sách tham số cố định, câu hỏi đầu tiên của thiết kế kiến trúc là phân bổ tham số vào *chiều sâu* (số lớp L) hay *chiều rộng* (kích thước ẩn d). Levine và cộng sự [12] phân tích lý thuyết khả năng biểu diễn của self-attention và chỉ ra rằng hai đại lượng này phải tăng *đồng bộ*: một mạng quá nông-rộng lãng phí tham số vì các phụ thuộc bậc cao giữa token không thể được hợp thành qua ít bước chú ý, trong khi một mạng quá sâu-hẹp lại bị chiều rộng chặn khả năng lưu trữ thông tin ở mỗi tầng.

Từ đó tồn tại một *vùng sâu–rộng tối ưu* cho từng cỡ mô hình.

Theo phân tích này, các cấu hình BERT truyền thống ($12 \text{ lớp} \times 768$ hoặc $24 \text{ lớp} \times 1.024$) nằm lệch về phía *quá rộng so với độ sâu*. NeoBERT do đó giữ kích thước ẩn 768 như BERT-base nhưng tăng số lớp lên 28 – trở thành một mô hình “sâu mà hẹp” so với BERT-large dù có ít tham số hơn. Đối với đề tài, thiết kế này mang hai ý nghĩa: (1) phần thân đủ sâu để học các biến đổi phi tuyến mạnh – chính là tài sản mà quá trình chuyển giao muốn giữ nguyên; và (2) chiều ẩn 768 trùng với chiều nhúng của mô hình hiến tặng ViDeBERTa-base, giúp phép chiếu không gian nhúng ở Chương 3 không phải xử lý thêm bước đổi chiều.

2.2.3 Mã hóa vị trí quay (Rotary Position Embeddings)

BERT mã hóa vị trí bằng một bảng nhúng vị trí *tuyệt đối* học được, cộng trực tiếp vào nhúng token: $x_i = e_i + p_i$. Cách làm này có hai nhược điểm: bảng p bị giới hạn cứng bởi độ dài huấn luyện (512 với BERT), và điểm chú ý giữa hai token phụ thuộc vào vị trí tuyệt đối của chúng thay vì khoảng cách tương đối – vốn mới là đại lượng mang ngữ nghĩa cú pháp.

NeoBERT thay bằng RoPE [13]: thông tin vị trí được đưa vào bằng cách *quay* véc-tơ truy vấn và khóa trong từng mặt phẳng hai chiều. Cụ thể, véc-tơ $x \in \mathbb{R}^{d_h}$ tại vị trí m được biến đổi như Công thức (2.4):

$$f(x, m) = R_m x, \quad R_m = \text{diag}(R_{m,1}, \dots, R_{m,d_h/2}),$$

$$R_{m,i} = \begin{pmatrix} \cos m\theta_i & -\sin m\theta_i \\ \sin m\theta_i & \cos m\theta_i \end{pmatrix} \quad (2.4)$$

Trong đó:

- R_m là ma trận quay khối-chéo: mỗi cặp chiều $(2i - 1, 2i)$ của x được quay một góc $m\theta_i$;

- $\theta_i = 10.000^{-2(i-1)/d_h}$ là tần số quay của cặp chiều thứ i – các cặp chiều đầu quay nhanh (nhắm quan hệ cục bộ), các cặp sau quay chậm (nhắm quan hệ xa);
- d_h là số chiều của mỗi đầu chú ý (64 với NeoBERT).

Tính chất mâu chốt của phép quay là tích vô hướng giữa truy vấn tại vị trí m và khóa tại vị trí n chỉ phụ thuộc vào *khoảng cách tương đối* $n - m$, như Công thức (2.5):

$$\langle R_m q, R_n k \rangle = q^\top R_{n-m} k \quad (2.5)$$

Nhờ đó RoPE mang lại đồng thời: (1) tính *tương đối* của điểm chú ý; (2) *không thêm tham số* – không còn bảng nhúng vị trí; (3) khả năng *mở rộng ngữ cảnh*: vì không có bảng vị trí cứng, NeoBERT nâng ngữ cảnh từ 1.024 lên 4.096 token chỉ bằng một giai đoạn huấn luyện bổ sung [5], và các kỹ thuật nội suy như YaRN [14] có thể kéo dài thêm nữa; (4) phép quay là biến đổi *trực giao* nên bảo toàn độ lớn véc-tơ – nhất quán với triết lý chuẩn hóa theo độ lớn của RMSNorm. Đối với đề tài, RoPE còn mang một thuận lợi quan trọng: thông tin vị trí *không nằm trong ma trận nhúng*, nên việc thay thế toàn bộ lớp nhúng tiếng Việt không đụng chạm tới cơ chế vị trí của mô hình.

2.2.4 Hàm kích hoạt SwiGLU

Trong BERT, mạng truyền thẳng của mỗi khối là hai phép chiếu với hàm kích hoạt GELU [15] ở giữa, như Công thức (2.6):

$$\text{FFN}_{\text{GELU}}(x) = \text{GELU}(xW_1 + b_1) W_2 + b_2 \quad (2.6)$$

Trong đó $W_1 \in \mathbb{R}^{d \times 4d}$ và $W_2 \in \mathbb{R}^{4d \times d}$ lần lượt mở rộng rồi thu hẹp chiều biểu diễn. Mọi chiều của biểu diễn trung gian đều đi qua cùng một phi tuyến – không có cơ chế nào cho phép mô hình *chọn lọc* thông tin truyền

qua.

NeoBERT thay bằng SwiGLU [16], một biến thể thuộc họ *đơn vị tuyến tính có cổng* (Gated Linear Unit – GLU), như Công thức (2.7):

$$\text{FFN}_{\text{SwiGLU}}(x) = (\text{SiLU}(xW_g) \odot (xW_u)) W_d, \quad \text{SiLU}(z) = z \cdot \sigma(z) \quad (2.7)$$

Trong đó:

- $W_g, W_u \in \mathbb{R}^{d \times d_{ff}}$ là hai phép chiếu song song: nhánh *cổng* (qua phi tuyến SiLU) và nhánh *giá trị* (tuyến tính);
- $\odot$ là phép nhân theo từng phần tử: nhánh cổng quyết định *mỗi chiều* của nhánh giá trị được truyền qua bao nhiêu;
- $W_d \in \mathbb{R}^{d_{ff} \times d}$ chiếu về chiều gốc; cả ba ma trận đều không dùng bias;
- σ là hàm sigmoid.

Vì SwiGLU dùng *ba* ma trận thay vì hai, chiều trung gian được thu lại theo quy tắc $d_{ff} = \frac{2}{3} \cdot 4d$ để giữ nguyên ngân sách tham số [16]. Với NeoBERT: $d = 768$, chiều trung gian danh nghĩa $4d = 3.072$, sau điều chỉnh $\frac{2}{3}$ còn $d_{ff} = 2.048$. Thực nghiệm của Shazeer cho thấy các biến thể GLU cải thiện chất lượng tiền huấn luyện và tinh chỉnh so với GELU/ReLU ở cùng chi phí; cơ chế cổng đặc biệt hữu ích khi kết hợp với thiết kế sâu, nơi khả năng điều tiết luồng thông tin qua từng tầng trở nên quan trọng.

2.2.5 Chuẩn hóa Pre-RMSNorm

Cải tiến thứ tư gồm hai quyết định độc lập nhưng bổ trợ nhau: *loại chuẩn hóa* (RMSNorm thay cho LayerNorm) và *vị trí chuẩn hóa* (trước thay vì sau tầng con).

RMSNorm. LayerNorm truyền thống chuẩn hóa bằng cả trung bình lẫn phương sai: $\text{LN}(x) = \gamma \odot (x - \mu) / \sqrt{\sigma^2 + \epsilon} + \beta$. Zhang và Sennrich [17]

chỉ ra rằng thành phần *tái định tâm* (trừ μ) đóng góp không đáng kể, và đề xuất RMSNorm chỉ chuẩn hóa theo độ lớn, như Công thức (2.8):

$$\text{RMSNorm}(x) = \frac{x}{\text{RMS}(x)} \odot g, \quad \text{RMS}(x) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon} \quad (2.8)$$

Trong đó $g \in \mathbb{R}^d$ là véc-tơ khuếch đại học được và ϵ là hằng số ổn định. RMSNorm bỏ được phép trừ trung bình và tham số dịch β , nhẹ hơn về tính toán mà chất lượng tương đương – do đó trở thành lựa chọn mặc định của các kiến trúc hiện đại.

Pre-norm. Về vị trí, BERT dùng Post-LN (chuẩn hóa *sau* khi cộng kết nối tắt), còn NeoBERT dùng Pre-norm (chuẩn hóa *trước* mỗi tầng con), như Công thức (2.9):

$$\underbrace{x_{l+1} = \text{LN}(x_l + F_l(x_l))}_{\text{Post-LN (BERT)}} \quad \text{so với} \quad \underbrace{x_{l+1} = x_l + F_l(\text{LN}(x_l))}_{\text{Pre-norm (NeoBERT)}} \quad (2.9)$$

Trong đó F_l là tầng con thứ l (chú ý hoặc FFN). Xiong và cộng sự [18] chứng minh rằng với Post-LN, độ lớn gradient tại thời điểm khởi tạo tăng theo độ sâu – buộc phải khởi động tốc độ học rất thận trọng; với Pre-norm, đường kết nối tắt là một “xa lộ” đồng nhất không bị chuẩn hóa cắt ngang, gradient chảy ổn định qua mọi tầng. Với 28 lớp – sâu hơn hẳn thể hệ BERT – lựa chọn Pre-RMSNorm là điều kiện để NeoBERT huấn luyện ổn định.

Đối với đề tài, đặc điểm này để lại một ràng buộc trực tiếp: lớp nhúng tiếng Việt khởi tạo mới sẽ đi qua RMSNorm ngay tầng đầu tiên, mà RMSNorm chuẩn hóa *theo độ lớn* của véc-tơ. Nếu phân phối độ lớn của các hàng nhúng lệch xa so với NeoBERT gốc, tín hiệu đưa vào phần thân sẽ bị sai lệch có hệ thống. Vì vậy, Chương 3 có bước hiệu chỉnh chuẩn cho lớp nhúng sau khi chiếu.

2.2.6 Dữ liệu và chiến lược tiền huấn luyện

NeoBERT được tiền huấn luyện trên RefinedWeb [19] – kho ngữ liệu web quy mô lớn được xây dựng từ CommonCrawl. Mô hình sử dụng mục tiêu MLM với tỷ lệ che 20% [20], tối ưu bằng AdamW [21] với lịch học cosine [22], và dùng FlashAttention [23] để giảm chi phí khi huấn luyện trên chuỗi dài. Các chi tiết huấn luyện đầy đủ không phải trọng tâm của đề tài; điều cần lưu ý là NeoBERT đã học được một phần thân Encoder mạnh, nhưng phần thân này vẫn gắn với từ vựng và dữ liệu tiếng Anh. Đây là lý do đề tài tập trung vào khởi tạo lại không gian nhúng tiếng Việt thay vì huấn luyện lại toàn bộ mô hình từ đầu.

2.3 Chuyển giao không gian nhúng và thích nghi ngôn ngữ

Đối với đề tài, thách thức trung tâm không chỉ là thay bộ từ vựng tiếng Anh của NeoBERT bằng bộ từ vựng tiếng Việt. Lớp nhúng mới còn phải nằm đủ gần không gian biểu diễn mà phần thân Transformer của NeoBERT đã học, để quá trình tiếp tục tiền huấn luyện không bắt đầu từ một trạng thái nhiễu loạn. Vì vậy, mục này gộp hai nền tảng có liên quan chặt chẽ: hình học của không gian biểu diễn và các phương pháp khởi tạo nhúng cho thích nghi ngôn ngữ.

2.3.1 Hình học của không gian biểu diễn

Không gian nhúng của mô hình ngôn ngữ thường có hình học phức tạp hơn một không gian Euclid đều đặn. Ba kết quả có liên quan trực tiếp tới đề tài là: biểu diễn theo ngữ cảnh có tính bất đẳng hướng [24]; các không gian đơn ngữ được huấn luyện độc lập không nhất thiết đẳng cấu [25]; và ma trận nhúng đầu vào không luôn có cùng hình học với ma trận đầu ra khi mô hình không buộc trọng số [26].

Các nhận xét này dẫn tới một lựa chọn thiết kế quan trọng: không nên dùng một ánh xạ tuyến tính toàn cục để chuyển toàn bộ từ vựng tiếng Việt sang NeoBERT. Thay vào đó, đề tài ưu tiên hướng chuyển giao cục bộ theo từng token, trong đó mỗi token mới được ánh xạ dựa trên các token neo gần nó về mặt ngữ nghĩa.

2.3.2 Thích nghi ngôn ngữ và rủi ro quên lãng

NeoBERT được tiền huấn luyện trên tiếng Anh, còn huấn luyện lại một mô hình tương đương cho tiếng Việt từ đầu là không thực tế về chi phí. Hướng khả thi hơn là tiếp tục tiền huấn luyện (Continued Pre-training – CPT) trên ngữ liệu tiếng Việt, tương tự tinh thần thích nghi miền của Gururangan và cộng sự [27].

Rủi ro của CPT là mô hình có thể phải học lại từ tín hiệu đầu vào nhiều nếu lớp nhúng mới được khởi tạo ngẫu nhiên. Các nghiên cứu về tái sử dụng mô hình xuyên ngôn ngữ [28] và phân tích CPT gần đây [29], [30] đều gợi ý rằng điểm khởi đầu của lớp nhúng ảnh hưởng lớn tới ổn định huấn luyện. Vì vậy, đề tài xem khởi tạo nhúng là bước quyết định trước khi CPT.

Một khía cạnh thực hành quan trọng khác của CPT là *lịch tốc độ học*. Lịch cosine truyền thống yêu cầu cam kết trước tổng số bước huấn luyện – điều khó đáp ứng khi CPT diễn ra theo nhiều phiên nối tiếp trên hạ tầng tính toán giới hạn. Lịch Warmup–Stable–Decay (WSD) [31] tách quá trình thành pha khởi động, pha ổn định ở tốc độ học đỉnh và pha làm nguội ngắt, cho phép dừng và tiếp tục linh hoạt; Hägele và cộng sự [32] cho thấy cách tiếp cận này đạt chất lượng tương đương cosine, đồng thời xác định dạng làm nguội $1 - \sqrt{\cdot}$ là hiệu quả nhất ở cùng ngân sách. Ngoài ra, khi huấn luyện tiếp từ một điểm kiểm tra đã làm nguội, tốc độ học cần được khởi động lại thay vì giữ ở mức gần 0 [30]. Các kết quả này là cơ sở cho lịch huấn luyện nhiều phiên được thiết kế ở Chương 3.

2.3.3 Khởi tạo nhúng có thông tin


Các phương pháp như WECHSEL [33], FOCUS [34] và OFA [35] đều theo cùng một hướng: token mới không được xem như ký hiệu rỗng, mà được khởi tạo bằng thông tin ngữ nghĩa từ token hoặc không gian nhúng đã biết. WECHSEL dựa trên nhúng tĩnh song ngữ, FOCUS tận dụng phần từ vựng chồng lấp và Sparsemax [36], còn OFA mở rộng sang thiết lập đa ngôn ngữ lớn hơn.

SALT kế thừa tinh thần này nhưng phù hợp hơn với đề tài vì nó tận dụng trực tiếp một mô hình đã tiền huấn luyện ở ngôn ngữ đích, thay vì chỉ dựa vào nhúng tĩnh hoặc phép trộn từ từ vựng nguồn.

2.3.4 Semantic Aware Linear Transfer (SALT)

SALT của Lee và cộng sự [8] khởi tạo từ vựng đích bằng cách chuyển biểu diễn từ một mô hình tiền huấn luyện ở ngôn ngữ đích sang không gian của mô hình nguồn. Thay vì học một ánh xạ chung cho toàn bộ từ vựng, SALT dùng các token neo trong phần từ vựng chồng lấp để ước lượng ánh xạ cục bộ cho từng token mới. Hình 2.3 minh họa luồng xử lý này: với mỗi token không trùng (ví dụ *pedestrian*), phương pháp tìm các neo gần nghĩa nhất trong phần chồng lấp, xếp các cặp nhúng tương ứng của chúng ở hai không gian thành hai ma trận, học một ánh xạ tuyến tính cục bộ X giữa hai ma trận đó, rồi áp dụng X lên nhúng gốc của token để thu về nhúng trong không gian mô hình nguồn.

Trong nghiên cứu gốc, SALT chủ yếu được kiểm chứng trên các mô hình dạng decoder như Gemma và XGLM. Đề tài kế thừa ý tưởng này nhưng áp dụng vào bối cảnh khác: mô hình nền là NeoBERT Encoder-only, ngôn ngữ đích là tiếng Việt, và lớp đầu ra của NeoBERT cần được xử lý như một ma trận riêng. Các điều chỉnh cụ thể được trình bày trong Chương 3.



Hình 2.3: Sơ đồ tổng quan SALT (Nguồn: Lee và cộng sự [8]).

2.4 Nhận xét định hướng

Từ các cơ sở trên, chúng tôi xem NeoBERT là một nền tảng phù hợp để xây dựng Encoder tiếng Việt hiện đại: phần thân Transformer đã mạnh, hỗ trợ ngữ cảnh dài, nhưng lớp từ vựng và không gian đầu vào vẫn mang thiên lệch tiếng Anh. Vì vậy, hướng tiếp cận hợp lý không phải huấn luyện lại từ đầu, mà là tái sử dụng phần thân NeoBERT và khởi tạo lại lớp nhúng tiếng Việt một cách có thông tin.

Nhận xét quan trọng nhất của chúng tôi là bước khởi tạo không gian nhúng quyết định chất lượng thích nghi ban đầu. Nếu điểm khởi đầu lệch quá xa không gian NeoBERT, quá trình CPT dễ tiêu tốn tài nguyên để sửa lỗi căn chỉnh thay vì học tiếng Việt. Do đó, Chương 3 sẽ tập trung vào một biến thể SALT phù hợp với NeoBERT, bao gồm lựa chọn tập neo, chiếu cục bộ, xử lý lớp đầu ra tách rời và hiệu chỉnh chuẩn của nhúng.

Chương 3

Phương pháp xây dựng Vietnamese NeoBERT

Chương này trình bày chi tiết phương pháp xây dựng mô hình Vietnamese NeoBERT (ViNeoBERT). Trước hết, chúng tôi mô tả tổng quan quy trình ba giai đoạn cùng các mô hình nguồn được sử dụng (Mục 3.1). Tiếp theo, chúng tôi trình bày bước cắt tỉa và đồng bộ từ vựng (Mục 3.2), quá trình trích xuất tập neo – được mở rộng bằng các cặp dịch, một cải tiến của đề tài so với SALT gốc (Mục 3.3), và phép chiếu SALT áp dụng cho cả lớp nhúng đầu vào lẫn lớp đầu ra tách rời của NeoBERT (Mục 3.4). Cuối cùng, chúng tôi mô tả giai đoạn căn chỉnh đóng băng (Mục 3.5) và giai đoạn tiếp tục tiền huấn luyện thích nghi (Mục 3.6). Các giá trị siêu tham số cụ thể được trình bày trong Chương 4.

3.1 Tổng quan phương pháp

3.1.1 Đặt vấn đề

Như đã phân tích trong Chương 2, việc xây dựng một Encoder hiện đại cho tiếng Việt từ NeoBERT đối mặt đồng thời ba thách thức: (1) NeoBERT chỉ được tiền huấn luyện trên ngữ liệu tiếng Anh, nên toàn bộ lớp nhúng của nó phản ánh phân phối từ vựng Anh ngữ; (2) tiếp tục tiền huấn luyện

với một lớp nhúng *khởi tạo ngẫu nhiên* để dẫn tới hiện tượng quên lãng thảm họa; và (3) huấn luyện lại từ đầu trên quy mô hàng nghìn tỷ token là bất khả thi về tài nguyên. Phương pháp của đề tài giải quyết đồng thời ba thách thức này bằng cách *khởi tạo có thông tin* lớp nhúng tiếng Việt thông qua kỹ thuật SALT, sau đó tinh chỉnh mô hình trên ngữ liệu tiếng Việt với chi phí khiêm tốn.

3.1.2 Mô hình nguồn và mô hình hiến tặng

Phương pháp sử dụng hai mô hình tiền huấn luyện:

- **NeoBERT** [5] đóng vai trò *kiến trúc đích*: toàn bộ phần thân Transformer (28 lớp với RoPE, SwiGLU, Pre-RMSNorm) cùng không gian biểu diễn tiếng Anh được giữ nguyên và dùng làm hệ tọa độ đích cho phép chiếu. Một đặc điểm quan trọng là NeoBERT sử dụng *đầu giải mã tách rời* (untied head): lớp đầu ra của tác vụ MLM là một ánh xạ tuyến tính riêng $y = W_{\text{dec}} h + b_{\text{dec}}$ với ma trận trọng số W_{dec} và véc-tơ độ chệch b_{dec} *độc lập* với ma trận nhúng đầu vào E . Do đó, việc thích nghi sang tiếng Việt đòi hỏi khởi tạo *cả hai* ma trận token: ma trận nhúng đầu vào E và ma trận đầu ra W_{dec} .
- **ViDeBERTa** [7] (bản **base**) đóng vai trò *mô hình hiến tặng* (donor): cung cấp không gian nhúng tiếng Việt chất lượng cao làm nguồn để tái sử dụng. ViDeBERTa dùng bộ tách từ SentencePiece theo thuật toán Unigram với kích thước từ vựng lớn (khoảng 128 nghìn token), trong đó mỗi đơn vị từ vựng đi kèm một điểm log-xác suất.


3.1.3 Quy trình ba giai đoạn

Mô hình ViNeoBERT được xây dựng qua ba giai đoạn nối tiếp, minh họa trong Hình 3.1:

1. **Khởi tạo SALT**: xây dựng tập từ vựng tiếng Việt, trích xuất tập neo, rồi chiếu không gian nhúng của ViDeBERTa sang không gian

NeoBERT để khởi tạo cả ma trận nhúng đầu vào lẫn ma trận đầu ra; độ chệch của đầu ra được khởi tạo theo tần suất từ đơn (Mục 3.2–3.4). Giai đoạn này *không* cập nhật phần thân Transformer.

2. **Căn chỉnh đóng băng:** đóng băng toàn bộ phần thân, chỉ huấn luyện ma trận nhúng và ma trận đầu ra trên một lượng nhỏ ngữ liệu tiếng Việt, nhằm để hai ma trận vừa khởi tạo căn chỉnh với nhau và với phần thân (Mục 3.5).
3. **Tiếp tục tiền huấn luyện thích nghi:** tinh chỉnh toàn bộ mô hình trên ngữ liệu tiếng Việt quy mô lớn với mục tiêu MLM theo lịch tốc độ học WSD (Mục 3.6).



Hình 3.1: Quy trình ba giai đoạn xây dựng ViNeoBERT.

3.2 Cắt tỉa và đồng bộ từ vựng

Phép chiếu SALT yêu cầu lớp nhúng nguồn và đích có cùng kích thước từ vựng. Vì từ vựng của ViDeBERTa lớn hơn nhiều so với 30.522 token của NeoBERT, cần một bước *cắt tỉa từ vựng* (vocabulary pruning) để đồng bộ kích thước. Quá trình này giữ lại toàn bộ các token đặc biệt (như [CLS], [SEP], [MASK], [PAD]), sau đó chọn bổ sung các token thông thường có *điểm log-xác suất Unigram cao nhất* – tức các đơn vị từ vựng phổ biến và đáng tin cậy nhất – cho tới khi đạt đúng 30.522 token.

Gọi $\mathcal{V}_s$ là tập token đặc biệt và $\mathcal{V}_n$ là tập token thông thường của ViDeBERTa, với điểm Unigram score($\cdot$). Tập từ vựng tiếng Việt sau cắt

tĩa $\mathcal{V}_t$ được xác định như Công thức (3.1):

$$\mathcal{V}_t = \mathcal{V}_s \cup \text{TopK}(\mathcal{V}_n, \text{score}, K), \quad K = 30,522 - |\mathcal{V}_s| \quad (3.1)$$

Trong đó $\text{TopK}(\mathcal{V}_n, \text{score}, K)$ trả về K token có điểm Unigram cao nhất. Bộ tách từ được ghi lại với ánh xạ chỉ số mới, đồng thời lưu một ánh xạ $\pi : \text{id mới} \rightarrow \text{id gốc}$ trong ViDeBERTa để truy xuất đúng hàng nhúng hiển tĩng ở các bước sau. Phép so khớp chuỗi piece là chính xác vì các đơn vị Unigram là duy nhất trong từ vựng.

3.3 Trích xuất tập neo (anchor set)

3.3.1 Vai trò của tập neo

Tập neo (anchor set) $\mathcal{A}$ là tập các cặp token $(t_{\text{vi}}, t_{\text{neo}})$ có tương ứng ngữ nghĩa rõ ràng giữa từ vựng tiếng Việt (ViDeBERTa đã cắt tĩa) và từ vựng NeoBERT. Mỗi cặp neo cung cấp một điểm *đã biết* của ánh xạ giữa hai không gian nhúng, và giữ vai trò kép trong phép chiếu SALT:

- **Khởi tạo trực tiếp:** bản thân token neo t_{vi} được khởi tạo bằng cách *sao chép nguyên vẹn* hàng nhúng NeoBERT của t_{neo} , bảo đảm độ trung thực tuyệt đối với không gian đích cho các token đã có tương ứng chắc chắn.
- **Tập giám sát:** các cặp $(e_{\text{vi}}, e_{\text{neo}})$ của tập neo đóng vai trò tập giám sát (support set) để *học các ánh xạ tuyến tính cục bộ*, từ đó suy ra nhúng cho những token *không* thuộc tập neo (Mục 3.4).

Do đó, chất lượng và độ phủ của tập neo quyết định trực tiếp chất lượng của phép chiếu SALT.

Trong nghiên cứu gốc, SALT [8] cũng như FOCUS [34] chỉ khai thác các token *trùng lặp bề mặt* (cùng dạng chuỗi) giữa hai từ vựng làm neo. Đối với cặp ngôn ngữ Anh–Việt vốn khác biệt lớn về hình thái, số token

trùng lặp bề mặt là khá hạn chế và độ phủ ngữ nghĩa hẹp. Vì vậy, chúng tôi xây dựng tập neo từ *ba nguồn bổ sung cho nhau*: (1) neo trùng lặp bề mặt *đã xác minh nghĩa*, (2) neo số, và (3) các *cặp dịch* Anh–Việt khai thác tự động. Trong đó, việc mở rộng tập neo bằng cặp dịch là một trong những đóng góp chính của đề tài.

3.3.2 Neo trùng lặp bề mặt và neo số

Neo trùng lặp bề mặt. Theo ý tưởng gốc của SALT, các token có *cùng dạng chuỗi* ở cả hai từ vựng là ứng viên neo tự nhiên, bởi trùng dạng chuỗi thường hàm ý cùng khái niệm – điển hình là từ vay mượn, tên riêng và thuật ngữ khoa học (*internet, vitamin, radio*). Chúng tôi trích các từ *đầy đủ* (word-initial), độ dài đủ lớn, xuất hiện ở cả hai từ vựng và lấy giao làm tập ứng viên.

Tuy nhiên, vì tiếng Việt cũng dùng hệ chữ Latin như tiếng Anh, *cùng dạng chuỗi chưa chắc cùng nghĩa*: nhiều token trùng chuỗi thực chất là hiện tượng *đồng tự khác nghĩa* (false friends). Chẳng hạn “song” trong tiếng Việt nghĩa là *song song* hoặc liên từ *nhưng*, còn “song” trong tiếng Anh nghĩa là *bài hát*; “sang” tiếng Việt nghĩa là *sang trọng*, còn trong tiếng Anh là dạng quá khứ của *sing*. Một cặp neo đồng tự khác nghĩa sẽ tạo ra một điểm ánh xạ sai lệch, kéo phép chiếu đi chệch. Để loại các neo giả này, chúng tôi *xác minh nghĩa* từng ứng viên bằng dịch máy MarianMT Việt–Anh [37]: chỉ giữ lại làm neo khi bản dịch tiếng Anh *trùng khớp chính chuỗi gốc*. Một khái niệm chung thực sự (vay mượn, tên riêng) sẽ dịch về chính nó và được giữ; ngược lại, một token đồng tự khác nghĩa sẽ dịch sang một từ tiếng Anh khác và bị loại bỏ.

Neo số. Song song, chúng tôi giữ trực tiếp các token *số* xuất hiện ở cả hai từ vựng làm neo mà *không* cần xác minh nghĩa, vì ký hiệu số mang tính phổ quát (universal) giữa các ngôn ngữ – “2024” biểu thị cùng một giá trị bất kể ngôn ngữ. Đây là nguồn neo tin cậy tuyệt đối và không phụ thuộc chất lượng dịch máy.

3.3.3 Mở rộng tập neo bằng cặp dịch ba tầng

Hai nguồn trên cho số neo hạn chế và tập trung ở từ vay mượn, tên riêng và số – không bao phủ được phần lớn kho từ vựng thuần Việt. Để *làm giàu và mở rộng độ phủ* của tập neo, chúng tôi bổ sung nguồn neo thứ ba: các cặp dịch Anh–Việt khai thác tự động, trong đó t_{vi} và t_{neo} *khác dạng chuỗi* nhưng tương ứng về nghĩa (ví dụ “nước” $\leftrightarrow$ “water”). Đây là đóng góp chính của đề tài ở bước khởi tạo.

Trước khi khai thác, chúng tôi lọc để chỉ giữ các *từ tiếng Việt đầy đủ và hợp lệ*: loại token chứa ký tự không bản địa (f, j, w, z), giới hạn độ dài, yêu cầu đúng một cụm nguyên âm liền mạch, và tuân thủ các quy tắc chính tả tiếng Việt (chẳng hạn k, gh, ngh chỉ đứng trước $i, e, ê, y$; q luôn đi kèm u). Bộ lọc chính tả này bảo đảm ứng viên là từ tiếng Việt thực thụ, tránh nhiều từ các chuỗi ngoại lai. Trên tập đã lọc, cặp dịch được khai thác theo *ba tầng* bổ sung cho nhau:

- **Tầng 1 – dịch ngược (back-translation)**: mỗi từ tiếng Việt được dịch sang tiếng Anh rồi *dịch ngược* trở lại tiếng Việt; cặp neo chỉ được chấp nhận khi (a) kết quả dịch ngược trùng với từ gốc, (b) bản dịch tiếng Anh là một *từ đơn* khác với từ gốc, và (c) thuộc từ vựng NeoBERT.
- **Tầng 2 – từ ghép**: các từ ghép tiếng Việt (đa âm tiết) chưa được phủ được dịch trực tiếp sang tiếng Anh, giữ lại khi bản dịch là một từ đơn thuộc từ vựng NeoBERT.
- **Tầng 3 – từ đơn còn lại**: các từ đơn chưa được phủ, sau khi loại bỏ một danh sách từ chức năng và từ dễ nhập nhằng (blacklist), được dịch trực tiếp và giữ theo cùng ràng buộc “một từ đơn thuộc từ vựng NeoBERT”; tầng này được giới hạn số lượng để kiểm soát chi phí và chất lượng.

Cơ sở khoa học của phép kiểm tra *dịch ngược* ở Tầng 1 là: một từ đa nghĩa thường không dịch ngược về chính nó một cách ổn định, do bản

dịch trung gian có thể ứng với một nghĩa khác. Vì vậy, ràng buộc dịch ngược trùng khớp tự nhiên loại bỏ phần lớn các từ đa nghĩa, chỉ giữ lại các cặp tương ứng một–một đáng tin cậy. Ràng buộc “bản dịch là một từ đơn thuộc từ vựng NeoBERT” bảo đảm mỗi cặp neo ứng đúng *một* token NeoBERT.

Tập neo cuối cùng là *hợp* của ba nguồn – neo bề mặt đã xác minh, neo số và cặp dịch ba tầng – sau khi loại các cặp trùng lặp, thu được ánh xạ $t_{vi} \mapsto t_{neo}$ dùng thống nhất cho cả lớp nhúng đầu vào lẫn lớp đầu ra ở Mục 3.4. Thực nghiệm khởi tạo cho thấy việc mở rộng tập neo bằng cặp dịch làm tăng đáng kể số lượng neo và độ phủ ngữ nghĩa, qua đó cải thiện chất lượng khởi tạo so với phương án chỉ dùng neo trùng lặp bề mặt như nghiên cứu gốc.

3.4 Phép chiếu SALT cho lớp nhúng và lớp đầu ra

Mục này trình bày phép chiếu SALT – bước khởi tạo cốt lõi. Với mỗi token tiếng Việt *không thuộc* tập neo, chúng tôi xây dựng nhúng của nó bằng một ánh xạ tuyến tính cục bộ học từ các neo lân cận về mặt ngữ nghĩa. Các token neo và token đặc biệt được sao chép trực tiếp hàng tương ứng từ NeoBERT.

3.4.1 Lựa chọn neo bằng Sparsemax

Để xác định các neo liên quan tới một token đích t , chúng tôi đo độ tương đồng ngữ nghĩa trong không gian nhúng từ tĩnh fastText [38], [39]. Gọi $\mathbf{f}_t$ là véc-tơ fastText của t và $\{\mathbf{f}_a\}_{a \in \mathcal{A}}$ là véc-tơ fastText của các neo. Độ tương đồng cosine và trọng số neo được tính như Công thức (3.2):

$$s_{t,a} = \frac{\mathbf{f}_t^\top \mathbf{f}_a}{\|\mathbf{f}_t\| \|\mathbf{f}_a\|}, \quad \mathbf{w}_t = \text{sparsemax}(\mathbf{s}_t), \quad \mathcal{S}_t = \{a : w_{t,a} > 0\} \quad (3.2)$$

Trong đó $\text{sparsemax}(\cdot)$ [36] là phép chiếu lên đơn hình xác suất, cho kết quả *thưa* – chỉ một tập con nhỏ $\mathcal{S}_t$ các neo liên quan nhất nhận trọng số khác 0 (xem Mục 2.3.3). Việc dùng Sparsemax thay cho softmax đặc biệt phù hợp với cấu trúc *bất đẳng hướng* của không gian biểu diễn (Mục 2.3.1): vì trong không gian bất đẳng hướng mọi cặp từ đều có độ tương đồng cosine khá cao, một phân phối dày đặc sẽ pha trộn nhiều, trong khi hỗ trợ thưa giữ lại đúng các neo thực sự gần nghĩa.

3.4.2 Ánh xạ tuyến tính cục bộ theo từng token

Như đã lập luận ở Mục 2.3.1, do hai không gian nhúng là bất đẳng hướng và không đẳng cấu, một ánh xạ tuyến tính toàn cục duy nhất là không đủ. Thay vào đó, SALT học một *ánh xạ tuyến tính riêng cho từng token* từ tập neo được chọn. Gọi $A_t^{\text{src}} \in \mathbb{R}^{k \times h}$ là ma trận xếp chồng các nhúng *hiển tặc* (ViDeBERTa) của $k = |\mathcal{S}_t|$ neo trong $\mathcal{S}_t$, và $A_t^{\text{tgt}} \in \mathbb{R}^{k \times h}$ là ma trận các hàng *đích* (NeoBERT) tương ứng. Khi số neo đủ lớn ($k \geq k_0$), ánh xạ cục bộ X_t và nhúng kết quả $\mathbf{e}_t$ được xác định như Công thức (3.3):

$$X_t = (A_t^{\text{src}})^+ A_t^{\text{tgt}}, \quad \mathbf{e}_t = \mathbf{d}_t X_t \quad (3.3)$$

Trong đó $(\cdot)^+$ là *giả nghịch đảo* Moore–Penrose (nghiệm bình phương tối thiểu chuẩn nhỏ nhất), $\mathbf{d}_t \in \mathbb{R}^h$ là nhúng hiển tặc của token t , và h là số chiều ẩn. Ánh xạ X_t học quan hệ tuyến tính giữa hai không gian *cục bộ quanh token* t , dựa trên các neo gần nghĩa nhất với nó.

Khi số neo không đủ ($k < k_0$), giả nghịch đảo trở nên kém ổn định; khi đó chúng tôi thoái lui về *trung bình có trọng số Sparsemax* của các hàng đích, như Công thức (3.4):

$$\mathbf{e}_t = \frac{\sum_{a \in \mathcal{S}_t} w_{t,a} \mathbf{a}^{\text{tgt}}}{\sum_{a \in \mathcal{S}_t} w_{t,a}} \quad (3.4)$$

Trường hợp token không có véc-tơ fastText hợp lệ, nhúng được khởi tạo

ngẫu nhiên theo phân phối chuẩn khớp với thống kê của NeoBERT.

3.4.3 Áp dụng cho cả lớp nhúng đầu vào và lớp đầu ra

Đây là điểm khác biệt then chốt so với SALT gốc. Vì NeoBERT dùng đầu giải mã *tách rời*, ma trận đầu ra W_{dec} là một ma trận độc lập với hình học riêng – và theo kết quả về hiện tượng thoái hóa biểu diễn (Mục 2.3.1), nó *không* thể được khởi tạo bằng cách sao chép ma trận nhúng. Do đó, chúng tôi áp dụng *cùng một quy trình chiếu SALT theo từng token* cho cả hai ma trận, chỉ khác ở tập hàng đích:

- Với **ma trận nhúng đầu vào** E : hàng đích A_t^{tgt} lấy từ các *hàng nhúng* NeoBERT của các neo.
- Với **ma trận đầu ra** W_{dec} : hàng đích A_t^{tgt} lấy từ các *hàng đầu giải mã* NeoBERT của các neo.

Nhờ vậy, mỗi ma trận được khởi tạo trong đúng không gian của nó, phản ánh trung thực quan hệ ngữ nghĩa mà các neo thiết lập trong từng không gian.

Một lựa chọn thay thế là dựng ma trận đầu ra bằng *một ánh xạ tuyến tính toàn cục* (global map) học chung cho mọi token thay vì ánh xạ cục bộ theo từng token. Chúng tôi chọn phương án chiếu theo từng token cho cả hai ma trận vì lý do hình học đã nêu ở Mục 2.3.1; hiệu quả của lựa chọn này so với ánh xạ toàn cục được đánh giá bằng thực nghiệm trong Chương 4.

3.4.4 Hiệu chỉnh chuẩn của lớp nhúng

Như đã lưu ý ở Mục 2.2.5, NeoBERT dùng Pre-RMSNorm vốn chuẩn hóa theo độ lớn của véc-tơ; do đó độ lớn (norm) của mỗi hàng nhúng ảnh hưởng trực tiếp đến hành vi mô hình. Các nhúng sinh ra từ phép chiếu

SALT thường có độ lớn lệch so với phân phối của NeoBERT. Để tránh gây bất ổn định, chúng tôi hiệu chỉnh độ lớn của mỗi hàng *không phải neo* về độ lớn trung bình của NeoBERT trong khi giữ nguyên hướng, như Công thức (3.5):

$$\mathbf{e}_t \leftarrow \mathbf{e}_t \cdot \frac{\mu_{\text{neo}}}{\|\mathbf{e}_t\|}, \quad \mu_{\text{neo}} = \frac{1}{|\mathcal{V}_{\text{neo}}|} \sum_v \|E_v^{\text{neo}}\| \quad (3.5)$$

Trong đó μ_{neo} là độ lớn trung bình của các hàng nhúng NeoBERT. Các hàng neo và token đặc biệt được giữ nguyên để bảo toàn độ trung thực với NeoBERT.

3.4.5 Khởi tạo độ chệch đầu ra theo tần suất

Lớp đầu ra của NeoBERT có một véc-tơ độ chệch b_{dec} mã hóa *tiên nghiệm tần suất* của token. Các phương pháp khởi tạo trước đây thường để độ chệch này bằng 0, khiến mô hình ở bước đầu phải lãng phí công sức học lại phân phối tần suất biên. Đề tài khởi tạo b_{dec} theo *log-tần-suất từ đơn* (unigram log-frequency) của tiếng Việt, như Công thức (3.6):

$$b_{\text{dec},v} = \log p_v, \quad p_v = \frac{c_v + 1}{\sum_{u \in \mathcal{V}_t} c_u + |\mathcal{V}_t|} \quad (3.6)$$

Trong đó c_v là số lần xuất hiện của token v trong ngữ liệu tiếng Việt (đếm qua bộ tách từ đã cắt tĩa), và phép cộng 1 ở tử số là làm trơn Laplace. Nhờ cách khởi tạo này, ngay ở bước huấn luyện đầu tiên mô hình đã “đoán” đúng phân phối tần suất từ đơn thay vì phân phối đều, giúp hàm mất mát khởi điểm xấp xỉ *entropy từ đơn* của tiếng Việt – thấp hơn đáng kể so với mức ngẫu nhiên $\log |\mathcal{V}_t|$. Cách “khởi tạo sao cho dự đoán ban đầu trùng với phân phối tiên nghiệm” này cùng tinh thần với kỹ thuật khởi tạo độ chệch theo xác suất tiên nghiệm của Lin và cộng sự [40], vốn đã chứng minh hiệu quả ổn định hóa giai đoạn đầu huấn luyện.

3.4.6 Co trọng số đầu ra để tiên nghiệm dẫn dắt giai đoạn đầu

Tiên nghiệm tần suất ở trên chỉ phát huy tác dụng nếu ở bước khởi đầu, thành phần logit do trọng số W_{dec} sinh ra *không lấn át* độ chệch b_{dec} . Ngay sau phép chiếu, các hàng của W_{dec} tuy đã mang cấu trúc ngữ nghĩa từ SALT nhưng chưa từng được huấn luyện cùng phần thân trên tiếng Việt, nên biên độ logit của chúng chưa đáng tin cậy: nếu giữ nguyên, các logit “nhiều” này sẽ nhấn chìm tín hiệu tiên nghiệm. Vì vậy, chúng tôi *co* (scale) trọng số đầu ra bằng một hệ số vô hướng γ như Công thức (3.7):

$$y = \gamma W_{\text{dec}} h + b_{\text{dec}}, \quad \gamma = 0,1 \quad (3.7)$$

Trong đó h là biểu diễn ẩn ở đầu ra của phần thân và γ là hệ số co áp dụng một lần lên W_{dec} tại thời điểm khởi tạo. Cơ sở khoa học của lựa chọn này gồm hai vế:

- **Gần 0 – để tiên nghiệm dẫn dắt:** với γ nhỏ, $\|\gamma W_{\text{dec}} h\|$ trở nên nhỏ so với biên độ của b_{dec} , nên phân phối dự đoán ban đầu do tiên nghiệm tần suất chi phối: mất mát khởi điểm xấp xỉ entropy từ đơn của tiếng Việt, mô hình *bỏ qua* giai đoạn phải học lại phân phối biên và dồn toàn bộ tín hiệu gradient vào việc học ngữ nghĩa.
- **Khác 0 – để giữ ngữ nghĩa:** phép nhân vô hướng bảo toàn *hướng* của các hàng W_{dec} , tức bảo toàn cấu trúc lân cận ngữ nghĩa thu được từ phép chiếu SALT. Trong quá trình huấn luyện, mô hình chỉ cần *khuếch đại dần* biên độ của tín hiệu ngữ nghĩa sẵn có thay vì học lại từ đầu, nhờ đó tốc độ học về sau nhanh hơn so với một lớp đầu ra ngẫu nhiên.

Giả thuyết này được kiểm chứng bằng thực nghiệm trong Chương 4: khi giữ nguyên biên độ ($\gamma = 1$) hoặc chỉ co một nửa ($\gamma = 0,5$), mất mát khởi điểm cao hơn hẳn (tiệm cận mức ngẫu nhiên $\log |\mathcal{V}_t|$) và – quan trọng

hơn – quá trình huấn luyện bị *mắc kẹt* ở mức mất mát cao, không hội tụ về vùng của các phương án tốt; trong khi $\gamma = 0,1$ vừa cho khởi điểm thấp vừa hội tụ nhanh. Do đó $\gamma = 0,1$ được chọn cho toàn bộ quy trình.

3.5 Giai đoạn căn chỉnh đóng băng

Sau bước khởi tạo, ma trận nhúng và ma trận đầu ra của tiếng Việt là *mới* đối với phần thân Transformer đã được huấn luyện trên tiếng Anh. Nếu lập tức tinh chỉnh toàn bộ mô hình, phần thân có thể bị kéo theo để thích ứng với hai ma trận mới còn chưa ổn định, làm gia tăng nguy cơ quên lãng thảm họa (Mục 2.3.2). Vì vậy, chúng tôi chèn một *giai đoạn căn chỉnh đóng băng*: đóng băng toàn bộ phần thân Transformer và chỉ huấn luyện ma trận nhúng đầu vào, ma trận đầu ra và độ chệch của nó trên một lượng nhỏ ngữ liệu tiếng Việt với mục tiêu MLM.

Trực giác của bước này là để hai ma trận vừa khởi tạo *căn chỉnh với nhau và với phần thân cố định* trong không gian biểu diễn trước khi cho phép phần thân thay đổi; nhờ đó điểm khởi đầu của giai đoạn tiếp tục tiền huấn luyện ổn định hơn. Cách làm này nằm trong tinh thần chiến lược *đóng băng rồi thích nghi* của de Vries và Nissim [28], vốn cho thấy việc tách giai đoạn học lớp nhúng khỏi giai đoạn tinh chỉnh toàn bộ giúp tái sử dụng mô hình hiệu quả hơn. Trong thực nghiệm (Chương 4), chúng tôi quan sát thấy giai đoạn này *luôn* cải thiện chất lượng lớp nhúng khởi tạo, do đó được giữ lại trong quy trình.


3.6 Tiếp tục tiền huấn luyện thích nghi

Ở giai đoạn cuối, toàn bộ mô hình được tinh chỉnh trên ngữ liệu tiếng Việt quy mô lớn CulturaX với mục tiêu MLM. Theo Gururangan và cộng sự [27], việc tiếp tục tiền huấn luyện trên dữ liệu miền đích mang lại cải thiện ổn định; ở đây miền đích là toàn bộ ngôn ngữ tiếng Việt.

Lịch tốc độ học WSD. Chúng tôi sử dụng lịch *Warmup–Stable–Decay* (WSD) [31] thay cho lịch cosine cố định, vì WSD cho phép huấn luyện theo nhiều phiên nối tiếp mà không phải cam kết trước tổng số bước. Tốc độ học η theo bước toàn cục s được định nghĩa như Công thức (3.8):

$$\eta(s) = \begin{cases} \eta_{\text{peak}} \cdot \frac{s}{S_w} & \text{nếu } s < S_w \quad (\text{khởi động}) \\ \eta_{\text{peak}} & \text{nếu } S_w \leq s < S_c \quad (\text{ổn định}) \\ \eta_{\text{peak}} \cdot \left(1 - \sqrt{\frac{s-S_c}{S_d}}\right) & \text{nếu } s \geq S_c \quad (\text{làm nguội}) \end{cases} \quad (3.8)$$

Trong đó S_w là mốc kết thúc khởi động, S_c là mốc bắt đầu làm nguội, và S_d là độ dài giai đoạn làm nguội. Pha *ổn định* giữ tốc độ học ở đỉnh trong phần lớn quá trình; pha *làm nguội* dùng dạng $1 - \sqrt{\cdot}$ vốn được Hägele và cộng sự [32] chứng minh là dạng làm nguội cho chất lượng hạ nguồn tốt nhất ở một ngân sách cho trước. Vì lịch WSD được điều khiển theo *bước toàn cục*, một phiên huấn luyện nối tiếp tiếp tục ở pha ổn định mà không bị khởi động lại đột ngột. Hình 3.2 minh họa hình dạng của lịch và ưu điểm cốt lõi của nó: tại bất kỳ điểm nào trong pha ổn định đều có thể “rẽ nhánh” một pha làm nguội ngắn để thu về mô hình hoàn chỉnh, trong khi nhánh chính tiếp tục huấn luyện – điều mà lịch cosine (phải cam kết trước tổng số bước) không làm được.



Hình 3.2: Lịch tốc độ học Warmup–Stable–Decay theo Công thức (3.8).

Khởi động lại tốc độ học. Một điểm kiểm tra đã được làm nguội về tốc độ học gần 0 gần như không thể cập nhật trọng số nếu huấn luyện

tiếp mà không xử lý. Do đó, mỗi khi tiếp tục huấn luyện trên dữ liệu mới (ví dụ một pha làm nguội trên dữ liệu mới), tốc độ học được *khởi động lại* rồi làm nguội lại theo đúng khuyến nghị của Ibrahim và cộng sự [30]. Ngoài ra, bộ tối ưu AdamW được giữ *liên tục* giữa các phiên (mang theo các mô-men bậc nhất và bậc hai) với cặp tham số $\beta = (0,9; 0,95)$ theo công thức gốc của NeoBERT, để bộ tiền điều kiện của bộ tối ưu khớp với chế độ mà phần thân đã được huấn luyện.

3.7 Tổng kết phương pháp

Tóm lại, phương pháp xây dựng ViNeoBERT gồm ba giai đoạn: (1) khởi tạo lớp nhúng và lớp đầu ra bằng phép chiếu SALT theo từng token từ ViDeBERTa sang không gian NeoBERT, với tập neo được làm giàu bằng cặp dịch và độ chệch đầu ra khởi tạo theo tần suất; (2) căn chỉnh đóng băng để hai ma trận mới ổn định cùng phần thân; và (3) tiếp tục tiền huấn luyện thích nghi theo lịch WSD. So với SALT gốc, đề tài có ba khác biệt chính: *mở rộng tập neo bằng cặp dịch* (Mục 3.3), *áp dụng phép chiếu cho cả lớp đầu ra tách rời – kèm khởi tạo độ chệch theo tần suất và co trọng số đầu ra để tiên nghiệm dẫn dắt giai đoạn đầu* (Mục 3.4), và *bổ sung giai đoạn căn chỉnh đóng băng* (Mục 3.5). Hiệu quả của các thành phần này được đánh giá trong Chương 4.

Chương 4

Thực nghiệm và Đánh giá

Chương này trình bày quá trình thực nghiệm nhằm kiểm chứng phương pháp đã đề xuất ở Chương 3. Trước hết, chúng tôi mô tả môi trường, dữ liệu và cấu hình huấn luyện (Mục 4.1–4.2), cùng các độ đo được sử dụng (Mục 4.3). Phần kết quả được tổ chức theo hai câu hỏi nghiên cứu: (1) *phương án khởi tạo nào là tốt nhất?* – trả lời bằng thí nghiệm so sánh các phương án khởi tạo ở cùng ngân sách huấn luyện (Mục 4.4); và (2) *mô hình cuối cùng đạt chất lượng ra sao so với các mô hình hiện có?* – trả lời bằng đường cong chất lượng theo mốc ngân sách và bảng đánh giá đa nhiệm trên mười tác vụ hiểu tiếng Việt (Mục 4.5). Cuối chương là phần thảo luận chung (Mục 4.6).

4.1 Môi trường và dữ liệu thực nghiệm

4.1.1 Môi trường thực nghiệm

Toàn bộ thực nghiệm được thực hiện trên nền tảng Google Colab với GPU NVIDIA A100 (bộ nhớ 80GB), sử dụng PyTorch và hệ sinh thái Hugging Face (`transformers`, `datasets`, `safetensors`). Do một phiên Colab có thời lượng giới hạn, quy trình huấn luyện được thiết kế *theo phiên nối tiếp* như đã mô tả ở Mục 3.6: mỗi phiên xử lý một cửa sổ dữ liệu cố định, lưu điểm kiểm tra cùng trạng thái bộ tối ưu, và phiên kế tiếp

khôi phục đúng trạng thái để tiếp tục – lịch tốc độ học được khóa theo bước toàn cục nên không bị khởi động lại giữa chừng.

4.1.2 Dữ liệu tiền huấn luyện

Giai đoạn căn chỉnh đóng băng và tiếp tục tiền huấn luyện sử dụng phần tiếng Việt của CulturaX [41] – kho ngữ liệu web đa ngữ quy mô lớn đã được làm sạch và khử trùng lặp qua nhiều tầng lọc. Dữ liệu được truyền trực tuyến (streaming) theo từng phiên huấn luyện; tổng ngân sách sử dụng là 5 triệu tài liệu đầu tiên của kho ngữ liệu. Bảng 4.1 tóm tắt thống kê dữ liệu sử dụng trong đề tài.

Bảng 4.1: Thống kê dữ liệu sử dụng trong thực nghiệm.

Dữ liệu	Vai trò	Quy mô sử dụng
CulturaX (tiếng Việt)	Căn chỉnh đóng băng	~20 triệu token
CulturaX (tiếng Việt)	Tiếp tục tiền huấn luyện	5 triệu tài liệu (~5 tỷ token)
UIT-ViQuAD 2.0 (câu hỏi trả lời được)	Tinh chỉnh hạ nguồn (chính)	~18 nghìn câu hỏi huấn luyện
Bộ đánh giá đa nhiệm (Mục 4.1.3)	Tinh chỉnh hạ nguồn	9 tác vụ bổ sung

4.1.3 Dữ liệu đánh giá hạ nguồn

Mô hình được đánh giá trên một bộ tác vụ hiểu ngôn ngữ tiếng Việt đa dạng, phủ các nhóm năng lực khác nhau của một Encoder:

- **Hỏi đáp đọc hiểu:** UIT-ViQuAD 2.0 – bộ dữ liệu hỏi đáp trích xuất xây dựng theo phương pháp luận của SQuAD; mô hình phải xác định đoạn văn bản trả lời trong ngữ cảnh cho trước. Chúng tôi chỉ dùng các câu hỏi *trả lời được* (answerable); tập validation công khai được chia đôi ngẫu nhiên thành tập phát triển và tập kiểm tra. Đây là tác vụ chính vì đủ khó để phân hóa chất lượng biểu diễn giữa các mô hình tốt.

- **Suy luận ngôn ngữ tự nhiên:** XNLI (phần tiếng Việt), ViANLI (bộ NLI đối kháng, khó hơn đáng kể) và QNLI bản tiếng Việt (suy luận câu hỏi–câu).
- **Phân loại văn bản:** UIT-VSFC (phản hồi sinh viên), UIT-VSMEC (cảm xúc đa lớp), UIT-ViCTSD (bình luận độc hại).
- **Gán nhãn chuỗi:** gán nhãn từ loại trên treebank Universal Dependencies Vietnamese-VTB.
- **Tương đồng ngữ nghĩa:** bộ STS bản tiếng Việt, đo tương quan giữa điểm dự đoán và điểm do con người gán.
- **Mô hình hóa ngôn ngữ:** pseudo-perplexity trên một mẫu văn bản tiếng Việt giữ lại, đo trực tiếp chất lượng MLM mà không cần tinh chỉnh.

4.2 Cấu hình huấn luyện

Bảng 4.2 liệt kê siêu tham số của từng giai đoạn trong quy trình. Các giá trị được giữ cố định cho *mọi* phương án khởi tạo trong thí nghiệm so sánh, bảo đảm khác biệt duy nhất giữa các phương án là cách khởi tạo lớp nhúng và lớp đầu ra.

Bảng 4.2: Siêu tham số của các giai đoạn huấn luyện.

Siêu tham số	Căn chỉnh đồng bằng	CPT (WSD)	Tinh chỉnh MRC
Tốc độ học đỉnh	10^{-4}	10^{-4}	2×10^{-5}
Khởi động (warmup)	10% số bước	2% (chặn [20, 500] bước)	không
Độ dài chuỗi tối đa	1.024	1.024	384
Batch size hiệu dụng	$32 \times 4 = 128$	$32 \times 16 = 512$	8
Tỷ lệ che MLM	20%	20%	–
Bộ tối ưu	AdamW, $\beta = (0,9; 0,95)$, weight decay 0,01		AdamW
Lịch tốc độ học	tuyến tính	WSD (làm nguội cosine/ $1 - \sqrt{\cdot}$)	tuyến tính
Số epoch	1 lượt ($\sim 20M$ token)	theo phiên 1M tài liệu	5 (dừng sớm, patience 2)
Số hạt giống (seed)	–	–	5

Đối với bước khởi tạo SALT, các siêu tham số chính gồm: số neo kích hoạt tối đa qua sparsemax là 64, ngưỡng số neo tối thiểu cho ánh xạ cục

bộ $k_0 = 8$, hệ số co trọng số đầu ra $\gamma = 0,1$, và độ chệch đầu ra được ước lượng từ 20.000 tài liệu CulturaX (Mục 3.4). Cột tính chỉnh trong Bảng 4.2 mô tả cấu hình cho tác vụ chính (hỏi đáp đọc hiểu); các tác vụ còn lại trong bộ đánh giá đa nhiệm được tính chỉnh theo quy trình tương tự với siêu tham số phù hợp từng tác vụ, giữ đồng nhất giữa các mô hình so sánh.

4.3 Độ đo đánh giá

Chúng tôi sử dụng các nhóm độ đo sau; trừ khi ghi chú khác, mọi kết quả tính chỉnh được tính trung bình trên 5 lần chạy với hạt giống khác nhau và báo cáo kèm độ lệch chuẩn:

- **Mất mát MLM và perplexity (PPL)(↓)**: mất mát cross-entropy của tác vụ mô hình hóa ngôn ngữ có mặt nạ trên tập giữ lại (held-out) của CulturaX, và perplexity tương ứng $PPL = \exp(\mathcal{L}_{MLM})$ – dùng để theo dõi quá trình huấn luyện.
- **Pseudo-perplexity (PPPL)(↓)** [42]: với mô hình MLM, xác suất một câu được ước lượng bằng cách che lần lượt từng token và lấy tích các xác suất khôi phục; PPPL là nghịch đảo trung bình hình học của các xác suất này. Do các mô hình dùng bộ từ vựng khác nhau, PPPL chỉ mang tính tham khảo tương đối giữa các mô hình.
- **Exact Match (EM)(↑) và F1(↑)** cho hỏi đáp đọc hiểu: EM là tỷ lệ câu trả lời trùng khớp hoàn toàn với đáp án chuẩn sau chuẩn hóa; F1 đo mức chồng lấp ở cấp token giữa câu trả lời dự đoán và đáp án chuẩn.
- **Accuracy, F1-macro, F1-weighted (↑)** cho các tác vụ phân loại và suy luận: F1-macro lấy trung bình đều giữa các lớp (phù hợp dữ liệu lệch lớp), F1-weighted lấy trung bình theo tỷ trọng lớp.

- **Hệ số tương quan Spearman** ($\uparrow$) cho tác vụ tương đồng ngữ nghĩa: đo tương quan hạng giữa điểm dự đoán và điểm con người gán.

4.4 So sánh các phương án khởi tạo

4.4.1 Các phương án so sánh


Để định lượng đóng góp của từng thành phần khởi tạo, chúng tôi huấn luyện CPT tám phương án khởi tạo khác nhau ở *cùng ngân sách dữ liệu và cùng cấu hình*, mô tả trong Bảng 4.3. Các phương án ngẫu nhiên đóng vai trò đối chứng; các phương án còn lại lần lượt thay đổi một thành phần của phương pháp để cô lập tác dụng của nó.

Bảng 4.3: Các phương án khởi tạo trong thí nghiệm so sánh.

Phương án	Mô tả
freezealigned	Khởi tạo SALT theo token cho cả hai ma trận + căn chỉnh đóng băng (quy trình đầy đủ của đề tài).
decpertoken	Như trên nhưng <i>không</i> có giai đoạn căn chỉnh đóng băng.
globalmap	Nhúng SALT theo token; lớp đầu ra dựng bằng <i>một ánh xạ tuyến tính toàn cục</i> từ không gian nhúng sang không gian đầu ra, $\gamma = 0,1$.
decscale05	Như <code>globalmap</code> nhưng $\gamma = 0,5$.
decscale10	Như <code>globalmap</code> nhưng $\gamma = 1,0$ (không có).
dectied	Lớp đầu ra sao chép ma trận nhúng tại khởi tạo (mô phỏng buộc trọng số).
random-meannorm	Đối chứng: nhúng ngẫu nhiên có hiệu chỉnh độ lớn theo NeoBERT – khác SALT <i>duy nhất</i> ở chỗ không mang ngữ nghĩa.
naive-random	Đối chứng ngây thơ: nhúng ngẫu nhiên $\mathcal{N}(0; 0,02)$, độ chệch đầu ra bằng 0 (cách làm mặc định khi thay từ vựng).

4.4.2 Kết quả mô hình hóa ngôn ngữ

Hình 4.1 trình bày mất mát đánh giá của tám phương án theo ngân sách huấn luyện. Có thể rút ra ba quan sát chính:



Hình 4.1: Mất mát MLM trên tập đánh giá của tám phương án khởi tạo.

Thứ nhất, khởi tạo SALT mang lại lợi thế ngay từ bước 0 và duy trì suốt quá trình. Các phương án SALT với $\gamma = 0,1$ khởi đầu ở mức mất mát xấp xỉ 7,2 – đúng vùng entropy từ đơn của tiếng Việt như phân tích ở Mục 3.4.5 – và hội tụ về khoảng 3,0–3,1. Trong khi đó, đối chứng **naive-random** khởi đầu ở mức trên 16 (cao hơn cả mức ngẫu nhiên $\log |\mathcal{V}_t| \approx 10,3$ do độ lệch bằng 0 kết hợp trọng số chưa chuẩn hóa) và chỉ hội tụ về khoảng 5,5. Đối chứng **random-meannorm** – vốn chỉ khác SALT ở việc thiếu tín hiệu ngữ nghĩa – hội tụ về khoảng 3,5, vẫn kém nhóm SALT một khoảng cách rõ; điều này cho thấy phần lợi thế còn lại đến từ chính *ngữ nghĩa* được chuyển giao, không chỉ từ việc chuẩn hóa độ lớn.

Thứ hai, giả thuyết về hệ số co trọng số đầu ra được xác nhận. Đúng như phân tích ở Mục 3.4.6: phương án không co ($\gamma = 1,0$) khởi đầu ở mức xấp xỉ 10,1 – gần mức ngẫu nhiên, tức các logit nhiều đã nhấn chìm hoàn toàn tiên nghiệm tần suất; phương án co một nửa ($\gamma = 0,5$) khởi đầu


ở 8,1. Quan trọng hơn, cả hai đều *mắc kẹt* quanh mức 6,6–6,9 cho tới hết ngân sách – thấp hơn cả đối chứng ngẫu nhiên ngây thơ – cho thấy khởi đầu sai lệch ở lớp đầu ra không chỉ làm chậm mà còn đẩy quá trình tối ưu vào vùng khó phục hồi. Phương án buộc trọng số **dectied** khởi đầu tệ nhất (trên 21), phù hợp với phân tích về khác biệt hình học giữa hai ma trận ở Mục 2.3.1.

Thứ ba, căn chỉnh đóng băng cải thiện nhất quán. Đường cong **freezealigned** nằm dưới **decptoken** ở mọi mốc ngân sách – giai đoạn căn chỉnh giúp mô hình khởi đầu CPT từ trạng thái ổn định hơn và duy trì lợi thế đó trong suốt quá trình.

4.4.3 Ảnh hưởng tới tác vụ hạ nguồn

Chất lượng mô hình hóa ngôn ngữ không phải lúc nào cũng đồng nghĩa với chất lượng hạ nguồn. Vì vậy, sau cùng một ngân sách CPT 100 nghìn tài liệu, mỗi phương án được tính chỉnh trên UIT-ViQuAD với cấu hình đồng nhất; mỗi cột trong Hình 4.2 là trung bình qua các hạt giống với thanh lỗi là độ lệch chuẩn, đường đứt nét đỏ đánh dấu đối chứng ngẫu nhiên tốt nhất. Kết quả cho thấy thứ hạng hạ nguồn nhất quán với thứ hạng mô hình hóa ngôn ngữ.

Ba phương án SALT dẫn đầu với F1 khoảng 66–68, vượt xa đối chứng ngẫu nhiên tốt nhất (khoảng 56). Thứ tự trong nhóm SALT – **freezealigned** > **decptoken** > **globalmap** – ủng hộ cả hai lựa chọn thiết kế của đề tài: chiếu *theo từng token* cho lớp đầu ra tốt hơn ánh xạ toàn cục, và giai đoạn căn chỉnh đóng băng mang lại lợi ích bổ sung. Đáng chú ý, hai phương án γ lớn tụt xuống *dưới* cả đối chứng ngẫu nhiên (khoảng 42–47), khẳng định rằng khởi tạo đầu ra sai lệch gây tổn hại lâu dài chứ không chỉ làm chậm khởi đầu. Dựa trên kết quả này, phương án **freezealigned** được chọn làm mô hình chính để huấn luyện với toàn bộ ngân sách.



Hình 4.2: Điểm F1 trên UIT-ViQuAD của tám phương án khởi tạo sau 100 nghìn tài liệu CPT.


4.5 Kết quả của mô hình cuối

Mô hình chính được tiếp tục tiền huấn luyện tới 5 triệu tài liệu CulturaX theo lịch WSD. Chúng tôi phân tích kết quả theo hai góc nhìn: diễn tiến chất lượng theo ngân sách huấn luyện (Mục 4.5.1) và bức tranh đa nhiệm tại mốc cuối (Mục 4.5.2). Đối sánh là hai họ mô hình phổ biến nhất với tiếng Việt: PhoBERT [6] – đơn ngữ, huấn luyện trên dữ liệu đã tách từ – và XLM-R [43] – đa ngữ.

4.5.1 Diễn tiến theo ngân sách huấn luyện

Tại mỗi mốc ngân sách, điểm kiểm tra được làm nguội rồi tinh chỉnh trên UIT-ViQuAD; Hình 4.3 thể hiện kết quả (trong hình, các mốc của ViNeoBERT được ký hiệu “SALT (ours)”). Ba điểm đáng chú ý: *thứ nhất*, chỉ sau 0,5 triệu tài liệu ($\sim 10\%$ ngân sách), ViNeoBERT đã vượt XLM-R-base – phản ánh trực tiếp giá trị của khởi tạo có thông tin: mô hình

không phải học lại tiếng Việt từ đầu. *Thứ hai*, đường cong có đoạn chững quanh vùng 1–4 triệu tài liệu trước khi bật lên ở mốc 5 triệu – mốc được áp dụng pha làm nguội trên dữ liệu mới như mô tả ở Mục 3.6 – cho thấy còn dư địa cải thiện nếu tăng ngân sách. *Thứ ba*, khoảng cách với các mô hình lớn hơn (đường đứt nét phía trên) thu hẹp dần theo ngân sách.



Hình 4.3: Điểm F1 trên UIT-ViQuAD theo ngân sách tiếp tục tiền huấn luyện.

4.5.2 Đánh giá đa nhiệm tại mốc 5 triệu tài liệu

Để có bức tranh toàn diện hơn một tác vụ đơn lẻ, mô hình cuối được đánh giá trên mười tác vụ thuộc sáu nhóm năng lực (Mục 4.1.3), so với hai mô hình cùng hạng tham số. Kết quả trình bày trong Bảng 4.4.

Từ Bảng 4.4, chúng tôi rút ra ba nhận xét:

- **Bức tranh chung:** ViNeoBERT dẫn đầu 4/10 tác vụ – đọc hiểu (hơn XLM-R-base 4,1 điểm F1), pseudo-perplexity, gán nhãn từ loại

Bảng 4.4: Kết quả đánh giá đa nhiệm tại mốc 5 triệu tài liệu (trung bình $\pm$ độ lệch chuẩn qua 5 lần chạy; kết quả tốt nhất mỗi hàng in đậm; ô “–” chưa được đo).

Tác vụ	Độ đo	PhoBERT-base-v2	XLM-R-base	ViNeoBERT
MRC-ViQuAD	F1 ($\uparrow$)	–	$72,10 \pm 1,98$	$76,24 \pm 2,08$
Pseudo-perplexity	PPPL ($\downarrow$)	6,53	3,38	2,85
QNLI (vi)	Accuracy ($\uparrow$)	$0,8895 \pm 0,0056$	$0,8594 \pm 0,0032$	$0,8791 \pm 0,0033$
STS (vi)	Spearman ($\uparrow$)	$0,8560 \pm 0,0038$	$0,8233 \pm 0,0068$	$0,8392 \pm 0,0041$
UD-VTB (POS)	F1-macro ($\uparrow$)	$0,7801 \pm 0,0046$	$0,7827 \pm 0,0014$	$0,8089 \pm 0,0047$
UIT-VSFC	F1-weighted ($\uparrow$)	$0,9353 \pm 0,0037$	$0,9288 \pm 0,0025$	$0,9261 \pm 0,0013$
UIT-VSMEC	F1-macro ($\uparrow$)	$0,6398 \pm 0,0164$	$0,6177 \pm 0,0113$	$0,6163 \pm 0,0199$
UIT-ViCTSD	F1-macro ($\uparrow$)	$0,7450 \pm 0,0040$	$0,7072 \pm 0,0245$	$0,7315 \pm 0,0158$
ViANLI	F1-macro ($\uparrow$)	$0,4508 \pm 0,0104$	$0,3634 \pm 0,0555$	$0,4239 \pm 0,0127$
XNLI (vi)	F1-macro ($\uparrow$)	$0,7700 \pm 0,0071$	$0,7556 \pm 0,0060$	$0,7706 \pm 0,0045$

và XNLI – và đạt kết quả bằng hoặc cao hơn XLM-R-base ở 8/10 tác vụ. PhoBERT-base-v2 giữ ưu thế ở nhóm phân loại câu ngắn (VSFC, VSMEC, ViCTSD) và ViANLI; đáng chú ý, ở VSFC khoảng cách chỉ dưới 1 điểm – vùng đã bão hòa, mọi mô hình tốt đều đạt trên 0,92.

- **Hiệu quả dữ liệu – điểm mấu chốt:** lượng tiếng Việt mà ViNeoBERT tiếp xúc chỉ khoảng 5 tỷ token (một lượt qua 5 triệu tài liệu). Để so sánh: PhoBERT được huấn luyện 40 epoch trên kho 20GB văn bản (1GB Wikipedia + 19GB tin tức) [6], tức lượng token đã duyệt lớn hơn ViNeoBERT khoảng 30 lần; bản base-v2 còn được huấn luyện bổ sung trên 120GB văn bản OSCAR-2301. XLM-R được huấn luyện trên 2,5TB dữ liệu CC-100, trong đó riêng phần tiếng Việt đã khoảng 137GB [43] – gấp nhiều lần toàn bộ ngân sách của đề tài. Việc một mô hình chỉ “đọc” lượng tiếng Việt ít hơn một đến hai bậc như vậy vẫn cạnh tranh sòng phẳng, thậm chí dẫn đầu ở các tác vụ khó, chứng minh trực tiếp luận điểm của đề tài: khởi tạo có thông tin cho phép kế thừa năng lực của phần thân đã huấn luyện thay vì học lại từ đầu.
- **Phân bố điểm mạnh:** các tác vụ ViNeoBERT dẫn đầu (đọc hiểu span dài, gán nhãn từ loại, mô hình hóa ngôn ngữ) đều gắn với chất

lượng *biểu diễn theo ngữ cảnh ở cấp token* – đúng phần năng lực được kế thừa từ phần thân NeoBERT; trong khi các tác vụ phân loại câu ngắn dựa nhiều vào từ vựng bề mặt, nơi PhoBERT hưởng lợi từ tách từ tiếng Việt và 40 epoch dữ liệu trong miền.

4.6 Thảo luận

Kết quả thực nghiệm khép vòng với các mục tiêu đặt ra ở Chương 1. Thí nghiệm so sánh khởi tạo (Mục 4.4) chứng minh từng lựa chọn thiết kế của phương pháp đều đóng góp dương: khởi tạo SALT vượt mọi đối chứng ngẫu nhiên ở cả mô hình hóa ngôn ngữ lẫn hạ nguồn; chiếu theo từng token cho lớp đầu ra tốt hơn ánh xạ toàn cục; hệ số co $\gamma = 0,1$ là bắt buộc – các giá trị lớn hơn gây tổn hại không phục hồi; và căn chỉnh đóng bằng cải thiện nhất quán. Đánh giá theo ngân sách (Mục 4.5) cho thấy phương pháp đạt hiệu quả dữ liệu cao: vượt XLM-R-base chỉ với 0,5 triệu tài liệu, và ở mốc 5 triệu tài liệu dẫn đầu 4/10 tác vụ trong bảng đánh giá đa nhiệm dù lượng tiếng Việt tiếp xúc ít hơn các mô hình đối sánh một đến hai bậc.

Chúng tôi cũng lưu ý hai giới hạn của thực nghiệm. Thứ nhất, bảng đánh giá đa nhiệm hiện so sánh với hai mô hình cùng hạng **base**; các biến thể **large** mới xuất hiện ở đường cong theo ngân sách và sẽ được bổ sung vào bảng đa nhiệm. Bên cạnh đó, một số tác vụ phân loại (như UIT-VSFC) đã bão hòa nên ít phân hóa giữa các mô hình tốt. Thứ hai, ngân sách 5 triệu tài liệu vẫn nhỏ so với dữ liệu tiền huấn luyện của các mô hình đối sánh; xu hướng của đường cong học cho thấy khoảng cách còn lại nhiều khả năng tiếp tục thu hẹp khi tăng ngân sách. Các giới hạn này được thảo luận tiếp ở Chương 5.

Chương 5

Kết luận và Hướng phát triển

5.1 Kết luận

Khóa luận đã nghiên cứu và xây dựng thành công **ViNeoBERT** – một mô hình Encoder hiện đại cho tiếng Việt – bằng cách thích nghi NeoBERT thông qua kỹ thuật SALT được cải tiến, thay vì huấn luyện lại từ đầu. Đối chiếu với các mục tiêu đặt ra ở Chương 1, đề tài đã đạt được các kết quả sau:

- **Về nghiên cứu kiến trúc:** Chúng tôi đã phân tích các cải tiến kiến trúc của NeoBERT (RoPE, SwiGLU, Pre-RMSNorm, tỷ lệ sâu–hẹp tối ưu) và xác định đúng hai điểm mấu chốt ảnh hưởng tới việc chuyển giao: chuẩn hóa Pre-RMSNorm nhảy với độ lớn của nhúng – dẫn tới bước hiệu chỉnh chuẩn – và đầu giải mã tách rời đòi hỏi khởi tạo riêng cho lớp đầu ra (Chương 2, 3).
- **Về phương pháp chuyển giao:** Chúng tôi đã triển khai thuật toán SALT và cải tiến nó cho cặp ngôn ngữ Anh–Việt với ba đóng góp: (1) mở rộng tập neo bằng cặp dịch khai thác tự động, kèm cơ chế lọc từ đồng tự khác nghĩa đặc thù cho ngôn ngữ hệ chữ Latin; (2) áp dụng phép chiếu theo từng token cho cả lớp đầu ra tách rời, kết hợp khởi tạo độ chệch theo tần suất từ đơn và hệ số co trọng số $\gamma = 0,1$;

(3) bổ sung giai đoạn căn chỉnh đóng băng trước khi tiếp tục tiền huấn luyện (Chương 3).

- **Về kiểm chứng thực nghiệm:** Thí nghiệm so sánh tám phương án khởi tạo ở cùng ngân sách (Mục 4.4) xác nhận từng lựa chọn thiết kế: nhóm khởi tạo SALT vượt mọi đối chứng ngẫu nhiên ở cả mô hình hóa ngôn ngữ lẫn tác vụ hạ nguồn (F1 khoảng 66–68 so với 56 của đối chứng tốt nhất); chiếu theo từng token tốt hơn ánh xạ toàn cục; hệ số co $\gamma = 0,1$ là cần thiết – không co hoặc co không đủ khiến huấn luyện mắc kẹt và kết quả hạ nguồn tụt dưới cả đối chứng ngẫu nhiên; và căn chỉnh đóng băng cải thiện nhất quán.
- **Về hiệu quả của mô hình:** Sau 5 triệu tài liệu CulturaX, Vi-NeoBERT dẫn đầu 4/10 tác vụ trong bảng đánh giá đa nhiệm – đọc hiểu UIT-ViQuAD (76,24 F1, hơn XLM-R-base 4,1 điểm), pseudo-perplexity, gán nhãn từ loại và XNLI – và đạt kết quả bằng hoặc cao hơn XLM-R-base ở 8/10 tác vụ (Mục 4.5). Đáng nói nhất, lượng tiếng Việt mô hình tiếp xúc chỉ khoảng 5 tỷ token – ít hơn một đến hai bậc so với PhoBERT (40 epoch trên 20GB, bản v2 thêm 120GB OSCAR) hay XLM-R (~137GB tiếng Việt trong CC-100). Kết quả này xác nhận giả thuyết trung tâm của đề tài: *tái sử dụng không gian biểu diễn sẵn có là con đường tiết kiệm để đưa các kiến trúc Encoder thế hệ mới đến với tiếng Việt*.

Bên cạnh mô hình, đề tài đóng góp một quy trình ba giai đoạn có thể tái lập – khởi tạo SALT cải tiến, căn chỉnh đóng băng, tiếp tục tiền huấn luyện theo lịch WSD với khả năng huấn luyện theo phiên – cùng bộ mã nguồn công khai đi kèm.

5.2 Hạn chế của đề tài

Trong khuôn khổ thời gian và tài nguyên của một khóa luận, đề tài còn các hạn chế sau:

- **Ngân sách huấn luyện:** 5 triệu tài liệu vẫn nhỏ so với dữ liệu tiền huấn luyện của các mô hình đối sánh; ViNeoBERT chưa vượt PhoBERT-base-v2 ở nhóm tác vụ phân loại câu ngắn, dù xu hướng đường cong học cho thấy khoảng cách có thể tiếp tục thu hẹp khi tăng ngân sách.
- **Phạm vi đánh giá:** bảng đánh giá đa nhiệm hiện so sánh với hai mô hình cùng hạng **base**; các biến thể **large** và nhóm tác vụ truy hồi thông tin chưa được đưa vào so sánh đầy đủ.
- **Ngữ cảnh dài:** mô hình kế thừa trần ngữ cảnh 4.096 token của NeoBERT về mặt kiến trúc, nhưng quá trình tiếp tục tiền huấn luyện dùng chuỗi tối đa 1.024 token và đề tài chưa kiểm chứng chất lượng ở ngữ cảnh dài.
- **Bộ tách từ:** từ vựng kế thừa từ ViDeBERTa hoạt động ở mức âm tiết; ảnh hưởng của việc không tách từ (so với PhoBERT dùng dữ liệu đã tách từ) chưa được phân tích riêng.

5.3 Hướng phát triển

Từ các kết quả và hạn chế trên, chúng tôi đề xuất bốn hướng phát triển:

1. **Mở rộng ngân sách tiếp tục tiền huấn luyện:** tăng số tài liệu CulturaX vượt mốc 5 triệu và khai thác thêm các pha làm nguội trên dữ liệu mới – vốn đã cho thấy hiệu quả bật điểm ở mốc cuối – nhằm vượt các mô hình họ PhoBERT trên các tác vụ hạ nguồn.

2. **Kiểm chứng và khai thác ngữ cảnh dài:** huấn luyện bổ sung ở độ dài 4.096 token và đánh giá trên các tác vụ đòi hỏi ngữ cảnh dài (hỏi đáp đa đoạn, truy hồi tài liệu); khi cần vượt trần hiện tại, các kỹ thuật nội suy RoPE như YaRN [14] là ứng viên tự nhiên.
3. **Mở rộng bộ đánh giá:** bổ sung các tác vụ suy luận ngôn ngữ tự nhiên, gán nhãn chuỗi và truy hồi ngữ nghĩa cho tiếng Việt, nhằm đánh giá toàn diện hơn chất lượng biểu diễn của mô hình ở vai trò một Encoder đa dụng.
4. **Tổng quát hóa quy trình:** áp dụng quy trình ba giai đoạn của đề tài cho các ngôn ngữ ít tài nguyên khác hoặc các kiến trúc nền khác, qua đó kiểm chứng tính tổng quát của các cải tiến (tập neo theo cặp dịch, khởi tạo lớp đầu ra tách rời, căn chỉnh đóng băng) ngoài phạm vi cặp Anh–Việt và NeoBERT.

Tài liệu tham khảo

Tiếng Anh

- [1] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K., “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of NAACL-HLT*, 2019, pp. 4171–4186.
- [2] Liu, Y., Ott, M., Goyal, N., *et al.*, “RoBERTa: A robustly optimized BERT pretraining approach,” *arXiv preprint arXiv:1907.11692*, 2019.
- [3] Dubey, A. *et al.*, “The Llama 3 herd of models,” *arXiv preprint arXiv:2407.21783*, 2024.
- [4] DeepSeek-AI, “DeepSeek-V3 technical report,” *arXiv preprint arXiv:2412.1943*, 2024.
- [5] Le Breton, L., Fournier, Q., El Mezouar, M., Morris, J. X., and Chandar, S., “NeoBERT: A next-generation BERT,” *arXiv preprint arXiv:2502.19587*, 2025.
- [6] Nguyen, D. Q. and Nguyen, A. T., “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 1037–1042.
- [7] Tran, C. D., Pham, N. H., Nguyen, A., Hy, T. S., and Vu, T., “ViDeBERTa: A powerful pre-trained language model for Vietnamese,” in *Findings of the Association for Computational Linguistics: EACL 2023*, 2023, pp. 1071–1078.

- [8] Lee, S., Hong, S., Moon, H., and Lim, H., “Semantic aware linear transfer by recycling pre-trained language models for cross-lingual transfer,” *Findings of the Association for Computational Linguistics: ACL 2025*, 2025, arXiv:2505.10945.
- [9] Vaswani, A., Shazeer, N., Parmar, N., *et al.*, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [10] Nussbaum, Z., Morris, J. X., Duderstadt, B., and Mulyar, A., “Nomic embed: Training a reproducible long context text embedder,” *arXiv preprint arXiv:2402.01613*, 2024.
- [11] Warner, B., Chaffin, A., Clavié, B., *et al.*, “Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference,” *arXiv preprint arXiv:2412.13663*, 2024.
- [12] Levine, Y., Wies, N., Sharir, O., Bata, H., and Shashua, A., “The depth-to-width interplay in self-attention,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:2006.12467, 2020.
- [13] Su, J., Lu, Y., Pan, S., Murtadha, A., Wen, B., and Liu, Y., “RoFormer: Enhanced transformer with rotary position embedding,” *Neurocomputing*, vol. 568, 2024, arXiv:2104.09864.
- [14] Peng, B., Quesnelle, J., Fan, H., and Shippole, E., “YaRN: Efficient context window extension of large language models,” *arXiv preprint arXiv:2309.00071*, 2023.
- [15] Hendrycks, D. and Gimpel, K., “Gaussian error linear units (GELUs),” *arXiv preprint arXiv:1606.08415*, 2016.
- [16] Shazeer, N., “GLU variants improve transformer,” *arXiv preprint arXiv:2002.05202*, 2020.

- [17] Zhang, B. and Sennrich, R., “Root mean square layer normalization,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:1910.07467, 2019.
- [18] Xiong, R., Yang, Y., He, D., *et al.*, “On layer normalization in the transformer architecture,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.
- [19] Penedo, G., Malartic, Q., Hesslow, D., *et al.*, “The RefinedWeb dataset for Falcon LLM: Outperforming curated corpora with web data, and web data only,” *arXiv preprint arXiv:2306.01116*, 2023.
- [20] Wettig, A., Gao, T., Zhong, Z., and Chen, D., “Should you mask 15% in masked language modeling?” In *Proceedings of the 17th Conference of the European Chapter of the ACL (EACL)*, 2023.
- [21] Loshchilov, I. and Hutter, F., “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, arXiv:1711.05101, 2019.
- [22] Loshchilov, I. and Hutter, F., “SGDR: Stochastic gradient descent with warm restarts,” in *International Conference on Learning Representations (ICLR)*, arXiv:1608.03983, 2017.
- [23] Dao, T., “FlashAttention-2: Faster attention with better parallelism and work partitioning,” in *International Conference on Learning Representations (ICLR)*, arXiv:2307.08691, 2024.
- [24] Ethayarajh, K., “How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019.
- [25] Ormazabal, A., Artetxe, M., Labaka, G., Soroa, A., and Agirre, E., “Analyzing the limitations of cross-lingual word embedding mappings,” in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2019, pp. 4990–4995.

- [26] Gao, J., He, D., Tan, X., Qin, T., Wang, L., and Liu, T.-Y., “Representation degeneration problem in training natural language generation models,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [27] Gururangan, S., Marasović, A., Swayamdipta, S., *et al.*, “Don’t stop pretraining: Adapt language models to domains and tasks,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.
- [28] Vries, W. de and Nissim, M., “As good as new. how to successfully recycle English GPT-2 to make models for other languages,” in *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, 2021.
- [29] Elhady, A., Agirre, E., and Artetxe, M., “Emergent abilities of large language models under continued pretraining for language adaptation,” in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, arXiv:2506.00288, 2025.
- [30] Ibrahim, A., Thérien, B., Gupta, K., *et al.*, “Simple and scalable strategies to continually pre-train large language models,” *Transactions on Machine Learning Research (TMLR)*, 2024, arXiv:2403.08763.
- [31] Hu, S., Tu, Y., Han, X., He, C., Cui, G., Long, X., *et al.*, “MiniCPM: Unveiling the potential of small language models with scalable training strategies,” *arXiv preprint arXiv:2404.06395*, 2024.
- [32] Hägele, A., Bakouch, E., Kosson, A., Ben Allal, L., Von Werra, L., and Jaggi, M., “Scaling laws and compute-optimal training beyond fixed training durations,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:2405.18392, 2024.
- [33] Minixhofer, B., Paischer, F., and Reikhsaz, N., “WECHSEL: Effective initialization of subword embeddings for cross-lingual transfer

- of monolingual language models,” in *Proceedings of NAACL-HLT*, 2022, pp. 3992–4006.
- [34] Dobler, K. and Melo, G. de, “FOCUS: Effective embedding initialization for monolingual specialization of multilingual models,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023.
 - [35] Liu, Y., Lin, P., Wang, M., and Schütze, H., “OFA: A framework of initializing unseen subword embeddings for efficient large-scale multilingual continued pretraining,” in *Findings of the Association for Computational Linguistics: NAACL 2024*, 2024.
 - [36] Martins, A. F. T. and Astudillo, R. F., “From softmax to sparsemax: A sparse model of attention and multi-label classification,” in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 2016.
 - [37] Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., *et al.*, “Marian: Fast neural machine translation in C++,” in *Proceedings of ACL 2018, System Demonstrations*, 2018.
 - [38] Bojanowski, P., Grave, E., Joulin, A., and Mikolov, T., “Enriching word vectors with subword information,” *Transactions of the Association for Computational Linguistics (TACL)*, vol. 5, pp. 135–146, 2017.
 - [39] Grave, E., Bojanowski, P., Gupta, P., Joulin, A., and Mikolov, T., “Learning word vectors for 157 languages,” in *Proceedings of the 11th International Conference on Language Resources and Evaluation (LREC)*, 2018.
 - [40] Lin, T.-Y., Goyal, P., Girshick, R., He, K., and Dollár, P., “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

- [41] Nguyen, T., Nguyen, C. V., Lai, V. D., *et al.*, “CulturaX: A cleaned, enormous, and multilingual dataset for large language models in 167 languages,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING)*, arXiv:2309.09400, 2024, pp. 4226–4237.
- [42] Salazar, J., Liang, D., Nguyen, T. Q., and Kirchhoff, K., “Masked language model scoring,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020, pp. 2699–2712.
- [43] Conneau, A., Khandelwal, K., Goyal, N., *et al.*, “Unsupervised cross-lingual representation learning at scale,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020, pp. 8440–8451.

Phụ lục A

Bộ lọc chính tả tiếng Việt cho khai thác neo

Phụ lục này mô tả chi tiết bộ lọc chính tả được dùng ở Mục 3.3.3 để bảo đảm các ứng viên khai thác cặp dịch là từ tiếng Việt hợp lệ. Một token chỉ được giữ lại khi vượt qua *toàn bộ* các quy tắc sau:

1. **Ký tự bản địa:** loại mọi token chứa f, j, w, z – các ký tự không thuộc bảng chữ cái tiếng Việt.
2. **Độ dài:** tối đa 7 ký tự cho một âm tiết.
3. **Một cụm nguyên âm:** token phải chứa *đúng một* cụm nguyên âm liền mạch (kể cả nguyên âm mang dấu thanh).
4. **Quy tắc phụ âm đầu:**
 - k, gh, ngh bắt buộc đứng trước các nguyên âm hàng trước $i, e, ê, y$;
 - ngược lại, c, g, ng không được đứng trước các nguyên âm này;
 - q luôn đi kèm u ;
 - p không đứng một mình làm phụ âm đầu (loại các dạng vay mượn như $pô, pin$).

5. **Tổ hợp nguyên âm ngoại lai:** loại các chuỗi không xuất hiện trong âm tiết tiếng Việt như *ea, ee, oo, ii, uu, ion, eon*.
6. **Nguyên âm chưa trọn vẹn:** các nguyên âm như *ă, â* (và các tổ hợp *iê, uô, ươ*) không được đứng cuối âm tiết mà phải có phụ âm cuối đi kèm (loại các mảnh từ như *nhấ, tầ, nghiê*).
7. **Phụ âm đầu/cuối hợp lệ:** phụ âm đầu phải thuộc tập $\{\emptyset, b, c, ch, d, đ, g, gh, gi, h, k, kh, l, m, n, ng, ngh, nh, ph, q, qu, r, s, t, th, tr, v, x\}$; phụ âm cuối phải thuộc tập $\{\emptyset, c, ch, m, n, ng, nh, p, t\}$.
8. **Quy tắc thanh-phụ âm cuối:** âm tiết kết thúc bằng *c, ch, p, t* bắt buộc mang thanh sắc hoặc thanh nặng (loại các dạng sai như *sec, nhac, mít*).
9. **Danh sách loại trừ:** một danh sách nhỏ các chuỗi thỏa cấu trúc âm tiết nhưng là nhiễu trong thực tế (ví dụ mảnh phiên âm, từ cổ ít dùng) được loại thủ công.

Ngoài ra, ở Tầng 3 của quá trình khai thác cặp dịch (Mục 3.3.3), một danh sách chặn (blacklist) gồm các từ chức năng và từ dễ nhập nhằng của tiếng Việt (*các, những, được, để, thế, cái, ...*) được áp dụng trước khi dịch, nhằm tránh tạo ra các cặp neo kém tin cậy từ những từ có phân bố ngữ nghĩa rộng.