

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Bùi Khắc Trung - Trần Anh Tú

NGHIÊN CỨU PHƯƠNG PHÁP XÂY
DỰNG NEOBERT CHO TIẾNG VIỆT

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Bùi Khắc Trung - Trần Anh Tú
22120396 - 22120400

NGHIÊN CỨU PHƯƠNG PHÁP XÂY
DỰNG NEOBERT CHO TIẾNG VIỆT

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

TS. Nguyễn Hồng Bửu Long - TS. Lương An Vinh

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Tôi xin cam đoan đây là công trình nghiên cứu của tôi dưới sự hướng dẫn của ...

Thuyết minh chỉnh sửa đề tài

Bản thuyết minh chỉnh sửa đề tài (nếu có thay đổi tên đề tài, nội dung báo cáo, ... trong cuốn báo cáo sau bảo vệ)

Nhận xét hướng dẫn

Bản nhận xét của giảng viên hướng dẫn (có chữ ký) do giáo vụ cung cấp.

Nhận xét phản biện

Bản nhận xét của giảng viên phản biện (có chữ ký) do giáo vụ cung cấp.

Lời cảm ơn

Tôi xin chân thành cảm ơn ...

Đề cương chi tiết

Bản đề cương đã thực hiện và nộp cho giáo vụ trước đó *(phải có chữ ký của giảng viên hướng dẫn)*.

Mục lục

Lời cam đoan	i
Thuyết minh chỉnh sửa đề tài	ii
Nhận xét của GV hướng dẫn	iii
Nhận xét của GV phản biện	iv
Lời cảm ơn	v
Đề cương	vi
Mục lục	vii
Danh sách hình	x
Danh sách bảng	xi
Tóm tắt	xi
1 Giới thiệu	1
1.1 Bối cảnh và sự cần thiết của đề tài	1
1.2 Mục tiêu nghiên cứu	3
1.3 Phạm vi nghiên cứu	4
1.4 Đóng góp của đề tài	4

2	Cơ sở lý thuyết và các công trình liên quan	6
2.1	Kiến trúc Transformer và mô hình Encoder-only	7
2.1.1	Cơ chế tự chú ý trong kiến trúc Transformer	7
2.1.2	BERT và mô hình hóa ngôn ngữ có mặt nạ	8
2.1.3	Giới hạn của các mô hình Encoder thế hệ cũ	9
2.2	Kiến trúc NeoBERT	10
2.2.1	Tổng quan	10
2.2.2	Tỷ lệ chiều sâu trên chiều rộng tối ưu	11
2.2.3	Mã hóa vị trí quay (Rotary Position Embeddings)	12
2.2.4	Hàm kích hoạt SwiGLU	12
2.2.5	Chuẩn hóa Pre-RMSNorm	13
2.2.6	Dữ liệu và chiến lược tiền huấn luyện	14
2.3	Hình học của không gian biểu diễn từ	15
2.4	Thích nghi ngôn ngữ và khởi tạo không gian nhúng	16
2.4.1	Thích nghi ngôn ngữ và hiện tượng quên lãng thảm họa	16
2.4.2	Các phương pháp khởi tạo không gian nhúng	17
2.4.3	Kỹ thuật Semantic Aware Linear Transfer (SALT)	18
2.5	Nhận xét và định hướng	19
3	Phương pháp xây dựng Vietnamese NeoBERT	20
3.1	Tổng quan phương pháp	20
3.1.1	Đặt vấn đề	20
3.1.2	Mô hình nguồn và mô hình hiển tặng	21
3.1.3	Quy trình ba giai đoạn	21
3.2	Cắt tỉa và đồng bộ từ vựng	22
3.3	Trích xuất tập neo theo cặp dịch	23
3.3.1	Vai trò của tập neo	23
3.3.2	Lọc từ đầy đủ và hợp lệ	24
3.3.3	Khai thác cặp dịch ba tầng	24
3.4	Phép chiếu SALT cho lớp nhúng và lớp đầu ra	25

3.4.1	Lựa chọn neo bằng Sparsemax	25
3.4.2	Ánh xạ tuyến tính cục bộ theo từng token	26
3.4.3	Áp dụng cho cả lớp nhúng đầu vào và lớp đầu ra	26
3.4.4	Hiệu chỉnh chuẩn của lớp nhúng	27
3.4.5	Khởi tạo độ chệch đầu ra theo tần suất	27
3.5	Giai đoạn căn chỉnh đóng băng	28
3.6	Tiếp tục tiền huấn luyện thích nghi	29
3.7	Tổng kết phương pháp	30
4	Thực nghiệm và Đánh giá	31
4.1	Môi trường và dữ liệu thực nghiệm	31
4.2	Thiết lập các tham số huấn luyện (Hyperparameters)	31
4.3	Kịch bản đánh giá	31
4.4	Kết quả và Thảo luận	32
5	Kết luận và Hướng phát triển	33
5.1	Kết luận	33
5.2	Hạn chế của đề tài	33
5.3	Hướng phát triển trong tương lai	33
	Danh mục công trình của tác giả	34
	Tài liệu tham khảo	35
	Phụ lục	39
	A Phụ lục A	40

Danh sách hình

2.1	Cấu trúc một khối Encoder của NeoBERT theo lối chuẩn hóa trước (Pre-RMSNorm): tín hiệu lần lượt qua RMSNorm, khối tự chú ý đa đầu có áp dụng RoPE trên truy vấn và khóa, rồi tới mạng truyền thẳng SwiGLU. Hai đường bên cạnh biểu diễn các kết nối tắt (residual connection).	11
3.1	Quy trình ba giai đoạn xây dựng ViNeoBERT: khởi tạo lớp nhúng và lớp đầu ra bằng SALT từ ViDeBERTa sang không gian NeoBERT, căn chỉnh đóng băng phần thân, rồi tiếp tục tiền huấn luyện thích nghi trên ngữ liệu tiếng Việt.	22

Danh sách bảng

Tóm tắt

Nghiên cứu tập trung giải quyết bài toán xây dựng mô hình ngôn ngữ NeoBERT cho tiếng Việt bằng cách tái sử dụng không gian biểu diễn (embedding) từ mô hình tiền huấn luyện ViDeBERTa thông qua phương pháp Semantic Aware Linear Transfer (SALT). Thay vì huấn luyện lại từ đầu với chi phí khổng lồ, kỹ thuật SALT giúp thiết lập các đường hồi quy tuyến tính dựa trên tập từ vựng chung để ánh xạ đặc trưng ngữ nghĩa sang không gian của NeoBERT. Phương pháp này giúp mô hình thích nghi nhanh với tiếng Việt, xử lý ngữ cảnh dài (4096 tokens) mà không gặp phải hiện tượng quên lãng thảm họa (catastrophic forgetting).

Chương 1

Giới thiệu

1.1 Bối cảnh và sự cần thiết của đề tài

Trong lịch sử phát triển của lĩnh vực Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing – NLP), các mô hình dạng Encoder-only như BERT [1] và RoBERTa [2] từng đóng vai trò nền tảng không thể thiếu cho các bài toán hiểu ngôn ngữ (Natural Language Understanding – NLU) như phân loại văn bản, nhận dạng thực thể có tên, suy luận ngôn ngữ tự nhiên và trả lời câu hỏi. Nhờ cơ chế mã hóa hai chiều (bidirectional encoding), các mô hình này có khả năng nắm bắt ngữ cảnh từ cả hai phía của một chuỗi đầu vào, tạo ra biểu diễn ngữ nghĩa phong phú và được ứng dụng rộng rãi trong thực tế.

Tuy nhiên, trong khi các dòng mô hình Decoder-only – hay còn gọi là các Mô hình Ngôn ngữ Lớn (Large Language Models – LLMs) như LLaMA [3] và DeepSeek [4] – liên tục tiến hóa với quy mô dữ liệu và những đột phá về kiến trúc, các bộ Encoder-only lại gần như không có sự cải thiện đáng kể trong suốt nhiều năm qua. BERT và RoBERTa vẫn tiếp tục được sử dụng rộng rãi dù kiến thức của chúng ngày càng trở nên lỗi thời, đặc biệt trong các ứng dụng đòi hỏi hiểu ngữ cảnh dài hoặc tốc độ suy luận cao.

Sự ra đời của NeoBERT [5] vào năm 2025 đã thu hẹp đáng kể khoảng cách này. NeoBERT tái định nghĩa khả năng của các mô hình Encoder

bằng cách tích hợp các cải tiến kiến trúc tiên tiến nhất từ thế giới LLM: hàm kích hoạt SwiGLU, cơ chế mã hóa vị trí tương đối Rotary Position Embeddings (RoPE), chuẩn hóa Pre-RMSNorm, và tỷ lệ chiều sâu trên chiều rộng tối ưu (28 lớp ẩn với kích thước ẩn 768). Với 250 triệu tham số và được huấn luyện trên 2,1 nghìn tỷ tokens, NeoBERT vượt trội BERT_{large} và RoBERTa_{large} trên chuẩn đánh giá MTEB (Massive Text Embedding Benchmark), đồng thời hỗ trợ ngữ cảnh lên tới 4.096 tokens – gấp 8 lần so với các mô hình tiền nhiệm.

Tuy nhiên, NeoBERT chỉ được huấn luyện trên ngữ liệu tiếng Anh. Đối với tiếng Việt, nhu cầu về một bộ Encoder mạnh mẽ và hiện đại ngày càng cấp thiết khi các ứng dụng NLP trong nước – từ hệ thống tìm kiếm ngữ nghĩa, phân tích cảm xúc, đến các hệ thống hỏi-đáp tự động – đòi hỏi chất lượng biểu diễn ngữ nghĩa ngày càng cao. Các mô hình Encoder tiếng Việt hiện có như PhoBERT [6] và ViDeBERTa [7] tuy hiệu quả nhưng vẫn dựa trên kiến trúc Transformer cũ, bị giới hạn ở độ dài ngữ cảnh 512 tokens và thiếu đi các tối ưu hóa kiến trúc hiện đại.

Việc huấn luyện lại NeoBERT từ đầu (from scratch) cho tiếng Việt trên quy mô hàng nghìn tỷ tokens là điều bất khả thi về mặt tài nguyên tính toán đối với hầu hết các nhóm nghiên cứu. Bên cạnh đó, phương pháp tiếp tục tiền huấn luyện (Continued Pre-training) thông thường – tức là khởi tạo ngẫu nhiên lớp nhúng mới rồi huấn luyện trực tiếp – thường dẫn đến hiện tượng *quên lãng thảm họa* (catastrophic forgetting), làm phá vỡ các đặc trưng biểu diễn quý giá mà mô hình đã học từ dữ liệu tiếng Anh.

Xuất phát từ những thách thức trên, đề tài nghiên cứu phương pháp thích nghi ngôn ngữ hiệu quả cho NeoBERT thông qua kỹ thuật Semantic Aware Linear Transfer (SALT) [8]. Thay vì huấn luyện từ đầu, SALT tái sử dụng (recycling) bộ nhúng từ mô hình tiền huấn luyện tiếng Việt chất lượng cao ViDeBERTa, chuyển đổi không gian biểu diễn sang không gian của NeoBERT thông qua các phép hồi quy tuyến tính có nhận thức ngữ nghĩa. Đây là một hướng tiếp cận tiết kiệm tài nguyên, vừa kế thừa tri thức ngôn ngữ học tiếng Việt sẵn có, vừa bảo toàn được sức mạnh kiến

trúc của NeoBERT.

1.2 Mục tiêu nghiên cứu

Đề tài đặt ra các mục tiêu nghiên cứu cụ thể như sau:

1. **Nghiên cứu và nắm vững kiến trúc NeoBERT:** Phân tích chi tiết các cải tiến kiến trúc của NeoBERT so với BERT/RoBERTa truyền thống, bao gồm SwiGLU, RoPE, Pre-RMSNorm và tỷ lệ depth-to-width tối ưu; từ đó xác định những điểm cần điều chỉnh khi thích nghi sang tiếng Việt.
2. **Áp dụng kỹ thuật SALT để chuyển giao không gian biểu diễn:** Nghiên cứu và triển khai thuật toán SALT – bao gồm trích xuất tập neo (anchor extraction) dựa trên độ tương đồng ngữ nghĩa và phép biến đổi Bình phương Tối thiểu (Linear Least Squares) – nhằm ánh xạ không gian nhúng từ ViDeBERTa sang không gian vector của NeoBERT.
3. **Xây dựng mô hình Vietnamese NeoBERT:** Kết hợp lớp nhúng đã được khởi tạo bằng SALT với kiến trúc NeoBERT gốc, sau đó tiến hành huấn luyện thích nghi có chọn lọc (Language Adaptive Continual Pre-training) trên ngữ liệu tiếng Việt, hướng đến khả năng xử lý ngữ cảnh dài tới 4.096 tokens.
4. **Đánh giá hiệu quả của phương pháp:** So sánh toàn diện Vietnamese NeoBERT với các baseline hiện có (PhoBERT, ViDeBERTa) trên các bộ benchmark tiêu chuẩn cho tiếng Việt (VLSP, MTEB tiếng Việt) về cả chất lượng biểu diễn ngữ nghĩa, tốc độ hội tụ trong huấn luyện và chi phí tính toán.
5. **Kiểm chứng tính hiệu quả của việc tái sử dụng tri thức:** Thông qua kết quả thực nghiệm, xác minh rằng SALT giúp giảm

đáng kể số lượng token huấn luyện cần thiết và ngăn chặn hiện tượng quên lãng thảm họa so với phương pháp khởi tạo ngẫu nhiên.

1.3 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu thực nghiệm trong các giới hạn sau:

Đối tượng nghiên cứu chính bao gồm: (1) kiến trúc NeoBERT với trọng số gốc được công bố công khai; (2) thuật toán SALT với cơ chế trích xuất tập neo và hồi quy tuyến tính; (3) mô hình nguồn ViDeBERTa làm cơ sở chuyển giao không gian nhúng.

Dữ liệu thực nghiệm gồm ngữ liệu tiếng Việt quy mô lớn được trích xuất từ Wikipedia và các trang tin tức tổng hợp cho giai đoạn huấn luyện thích nghi, cùng các bộ benchmark VLSP và MTEB tiếng Việt cho đánh giá.

Các ràng buộc và giới hạn: Nghiên cứu *không* thực hiện huấn luyện NeoBERT từ đầu do hạn chế tài nguyên tính toán. Phạm vi bài toán chỉ bao gồm các tác vụ NLU và trích xuất đặc trưng (Feature Extraction), không bao gồm các bài toán sinh văn bản tự do của các mô hình Decoder-only.

1.4 Đóng góp của đề tài

Đề tài đưa ra các đóng góp cụ thể sau:

- **Mô hình Vietnamese NeoBERT:** Cung cấp một bộ Encoder tiên tiến 250M tham số cho tiếng Việt, hỗ trợ ngữ cảnh dài 4.096 tokens, tương thích với thư viện Hugging Face Transformers và sẵn sàng sử dụng cho các bài toán NLU thực tế.
- **Quy trình thích nghi ngôn ngữ tối ưu:** Đề xuất và kiểm chứng một pipeline chuyển giao ngôn ngữ hiệu quả áp dụng SALT lên kiến

trúc NeoBERT – lần đầu tiên được thực hiện cho một kiến trúc Encoder thể hệ mới hỗ trợ ngữ cảnh dài và FlashAttention-2, thay vì các kiến trúc BERT cũ như trong nghiên cứu gốc của SALT.

- **Bộ mã nguồn công khai:** Bao gồm thuật toán trích xuất tập neo, module hồi quy tuyến tính SALT và kịch bản huấn luyện thích nghi, phục vụ cho cộng đồng nghiên cứu NLP tiếng Việt.
- **Đóng góp khoa học:** Kết quả thực nghiệm khẳng định tính khả thi của việc linh hoạt tái sử dụng không gian biểu diễn từ các mô hình ngôn ngữ lớn sẵn có để chuyển giao tri thức cho các ngôn ngữ ít nguồn lực, mở ra một hướng tiếp cận tiết kiệm chi phí cho việc cập nhật và áp dụng các kiến trúc thể hệ mới.

Chương 2

Cơ sở lý thuyết và các công trình liên quan

Chương này trình bày nền tảng lý thuyết và các công trình liên quan làm cơ sở cho phương pháp được đề xuất. Trước hết, chúng tôi khảo sát kiến trúc Transformer cùng dòng mô hình Encoder-only đã trở thành chuẩn mực cho các bài toán hiểu ngôn ngữ (Mục 2.1). Tiếp theo, chúng tôi phân tích chi tiết kiến trúc NeoBERT – mô hình nền mà đề tài kế thừa – cùng các cải tiến hiện đại và cơ sở khoa học của chúng (Mục 2.2). Sau đó, chúng tôi trình bày các kết quả về hình học của không gian biểu diễn từ, vốn là nền tảng lý thuyết giải thích vì sao việc chuyển giao không gian nhúng cần được thực hiện một cách *cục bộ* (Mục 2.3). Cuối cùng, chúng tôi khảo sát bài toán thích nghi ngôn ngữ cùng các phương pháp khởi tạo không gian nhúng xuyên ngôn ngữ, dẫn tới kỹ thuật Semantic Aware Linear Transfer (SALT) mà đề tài áp dụng (Mục 2.4).

2.1 Kiến trúc Transformer và mô hình Encoder-only

2.1.1 Cơ chế tự chú ý trong kiến trúc Transformer

Kiến trúc Transformer, được Vaswani và cộng sự [9] giới thiệu năm 2017, đã tạo ra một bước ngoặt trong lĩnh vực Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing – NLP). Khác với các mạng hồi tiếp (Recurrent Neural Network – RNN) vốn xử lý chuỗi một cách tuần tự, Transformer loại bỏ hoàn toàn tính hồi tiếp và chỉ dựa trên *cơ chế tự chú ý* (self-attention) để mô hình hóa quan hệ giữa các vị trí trong chuỗi. Nhờ đó, mọi vị trí được xử lý song song và mọi cặp token được liên kết bởi một đường đi có độ dài không đổi, khắc phục được hạn chế về phụ thuộc xa của RNN.

Thành phần cốt lõi của Transformer là cơ chế *tự chú ý theo tích vô hướng có tỷ lệ* (Scaled Dot-Product Attention). Mỗi token đầu vào được chiếu thành ba véc-tơ: truy vấn (query), khóa (key) và giá trị (value); tập hợp các véc-tơ này theo toàn chuỗi tạo thành ba ma trận Q , K và V . Trọng số chú ý được tính như Công thức (2.1):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \quad (2.1)$$

Trong đó:

- $Q \in \mathbb{R}^{n \times d_k}$, $K \in \mathbb{R}^{n \times d_k}$, $V \in \mathbb{R}^{n \times d_v}$: lần lượt là ma trận truy vấn, khóa và giá trị của chuỗi có độ dài n ;
- d_k : số chiều của véc-tơ khóa, đóng vai trò hệ số chuẩn hóa;
- $\frac{1}{\sqrt{d_k}}$: hệ số tỷ lệ nhằm tránh tích vô hướng $QK^\top$ đạt giá trị quá lớn, vốn đẩy hàm softmax vào vùng bão hòa và làm gradient triệt tiêu.

Để mô hình có thể đồng thời chú ý đến thông tin từ nhiều không gian biểu diễn con khác nhau, Transformer mở rộng cơ chế trên thành *tự chú*

ý đa đầu (Multi-Head Attention). Cụ thể, Q , K , V được chiếu song song thành h tập con, mỗi tập được tính chú ý độc lập rồi nối lại như Công thức (2.2):

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \quad \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2.2)$$

Trong đó W_i^Q, W_i^K, W_i^V và W^O là các ma trận trọng số có thể học được. Cơ chế đa đầu cho phép mỗi đầu chú ý (attention head) học một loại quan hệ ngữ nghĩa hoặc cú pháp riêng biệt, từ đó tạo ra biểu diễn phong phú hơn [9].

Sau khối tự chú ý, mỗi vị trí được biến đổi độc lập bởi một mạng truyền thẳng theo vị trí (Position-wise Feed-Forward Network) gồm hai phép chiếu tuyến tính với một hàm phi tuyến ở giữa, như Công thức (2.3):

$$\text{FFN}(x) = \max(0, xW_1 + b_1) W_2 + b_2 \quad (2.3)$$

Mỗi khối Transformer kết hợp hai thành phần trên với *kết nối tắt* (residual connection) và *chuẩn hóa lớp* (Layer Normalization), giúp ổn định quá trình huấn luyện cho các mạng sâu.

2.1.2 BERT và mô hình hóa ngôn ngữ có mặt nạ

Trên nền tảng bộ mã hóa (encoder) của Transformer, Devlin và cộng sự [1] đề xuất BERT (Bidirectional Encoder Representations from Transformers) – mô hình Encoder-only đầu tiên khai thác triệt để tính hai chiều của cơ chế tự chú ý. Khác với các mô hình ngôn ngữ tự hồi quy chỉ mô hình hóa xác suất từ trái sang phải, BERT được tiền huấn luyện đồng thời trên ngữ cảnh hai phía thông qua tác vụ *mô hình hóa ngôn ngữ có mặt nạ* (Masked Language Modeling – MLM): một tỷ lệ token trong chuỗi đầu vào bị thay bằng ký hiệu [MASK], và mô hình phải dự đoán lại các token gốc dựa trên toàn bộ ngữ cảnh còn lại. Mục tiêu MLM được biểu diễn bởi

Công thức (2.4):

$$\mathcal{L}_{\text{MLM}} = - \sum_{i \in \mathcal{M}} \log P(x_i \mid x_{\setminus \mathcal{M}}) \quad (2.4)$$

Trong đó $\mathcal{M}$ là tập vị trí bị che, x_i là token gốc tại vị trí i , và $x_{\setminus \mathcal{M}}$ là phần ngữ cảnh không bị che. BERT gốc sử dụng tỷ lệ che 15% và bổ sung tác vụ dự đoán câu kế tiếp (Next Sentence Prediction – NSP).

Tiếp nối BERT, Liu và cộng sự [2] đề xuất RoBERTa với các cải tiến về quy trình tiền huấn luyện: loại bỏ tác vụ NSP vốn không cải thiện hiệu năng, sử dụng mặt nạ động thay cho mặt nạ tĩnh, đồng thời tăng đáng kể quy mô dữ liệu và kích thước lô. Những điều chỉnh này giúp RoBERTa vượt trội BERT mà không thay đổi kiến trúc, qua đó khẳng định vai trò quan trọng của chiến lược tiền huấn luyện bên cạnh thiết kế mô hình. BERT và RoBERTa đã trở thành nền tảng cho hầu hết các bài toán hiểu ngôn ngữ tự nhiên, trong đó có các mô hình tiếng Việt tiêu biểu như PhoBERT [6] và ViDeBERTa [7].

2.1.3 Giới hạn của các mô hình Encoder thế hệ cũ

Mặc dù thiết lập nền tảng vững chắc cho các bài toán hiểu ngôn ngữ, BERT và RoBERTa vẫn tồn tại nhiều hạn chế cố hữu khi đặt cạnh các tiến bộ hiện đại của thế giới mô hình ngôn ngữ lớn (Large Language Model – LLM).

Giới hạn độ dài ngữ cảnh. BERT và RoBERTa sử dụng *mã hóa vị trí tuyệt đối* (absolute positional embedding) được học cố định ở độ dài tối đa 512 token. Điều này khiến chúng không thể xử lý các văn bản dài hơn nếu không có can thiệp đặc biệt, gây trở ngại cho nhiều ứng dụng thực tế như phân tích tài liệu pháp lý hay bài báo khoa học.

Kiến trúc lạc hậu. Trong khi các LLM thế hệ mới như LLaMA [3] hay DeepSeek [4] liên tục tích hợp các cải tiến kiến trúc tiên tiến, BERT và RoBERTa vẫn dừng lại ở kiến trúc Transformer gốc với hàm kích hoạt GELU, chuẩn hóa Post-LayerNorm và mã hóa vị trí tuyệt đối.


Tỷ lệ chiều sâu – chiều rộng chưa tối ưu. Levine và cộng sự [10] chứng minh rằng với một ngân sách tham số cho trước, tồn tại một ngưỡng chiều rộng mà dưới đó việc tăng chiều sâu trở nên kém hiệu quả. Các mô hình nhỏ như BERT thường hoạt động trong vùng *kém hiệu quả về chiều rộng* (width-inefficient), tức phân bổ quá nhiều tham số cho chiều rộng thay vì chiều sâu, làm hạn chế khả năng biểu diễn phân cấp.

Dữ liệu tiền huấn luyện lỗi thời. BERT được huấn luyện trên BooksCorpus và Wikipedia (khoảng 13GB), trong khi các mô hình hiện đại sử dụng các kho ngữ liệu web được lọc kỹ với quy mô lớn hơn nhiều bậc. Chính những hạn chế này tạo ra nhu cầu cấp thiết cho một thể hệ Encoder mới, dẫn tới sự ra đời của NeoBERT.

2.2 Kiến trúc NeoBERT

2.2.1 Tổng quan

NeoBERT [5] là mô hình Encoder-only thể hệ mới do Le Breton và cộng sự giới thiệu năm 2025, với mục tiêu thu hẹp khoảng cách giữa các Encoder truyền thống và thế giới LLM hiện đại. Mô hình có 250 triệu tham số, được tiền huấn luyện trên kho ngữ liệu web RefinedWeb [11] và xử lý khoảng 2,1 nghìn tỷ token trong toàn bộ quá trình huấn luyện, hỗ trợ độ dài ngữ cảnh lên tới 4.096 token. NeoBERT tích hợp đồng thời bốn cải tiến kiến trúc cốt lõi: tỷ lệ chiều sâu trên chiều rộng tối ưu, mã hóa vị trí quay (RoPE), hàm kích hoạt SwiGLU, và chuẩn hóa Pre-RMSNorm. Trên chuẩn đánh giá MTEB (Massive Text Embedding Benchmark), NeoBERT vượt trội các mô hình BERT_{large}, RoBERTA_{large} và NomicBERT dưới cùng điều kiện tinh chỉnh, đồng thời đạt tốc độ suy luận cao hơn đáng kể trên các chuỗi dài. Cấu trúc tổng quát của một khối Encoder trong NeoBERT được minh họa trong Hình 2.1; các mục tiếp theo phân tích chi tiết từng cải tiến cùng cơ sở khoa học của chúng.



Hình 2.1: Cấu trúc một khối Encoder của NeoBERT theo lối chuẩn hóa trước (Pre-RMSNorm): tín hiệu lần lượt qua RMSNorm, khối tự chú ý đa đầu có áp dụng RoPE trên truy vấn và khóa, rồi tới mạng truyền thẳng SwiGLU. Hai đường bên cạnh biểu diễn các kết nối tắt (residual connection).

2.2.2 Tỷ lệ chiều sâu trên chiều rộng tối ưu

Dựa trên lý thuyết của Levine và cộng sự [10] về sự tương tác giữa chiều sâu và chiều rộng trong cơ chế tự chú ý, NeoBERT giữ nguyên kích thước ẩn (hidden size) bằng 768 – tương thích plug-and-play với BERT_{base} – nhưng tăng số lớp Transformer từ 12 lên 28. Thiết kế *sâu và hẹp* (deep-and-narrow) này giúp mô hình thoát khỏi vùng kém hiệu quả về chiều rộng và xây dựng biểu diễn phân cấp sâu hơn. Để kiểm chứng, nhóm tác giả NeoBERT trước tiên tăng tổng số tham số lên 250 triệu trong khi giữ nguyên tỷ lệ gốc (16 lớp, kích thước ẩn 1056), sau đó điều chỉnh sang tỷ lệ sâu-hẹp (28 lớp, kích thước ẩn 768). Kết quả cho thấy cấu hình 28 lớp đạt điểm GLUE cao hơn, xác nhận lợi ích của chiều sâu đối với các mô hình

quy mô nhỏ [5].

2.2.3 Mã hóa vị trí quay (Rotary Position Embeddings)

Như đã phân tích, mã hóa vị trí tuyệt đối của BERT cố định độ dài chuỗi và khó ngoại suy sang các chuỗi dài hơn. NeoBERT thay thế bằng *mã hóa vị trí quay* (Rotary Position Embeddings – RoPE) của Su và cộng sự [12]. Ý tưởng cốt lõi của RoPE là mã hóa vị trí bằng một *phép quay* áp dụng lên véc-tơ truy vấn và khóa trước khi tính tích vô hướng: token tại vị trí m được quay một góc tỷ lệ với m . Do tích vô hướng của hai véc-tơ đã quay chỉ phụ thuộc vào hiệu số góc quay, điểm chú ý giữa hai token trở thành hàm của *vị trí tương đối* ($m - n$) thay vì vị trí tuyệt đối.

Cụ thể, với véc-tơ truy vấn $\mathbf{q}_m$ tại vị trí m và véc-tơ khóa $\mathbf{k}_n$ tại vị trí n , RoPE biến đổi chúng qua ma trận quay $R_{\Theta, m}$ rồi tính điểm chú ý như Công thức (2.5):

$$\text{Attention}(\mathbf{q}_m, \mathbf{k}_n) = (R_{\Theta, m} \mathbf{q}_m)^\top (R_{\Theta, n} \mathbf{k}_n) = \mathbf{q}_m^\top R_{\Theta, n-m} \mathbf{k}_n \quad (2.5)$$

Trong đó $R_{\Theta, m}$ là ma trận quay khối chéo, ghép từ các khối quay hai chiều với góc $m\theta_i$ và tần số $\theta_i = 10000^{-2(i-1)/d}$ cho cặp chiều thứ i . Đáng chú ý cuối trong Công thức (2.5) thể hiện tính chất then chốt: điểm chú ý chỉ phụ thuộc vào hiệu vị trí ($n - m$). Nhờ đó, RoPE cho phép mô hình học khoảng cách tương đối một cách tự nhiên, không bị ràng buộc bởi độ dài chuỗi huấn luyện, và có khả năng ngoại suy tốt sang các chuỗi dài hơn, kết hợp được với các kỹ thuật mở rộng ngữ cảnh như YaRN [13].

2.2.4 Hàm kích hoạt SwiGLU

BERT sử dụng hàm kích hoạt GELU trong lớp truyền thẳng. NeoBERT thay thế bằng SwiGLU [14], một biến thể thuộc họ *đơn vị tuyến tính có cổng* (Gated Linear Unit – GLU). Ý tưởng của GLU là điều tiết luồng

thông tin qua mạng bằng một *cổng* (gate): đầu vào được chiếu song song theo hai nhánh, một nhánh đi qua hàm phi tuyến rồi nhân từng phần tử với nhánh còn lại. Với SwiGLU, hàm phi tuyến được chọn là Swish, như Công thức (2.6):

$$\text{SwiGLU}(x) = (\text{Swish}(xW_1)) \otimes (xV)W_2, \quad \text{Swish}(x) = x \cdot \sigma(x) \quad (2.6)$$

Trong đó W_1, V, W_2 là các ma trận trọng số, σ là hàm sigmoid, và $\otimes$ là phép nhân từng phần tử (tích Hadamard). Cơ chế cổng cho phép mô hình điều chỉnh linh hoạt mức độ đóng góp của từng đặc trưng, qua đó học được các biểu diễn phức tạp hơn so với hàm kích hoạt thông thường [14]. Do SwiGLU sử dụng ba ma trận trọng số thay vì hai, NeoBERT thu nhỏ kích thước lớp ẩn bên trong theo hệ số $\frac{2}{3}$ để giữ nguyên tổng số tham số.

2.2.5 Chuẩn hóa Pre-RMSNorm

BERT áp dụng *chuẩn hóa sau* (Post-Layer Normalization): phép chuẩn hóa được đặt *sau* mỗi khối con và nằm ngoài kết nối tắt, vốn dễ gây bất ổn định khi huấn luyện với tốc độ học lớn. NeoBERT chuyển sang *chuẩn hóa trước* (Pre-Layer Normalization): phép chuẩn hóa được đặt *trước* mỗi khối con và nằm trong nhánh residual. Xiong và cộng sự [15] chứng minh rằng cách bố trí này giúp gradient tại thời điểm khởi tạo có độ lớn ổn định và gần như độc lập với chiều sâu, nhờ đó loại bỏ nhu cầu khởi động (warmup) tinh vi và cho phép huấn luyện ổn định các mạng sâu.

Bên cạnh đó, thay cho LayerNorm vốn tính cả trung bình và phương sai, NeoBERT sử dụng *chuẩn hóa theo căn quân phương* (Root Mean Square Layer Normalization – RMSNorm) của Zhang và Sennrich [16], định nghĩa bởi Công thức (2.7):

$$\text{RMSNorm}(x) = \frac{x}{\text{RMS}(x)} \odot g, \quad \text{RMS}(x) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon} \quad (2.7)$$

Trong đó d là số chiều, g là véc-tơ hệ số tỷ lệ có thể học được, và ϵ là hằng số nhỏ bảo đảm ổn định số học. RMSNorm bỏ qua bước trừ trung bình, chỉ giữ lại phép chuẩn hóa theo độ lớn, qua đó giảm chi phí tính toán mà vẫn duy trì độ ổn định huấn luyện tương đương. Một hệ quả quan trọng đối với đề tài: vì RMSNorm chuẩn hóa theo độ lớn của véc-tơ đầu vào, độ lớn (norm) của mỗi hàng nhúng có ảnh hưởng trực tiếp đến hành vi của mô hình – đây là lý do bước hiệu chỉnh chuẩn được trình bày trong Chương 3.

2.2.6 Dữ liệu và chiến lược tiền huấn luyện

NeoBERT được tiền huấn luyện trên RefinedWeb [11] – kho ngữ liệu web quy mô lớn được xây dựng từ CommonCrawl qua quy trình lọc và khử trùng lặp nghiêm ngặt. Penedo và cộng sự chứng minh rằng dữ liệu web được lọc kỹ, không cần bổ sung các kho ngữ liệu được tuyển chọn thủ công, vẫn đủ để huấn luyện các mô hình mạnh. Bên cạnh dữ liệu, NeoBERT áp dụng một số cải tiến về quy trình huấn luyện:

- **Tỷ lệ che 20%:** thay cho 15% của BERT, dựa trên kết quả của Wettig và cộng sự [17] cho thấy tỷ lệ che cao hơn có thể tối ưu hơn tùy theo quy mô mô hình.
- **Bộ tối ưu AdamW** với lịch suy giảm cosine, kết hợp khởi động tuyến tính ở giai đoạn đầu.
- **FlashAttention** [18] và các kỹ thuật tối ưu bộ nhớ, cho phép huấn luyện hiệu quả trên chuỗi dài với kích thước lô lớn.

Đặc biệt, NeoBERT áp dụng chiến lược mở rộng ngữ cảnh *hai giai đoạn*: giai đoạn đầu huấn luyện ở độ dài tối đa 1.024 token, giai đoạn sau huấn luyện bổ sung ở độ dài 4.096 token với việc tăng tỷ lệ lấy mẫu các chuỗi dài. Nhờ tính ngoại suy của RoPE, mô hình ở giai đoạn đầu đã tổng quát hóa tốt tới khoảng 3.000 token, và sau giai đoạn hai có thể mô hình

hóa ổn định các chuỗi còn dài hơn [5]. Chính nhờ tập hợp các cải tiến này, NeoBERT đạt hiệu năng vượt trội trên GLUE và MTEB so với các Encoder tiền nhiệm có quy mô lớn hơn, đồng thời là mô hình nền mà đề tài lựa chọn để thích nghi sang tiếng Việt.

2.3 Hình học của không gian biểu diễn từ

Phương pháp của đề tài dựa trên việc ánh xạ không gian nhúng của một mô hình tiếng Việt sang không gian của NeoBERT. Để lựa chọn dạng ánh xạ phù hợp, cần hiểu rõ cấu trúc hình học của các không gian biểu diễn từ. Mục này trình bày ba kết quả lý thuyết then chốt.

Tính bất đẳng hướng của không gian biểu diễn. Ethayarajh [19] chỉ ra rằng các biểu diễn từ của BERT, ELMo và GPT-2 mang tính *bất đẳng hướng* (anisotropic): thay vì phân bố đều theo mọi hướng, các véc-tơ co cụm trong một *hình nón hẹp*. Hệ quả là hai từ bất kỳ đã có độ tương đồng cosine khá cao, và một véc-tơ tĩnh duy nhất chỉ giải thích được dưới 5% phương sai trong các biểu diễn theo ngữ cảnh của một từ. Cấu trúc bất đẳng hướng này cho thấy một phép ánh xạ tuyến tính *toàn cục* duy nhất khó có thể nắm bắt được quan hệ biến đổi cục bộ giữa hai không gian; thay vào đó, các ánh xạ *cục bộ theo từng token* mới có khả năng thích ứng với hình học riêng của từng vùng lân cận.

Giả định đẳng cấu và giới hạn của ánh xạ tuyến tính toàn cục. Ormazabal và cộng sự [20] phân tích các phương pháp ánh xạ nhúng xuyên ngôn ngữ và chỉ ra rằng chúng ngầm giả định hai không gian nhúng đơn ngữ là *xấp xỉ đẳng cấu* (isomorphic) – tức có cùng cấu trúc sai khác một phép biến đổi tuyến tính. Tuy nhiên, giả định này không bền vững đối với các không gian được huấn luyện độc lập, đặc biệt với các ngôn ngữ khác biệt. Do đó, một ánh xạ tuyến tính toàn cục có giới hạn cố hữu khi hai không gian nguồn và đích không thực sự đẳng cấu – chính là tình huống giữa NeoBERT (tiếng Anh) và mô hình tiếng Việt.

Hiện tượng thoái hóa biểu diễn và quyết định buộc/tách trọng

số. Gao và cộng sự [21] chứng minh rằng việc *buộc trọng số* (weight tying) – chia sẻ chung ma trận nhúng đầu vào và ma trận đầu ra – cùng quá trình tối ưu hợp lý cực đại sẽ đẩy các véc-tơ nhúng vào một hình nón hẹp *thoái hóa* (degenerate), trong đó các token tần suất thấp bị co cụm nghiêm trọng nhất. Kết quả này là cơ sở lý thuyết cho việc *tách rời* (untie) ma trận nhúng đầu vào và ma trận đầu ra: khi hai ma trận là độc lập, mỗi ma trận giữ được hình học riêng và tránh được hiện tượng thoái hóa.

Ba kết quả trên cùng dẫn tới hai hệ quả thiết kế mà đề tài kế thừa: (1) việc chuyển giao không gian nhúng nên thực hiện bằng các *ánh xạ tuyến tính cục bộ theo từng token* thay vì một ánh xạ toàn cục, vì các không gian là bất đẳng hướng và không đẳng cấu; và (2) khi mô hình nền sử dụng *đầu giải mã tách rời* (untied head) – như trường hợp NeoBERT – thì ma trận đầu ra cần được khởi tạo như một ma trận độc lập, chứ không sao chép từ ma trận nhúng.

2.4 Thích nghi ngôn ngữ và khởi tạo không gian nhúng

2.4.1 Thích nghi ngôn ngữ và hiện tượng quên lãng thảm họa

NeoBERT chỉ được huấn luyện trên ngữ liệu tiếng Anh, trong khi việc huấn luyện lại từ đầu cho tiếng Việt trên quy mô hàng nghìn tỷ token là bất khả thi đối với hầu hết các nhóm nghiên cứu. Hướng tiếp cận khả thi là *thích nghi ngôn ngữ* (language adaptation) thông qua *tiếp tục tiền huấn luyện* (Continued Pre-training – CPT): khởi tạo một lớp nhúng mới cho tiếng Việt rồi tiếp tục huấn luyện mô hình trên ngữ liệu tiếng Việt. Gururangan và cộng sự [22] đã chứng minh rằng việc tiếp tục tiền huấn luyện trên dữ liệu gần với miền đích mang lại cải thiện ổn định; thích nghi xuyên ngôn ngữ có thể xem là trường hợp dịch chuyển miền ở mức cực đại.

Tuy nhiên, CPT với một lớp nhúng *khởi tạo ngẫu nhiên* thường dẫn tới hiện tượng *quên lãng thảm họa* (catastrophic forgetting): các lớp Transformer sâu bị kéo theo để thích ứng với lớp nhúng nhiễu loạn ban đầu, làm phá vỡ tri thức ngôn ngữ học quý giá đã học được. de Vries và Nissim [23] cho thấy có thể *tái sử dụng* một mô hình tiếng Anh cho ngôn ngữ khác bằng cách giữ lại phần thân Transformer và học một lớp nhúng mới, trong đó một bước khởi tạo nhúng tốt là yếu tố then chốt rút ngắn quá trình thích nghi. Gần đây, Elhady và cộng sự [24] chỉ ra rằng trong quá trình CPT thích nghi ngôn ngữ, độ hỗn loạn (perplexity) có thể trở nên ổn định trong khi năng lực hạ nguồn vẫn suy giảm do quên lãng thảm họa, qua đó nhấn mạnh tầm quan trọng của một điểm khởi đầu tốt. Ngoài ra, Ibrahim và cộng sự [25] khuyến nghị *khởi động lại tốc độ học* (learning-rate re-warming) khi tiếp tục huấn luyện từ một điểm kiểm tra đã suy giảm tốc độ học về gần 0 – một lưu ý vận hành quan trọng cho giai đoạn huấn luyện thích nghi.

2.4.2 Các phương pháp khởi tạo không gian nhúng

Như đã phân tích, chất lượng của bước *khởi tạo* lớp nhúng quyết định phần lớn hiệu quả của quá trình thích nghi. Nhiều phương pháp đã được đề xuất nhằm khởi tạo nhúng cho từ vựng mới một cách *có thông tin* thay vì ngẫu nhiên, tạo thành một dòng nghiên cứu mà SALT kế thừa và đề tài áp dụng.

WECHSEL [26] khởi tạo nhúng của từ vựng đích bằng cách bắc cầu qua một không gian nhúng từ tính song ngữ (fastText): mỗi token đích được biểu diễn thành véc-tơ tính, rồi nhúng của nó được tính bằng trung bình có trọng số của các nhúng token nguồn dựa trên độ tương đồng ngữ nghĩa trong không gian chung.

FOCUS [27] chia từ vựng đích thành các token *trùng lặp* (xuất hiện ở cả hai từ vựng) và token *mới*. Token trùng lặp được sao chép trực tiếp nhúng từ mô hình nguồn; token mới được khởi tạo bằng tổ hợp *thừa* của

các token trùng lặp, với trọng số chọn lọc qua hàm Sparsemax [28] dựa trên độ tương đồng trong không gian nhúng phụ trợ.

OFA [29] mở rộng ý tưởng trên cho bối cảnh đa ngôn ngữ, kết hợp các véc-tơ tĩnh đa ngôn ngữ đã căn chỉnh với một phép phân rã ma trận nhằm giảm số tham số và tăng tốc hội tụ khi tiếp tục tiền huấn luyện. Các phương pháp này tạo thành nền tảng trực tiếp mà SALT kế thừa.

2.4.3 Kỹ thuật Semantic Aware Linear Transfer (SALT)

SALT (Semantic Aware Linear Transfer) của Lee và cộng sự [8] là kỹ thuật khởi tạo không gian nhúng mà đề tài áp dụng. Khác với việc khởi tạo ngẫu nhiên hay sao chép trực tiếp, SALT *tái sử dụng* (recycle) không gian nhúng của một mô hình tiền huấn luyện sẵn có ở ngôn ngữ đích, rồi chuyển sức biểu diễn đó sang mô hình nguồn thông qua các phép *biến đổi tuyến tính nhận thức ngữ nghĩa*.

Ý tưởng cốt lõi của SALT gồm hai phần. Thứ nhất, dựa trên phần *từ vựng chồng lấp* (overlap) giữa hai mô hình, SALT thiết lập các *đường hồi quy tuyến tính* (linear regression) mô tả quan hệ giữa hai không gian nhúng. Thứ hai, với mỗi token *không trùng*, SALT lựa chọn một tập con các token tham chiếu (neo, anchor) có liên quan ngữ nghĩa – thông qua độ tương đồng trong không gian nhúng tĩnh – rồi áp dụng phép hồi quy tuyến tính cục bộ để ánh xạ nhúng của token đó sang không gian đích. Cách tiếp cận *cục bộ theo từng token* này phù hợp với các kết quả về hình học không gian biểu diễn đã trình bày ở Mục 2.3: do hai không gian là bất đẳng hướng và không đẳng cấu, một tập các ánh xạ cục bộ phản ánh trung thực quan hệ giữa chúng tốt hơn một ánh xạ tuyến tính toàn cục duy nhất.

Trong nghiên cứu gốc, SALT được áp dụng cho các mô hình nguồn dạng giải mã (decoder) như Gemma và XGLM, với không gian nhúng đích lấy từ các mô hình tiền huấn luyện tương ứng. Đề tài kế thừa khung phương pháp này và áp dụng cho bối cảnh khác biệt – một Encoder thể hệ mới

(NeoBERT) và ngôn ngữ đích là tiếng Việt – đồng thời đề xuất một số cải tiến về cách trích xuất tập neo và cách xử lý lớp đầu ra. Các nội dung này được trình bày chi tiết trong Chương 3.

2.5 Nhận xét và định hướng

Qua khảo sát trên, có thể rút ra một số nhận xét định hướng cho đề tài. Thứ nhất, NeoBERT là một mô hình Encoder hiện đại với nhiều ưu thế kiến trúc, song chỉ hỗ trợ tiếng Anh; việc xây dựng một phiên bản tiếng Việt là cần thiết và có giá trị thực tiễn. Thứ hai, huấn luyện lại từ đầu là bất khả thi về tài nguyên, trong khi CPT với khởi tạo ngẫu nhiên dễ dẫn tới quên lãng thảm họa; do đó một bước khởi tạo nhúng có thông tin là thiết yếu. Thứ ba, các kết quả về hình học không gian biểu diễn cho thấy việc chuyển giao nên thực hiện bằng các ánh xạ tuyến tính cục bộ theo từng token, và lớp đầu ra tách rời của NeoBERT cần được khởi tạo như một ma trận độc lập. Những nhận xét này dẫn tới việc lựa chọn và cải tiến kỹ thuật SALT làm nền tảng cho phương pháp đề xuất, được trình bày trong Chương 3.

Chương 3

Phương pháp xây dựng Vietnamese NeoBERT

Chương này trình bày chi tiết phương pháp xây dựng mô hình Vietnamese NeoBERT (ViNeoBERT). Trước hết, chúng tôi mô tả tổng quan quy trình ba giai đoạn cùng các mô hình nguồn được sử dụng (Mục 3.1). Tiếp theo, chúng tôi trình bày bước cắt tỉa và đồng bộ từ vựng (Mục 3.2), quá trình trích xuất tập neo theo cặp dịch – một cải tiến của đề tài so với SALT gốc (Mục 3.3), và phép chiếu SALT áp dụng cho cả lớp nhúng đầu vào lẫn lớp đầu ra tách rời của NeoBERT (Mục 3.4). Cuối cùng, chúng tôi mô tả giai đoạn căn chỉnh đóng băng (Mục 3.5) và giai đoạn tiếp tục tiền huấn luyện thích nghi (Mục 3.6). Các giá trị siêu tham số cụ thể được trình bày trong Chương 4.

3.1 Tổng quan phương pháp

3.1.1 Đặt vấn đề

Như đã phân tích trong Chương 2, việc xây dựng một Encoder hiện đại cho tiếng Việt từ NeoBERT đối mặt đồng thời ba thách thức: (1) NeoBERT chỉ được tiền huấn luyện trên ngữ liệu tiếng Anh, nên toàn bộ lớp nhúng của nó phản ánh phân phối từ vựng Anh ngữ; (2) tiếp tục tiền huấn luyện

với một lớp nhúng *khởi tạo ngẫu nhiên* để dẫn tới hiện tượng quên lãng thảm họa; và (3) huấn luyện lại từ đầu trên quy mô hàng nghìn tỷ token là bất khả thi về tài nguyên. Phương pháp của đề tài giải quyết đồng thời ba thách thức này bằng cách *khởi tạo có thông tin* lớp nhúng tiếng Việt thông qua kỹ thuật SALT, sau đó tinh chỉnh mô hình trên ngữ liệu tiếng Việt với chi phí khiêm tốn.

3.1.2 Mô hình nguồn và mô hình hiến tặng

Phương pháp sử dụng hai mô hình tiền huấn luyện:

- **NeoBERT** [5] đóng vai trò *kiến trúc đích*: toàn bộ phần thân Transformer (28 lớp với RoPE, SwiGLU, Pre-RMSNorm) cùng không gian biểu diễn tiếng Anh được giữ nguyên và dùng làm hệ tọa độ đích cho phép chiếu. Một đặc điểm quan trọng là NeoBERT sử dụng *đầu giải mã tách rời* (untied head): lớp đầu ra của tác vụ MLM là một ánh xạ tuyến tính riêng $y = W_{\text{dec}} h + b_{\text{dec}}$ với ma trận trọng số W_{dec} và véc-tơ độ chệch b_{dec} *độc lập* với ma trận nhúng đầu vào E . Do đó, việc thích nghi sang tiếng Việt đòi hỏi khởi tạo *cả hai* ma trận token: ma trận nhúng đầu vào E và ma trận đầu ra W_{dec} .
- **ViDeBERTa** [7] (bản **base**) đóng vai trò *mô hình hiến tặng* (donor): cung cấp không gian nhúng tiếng Việt chất lượng cao làm nguồn để tái sử dụng. ViDeBERTa dùng bộ tách từ SentencePiece theo thuật toán Unigram với kích thước từ vựng lớn (khoảng 128 nghìn token), trong đó mỗi đơn vị từ vựng đi kèm một điểm log-xác suất.


3.1.3 Quy trình ba giai đoạn

Mô hình ViNeoBERT được xây dựng qua ba giai đoạn nối tiếp, minh họa trong Hình 3.1:

1. **Khởi tạo SALT**: xây dựng tập từ vựng tiếng Việt, trích xuất tập neo, rồi chiếu không gian nhúng của ViDeBERTa sang không gian

NeoBERT để khởi tạo cả ma trận nhúng đầu vào lẫn ma trận đầu ra; độ chệch của đầu ra được khởi tạo theo tần suất từ đơn (Mục 3.2–3.4). Giai đoạn này *không* cập nhật phần thân Transformer.

2. **Căn chỉnh đóng băng:** đóng băng toàn bộ phần thân, chỉ huấn luyện ma trận nhúng và ma trận đầu ra trên một lượng nhỏ ngữ liệu tiếng Việt, nhằm để hai ma trận vừa khởi tạo căn chỉnh với nhau và với phần thân (Mục 3.5).
3. **Tiếp tục tiền huấn luyện thích nghi:** tinh chỉnh toàn bộ mô hình trên ngữ liệu tiếng Việt quy mô lớn với mục tiêu MLM theo lịch tốc độ học WSD (Mục 3.6).



Hình 3.1: Quy trình ba giai đoạn xây dựng ViNeoBERT: khởi tạo lớp nhúng và lớp đầu ra bằng SALT từ ViDeBERTa sang không gian NeoBERT, căn chỉnh đóng băng phần thân, rồi tiếp tục tiền huấn luyện thích nghi trên ngữ liệu tiếng Việt.

3.2 Cắt tỉa và đồng bộ từ vựng

Phép chiếu SALT yêu cầu lớp nhúng nguồn và đích có cùng kích thước từ vựng. Vì từ vựng của ViDeBERTa lớn hơn nhiều so với 30.522 token của NeoBERT, cần một bước *cắt tỉa từ vựng* (vocabulary pruning) để đồng bộ kích thước. Quá trình này giữ lại toàn bộ các token đặc biệt (như [CLS], [SEP], [MASK], [PAD]), sau đó chọn bổ sung các token thông thường có *điểm log-xác suất Unigram cao nhất* – tức các đơn vị từ vựng phổ biến và đáng tin cậy nhất – cho tới khi đạt đúng 30.522 token.

Gọi $\mathcal{V}_s$ là tập token đặc biệt và $\mathcal{V}_n$ là tập token thông thường của ViDeBERTa, với điểm Unigram score($\cdot$). Tập từ vựng tiếng Việt sau cắt tĩa $\mathcal{V}_t$ được xác định như Công thức (3.1):

$$\mathcal{V}_t = \mathcal{V}_s \cup \text{TopK}(\mathcal{V}_n, \text{score}, K), \quad K = 30,522 - |\mathcal{V}_s| \quad (3.1)$$

Trong đó $\text{TopK}(\mathcal{V}_n, \text{score}, K)$ trả về K token có điểm Unigram cao nhất. Bộ tách từ được ghi lại với ánh xạ chỉ số mới, đồng thời lưu một ánh xạ $\pi : \text{id mới} \rightarrow \text{id gốc}$ trong ViDeBERTa để truy xuất đúng hàng nhúng hiển tãg ở các bước sau. Phép so khớp chuỗi piece là chính xác vì các đơn vị Unigram là duy nhất trong từ vựng.

3.3 Trích xuất tập neo theo cặp dịch

3.3.1 Vai trò của tập neo

Tập neo (anchor set) $\mathcal{A}$ là tập các cặp token $(t_{\text{vi}}, t_{\text{neo}})$ có tương ứng ngữ nghĩa rõ ràng giữa từ vựng tiếng Việt và từ vựng NeoBERT. Mỗi cặp neo cung cấp một điểm *đã biết* của ánh xạ giữa hai không gian nhúng: nhúng NeoBERT của t_{neo} chính là đích mà nhúng ViDeBERTa của t_{vi} cần được ánh xạ tới. Do đó, chất lượng và độ phủ của tập neo quyết định trực tiếp chất lượng của phép chiếu SALT.

Trong nghiên cứu gốc, SALT [8] cũng như FOCUS [27] chủ yếu khai thác các token *trùng lặp bề mặt* (cùng dạng chuỗi) giữa hai từ vựng làm neo. Đối với cặp ngôn ngữ Anh–Việt vốn khác biệt lớn về hình thái, số token trùng lặp bề mặt là khá hạn chế. Vì vậy, đề tài đề xuất *mở rộng tập neo bằng các cặp dịch* Anh–Việt được khai thác tự động, nhằm làm giàu và phủ rộng tập neo. Đây là một trong những đóng góp chính của đề tài.

3.3.2 Lọc từ đầy đủ và hợp lệ

Để bảo đảm các cặp neo mang ngữ nghĩa trong sạch, trước khi khai thác cặp dịch, chúng tôi áp dụng hai bộ lọc. Thứ nhất, chỉ giữ lại các *token là từ đầy đủ* (word-initial), loại bỏ các mảnh từ phụ (subword) vốn không mang nghĩa độc lập. Thứ hai, đối với token tiếng Việt, chúng tôi áp dụng một bộ *lọc chính tả tiếng Việt* nghiêm ngặt: loại các token chứa ký tự không bản địa (f, j, w, z), giới hạn độ dài, yêu cầu đúng một cụm nguyên âm liền mạch, và tuân thủ các quy tắc chính tả (chẳng hạn k, gh, ngh chỉ đứng trước $i, e, ê, y$). Hai bộ lọc này bảo đảm chỉ những từ tiếng Việt hợp lệ và đơn nghĩa mới được xét làm neo.

3.3.3 Khai thác cặp dịch ba tầng

Trên tập token đã lọc, chúng tôi khai thác cặp dịch theo ba tầng bổ sung cho nhau:

- **Tầng trùng lặp bề mặt và số:** các từ có cùng dạng chuỗi ở cả hai từ vựng (được xác minh bằng dịch máy MarianMT [30]) và các token số chung.
- **Tầng dịch ngược một từ:** với mỗi từ tiếng Việt, chúng tôi dịch sang tiếng Anh rồi *dịch ngược* trở lại tiếng Việt; cặp neo chỉ được chấp nhận nếu kết quả dịch ngược trùng khớp với từ gốc và bản dịch tiếng Anh là một từ đơn thuộc từ vựng NeoBERT.
- **Tầng từ ghép:** các từ ghép tiếng Việt (đa âm tiết) được dịch trực tiếp, chỉ giữ lại khi bản dịch là một từ đơn thuộc từ vựng NeoBERT.

Cơ sở khoa học của phép kiểm tra *dịch ngược* là: một từ đa nghĩa thường không dịch ngược về chính nó một cách ổn định, do bản dịch trung gian có thể tương ứng với một nghĩa khác. Vì vậy, ràng buộc dịch ngược trùng khớp tự nhiên loại bỏ phần lớn các từ đa nghĩa, chỉ giữ lại các cặp tương ứng một–một đáng tin cậy. Ràng buộc “bản dịch là một từ đơn” bảo

đảm mỗi cặp neo tương ứng đúng một token NeoBERT. Toàn bộ tập neo thu được hợp nhất từ ba tầng và được dùng thống nhất cho cả lớp nhúng đầu vào lẫn lớp đầu ra ở Mục 3.4.

3.4 Phép chiếu SALT cho lớp nhúng và lớp đầu ra

Mục này trình bày phép chiếu SALT – bước khởi tạo cốt lõi. Với mỗi token tiếng Việt *không thuộc* tập neo, chúng tôi xây dựng nhúng của nó bằng một ánh xạ tuyến tính cục bộ học từ các neo lân cận về mặt ngữ nghĩa. Các token neo và token đặc biệt được sao chép trực tiếp hàng tương ứng từ NeoBERT.

3.4.1 Lựa chọn neo bằng Sparsemax

Để xác định các neo liên quan tới một token đích t , chúng tôi đo độ tương đồng ngữ nghĩa trong không gian nhúng từ tính fastText [31], [32]. Gọi $\mathbf{f}_t$ là véc-tơ fastText của t và $\{\mathbf{f}_a\}_{a \in \mathcal{A}}$ là véc-tơ fastText của các neo. Độ tương đồng cosine và trọng số neo được tính như Công thức (3.2):

$$s_{t,a} = \frac{\mathbf{f}_t^\top \mathbf{f}_a}{\|\mathbf{f}_t\| \|\mathbf{f}_a\|}, \quad \mathbf{w}_t = \text{sparsemax}(\mathbf{s}_t), \quad \mathcal{S}_t = \{a : w_{t,a} > 0\} \quad (3.2)$$

Trong đó $\text{sparsemax}(\cdot)$ [28] là phép chiếu lên đơn hình xác suất, cho kết quả *thưa* – chỉ một tập con nhỏ $\mathcal{S}_t$ các neo liên quan nhất nhận trọng số khác 0 (xem Mục 2.4.2). Việc dùng Sparsemax thay cho softmax đặc biệt phù hợp với cấu trúc *bất đẳng hướng* của không gian biểu diễn (Mục 2.3): vì trong không gian bất đẳng hướng mọi cặp từ đều có độ tương đồng cosine khá cao, một phân phối dày đặc sẽ pha trộn nhiều, trong khi hỗ trợ thưa giữ lại đúng các neo thực sự gần nghĩa.

3.4.2 Ánh xạ tuyến tính cục bộ theo từng token

Như đã lập luận ở Mục 2.3, do hai không gian nhúng là bất đẳng hướng và không đẳng cấu, một ánh xạ tuyến tính toàn cục duy nhất là không đủ. Thay vào đó, SALT học một *ánh xạ tuyến tính riêng cho từng token* từ tập neo được chọn. Gọi $A_t^{\text{src}} \in \mathbb{R}^{k \times h}$ là ma trận xếp chồng các nhúng *hiến tặng* (ViDeBERTa) của $k = |\mathcal{S}_t|$ neo trong $\mathcal{S}_t$, và $A_t^{\text{tgt}} \in \mathbb{R}^{k \times h}$ là ma trận các hàng *đích* (NeoBERT) tương ứng. Khi số neo đủ lớn ($k \geq k_0$), ánh xạ cục bộ X_t và nhúng kết quả $\mathbf{e}_t$ được xác định như Công thức (3.3):

$$X_t = (A_t^{\text{src}})^+ A_t^{\text{tgt}}, \quad \mathbf{e}_t = \mathbf{d}_t X_t \quad (3.3)$$

Trong đó $(\cdot)^+$ là *giả nghịch đảo* Moore–Penrose (nghiệm bình phương tối thiểu chuẩn nhỏ nhất), $\mathbf{d}_t \in \mathbb{R}^h$ là nhúng hiến tặng của token t , và h là số chiều ẩn. Ánh xạ X_t học quan hệ tuyến tính giữa hai không gian *cục bộ quanh token* t , dựa trên các neo gần nghĩa nhất với nó.

Khi số neo không đủ ($k < k_0$), giả nghịch đảo trở nên kém ổn định; khi đó chúng tôi thoái lui về *trung bình có trọng số Sparsemax* của các hàng đích, như Công thức (3.4):

$$\mathbf{e}_t = \frac{\sum_{a \in \mathcal{S}_t} w_{t,a} \mathbf{a}^{\text{tgt}}}{\sum_{a \in \mathcal{S}_t} w_{t,a}} \quad (3.4)$$

Trường hợp token không có véc-tơ fastText hợp lệ, nhúng được khởi tạo ngẫu nhiên theo phân phối chuẩn khớp với thống kê của NeoBERT.

3.4.3 Áp dụng cho cả lớp nhúng đầu vào và lớp đầu ra

Đây là điểm khác biệt then chốt so với SALT gốc. Vì NeoBERT dùng đầu giải mã *tách rời*, ma trận đầu ra W_{dec} là một ma trận độc lập với hình học riêng – và theo kết quả về hiện tượng thoái hóa biểu diễn (Mục 2.3),

nó *không* thể được khởi tạo bằng cách sao chép ma trận nhúng. Do đó, chúng tôi áp dụng *cùng một quy trình chiếu SALT theo từng token* cho cả hai ma trận, chỉ khác ở tập hàng đích:

- Với **ma trận nhúng đầu vào** E : hàng đích A_t^{tgt} lấy từ các *hàng nhúng* NeoBERT của các neo.
- Với **ma trận đầu ra** W_{dec} : hàng đích A_t^{tgt} lấy từ các *hàng đầu giải mã* NeoBERT của các neo.

Nhờ vậy, mỗi ma trận được khởi tạo trong đúng không gian của nó, phản ánh trung thực quan hệ ngữ nghĩa mà các neo thiết lập trong từng không gian.

3.4.4 Hiệu chỉnh chuẩn của lớp nhúng

Như đã lưu ý ở Mục 2.2.5, NeoBERT dùng Pre-RMSNorm vốn chuẩn hóa theo độ lớn của véc-tơ; do đó độ lớn (norm) của mỗi hàng nhúng ảnh hưởng trực tiếp đến hành vi mô hình. Các nhúng sinh ra từ phép chiếu SALT thường có độ lớn lệch so với phân phối của NeoBERT. Để tránh gây bất ổn định, chúng tôi hiệu chỉnh độ lớn của mỗi hàng *không phải neo* về độ lớn trung bình của NeoBERT trong khi giữ nguyên hướng, như Công thức (3.5):

$$\mathbf{e}_t \leftarrow \mathbf{e}_t \cdot \frac{\mu_{\text{neo}}}{\|\mathbf{e}_t\|}, \quad \mu_{\text{neo}} = \frac{1}{|\mathcal{V}_{\text{neo}}|} \sum_v \|E_v^{\text{neo}}\| \quad (3.5)$$

Trong đó μ_{neo} là độ lớn trung bình của các hàng nhúng NeoBERT. Các hàng neo và token đặc biệt được giữ nguyên để bảo toàn độ trung thực với NeoBERT.

3.4.5 Khởi tạo độ chệch đầu ra theo tần suất

Lớp đầu ra của NeoBERT có một véc-tơ độ chệch b_{dec} mã hóa *tiên nghiệm tần suất* của token. Các phương pháp khởi tạo trước đây thường

để độ chệch này bằng 0, khiến mô hình ở bước đầu phải lãng phí công sức học lại phân phối tần suất biên. Đề tài khởi tạo b_{dec} theo *log-tần-suất từ đơn* (unigram log-frequency) của tiếng Việt, như Công thức (3.6):

$$b_{\text{dec},v} = \log p_v, \quad p_v = \frac{c_v + 1}{\sum_{u \in \mathcal{V}_t} c_u + |\mathcal{V}_t|} \quad (3.6)$$

Trong đó c_v là số lần xuất hiện của token v trong ngữ liệu tiếng Việt (đếm qua bộ tách từ đã cắt tĩa), và phép cộng 1 ở tử số là làm trơn Laplace. Nhờ cách khởi tạo này, ngay ở bước huấn luyện đầu tiên mô hình đã “đoán” đúng phân phối tần suất từ đơn thay vì phân phối đều, giúp hàm mất mát khởi điểm xấp xỉ *entropy từ đơn* của tiếng Việt – thấp hơn đáng kể so với mức ngẫu nhiên $\log |\mathcal{V}_t|$. Đây là một cải tiến đơn giản nhưng hiệu quả, phối hợp ăn khớp với việc khởi tạo trọng số đầu ra bằng SALT.

3.5 Giai đoạn căn chỉnh đóng băng

Sau bước khởi tạo, ma trận nhúng và ma trận đầu ra của tiếng Việt là *mới* đối với phần thân Transformer đã được huấn luyện trên tiếng Anh. Nếu lập tức tinh chỉnh toàn bộ mô hình, phần thân có thể bị kéo theo để thích ứng với hai ma trận mới còn chưa ổn định, làm gia tăng nguy cơ quên lãng thảm họa (Mục 2.4.1). Vì vậy, chúng tôi chèn một *giai đoạn căn chỉnh đóng băng*: đóng băng toàn bộ phần thân Transformer và chỉ huấn luyện ma trận nhúng đầu vào, ma trận đầu ra và độ chệch của nó trên một lượng nhỏ ngữ liệu tiếng Việt với mục tiêu MLM.

Trực giác của bước này là để hai ma trận vừa khởi tạo *căn chỉnh với nhau và với phần thân cố định* trong không gian biểu diễn trước khi cho phép phần thân thay đổi; nhờ đó điểm khởi đầu của giai đoạn tiếp tục tiền huấn luyện ổn định hơn. Cách làm này nằm trong tinh thần chiến lược *đóng băng rồi thích nghi* của de Vries và Nissim [23], vốn cho thấy việc tách giai đoạn học lớp nhúng khỏi giai đoạn tinh chỉnh toàn bộ giúp tái sử dụng mô hình hiệu quả hơn. Trong thực nghiệm (Chương 4), chúng tôi

quan sát thấy giai đoạn này cải thiện chất lượng khởi đầu, do đó được giữ lại trong quy trình.

3.6 Tiếp tục tiền huấn luyện thích nghi

Ở giai đoạn cuối, toàn bộ mô hình được tinh chỉnh trên ngữ liệu tiếng Việt quy mô lớn CulturaX với mục tiêu MLM. Theo Gururangan và cộng sự [22], việc tiếp tục tiền huấn luyện trên dữ liệu miền đích mang lại cải thiện ổn định; ở đây miền đích là toàn bộ ngôn ngữ tiếng Việt.

Lịch tốc độ học WSD. Chúng tôi sử dụng lịch *Warmup–Stable–Decay* (WSD) [33] thay cho lịch cosine cố định, vì WSD cho phép huấn luyện theo nhiều phiên nối tiếp mà không phải cam kết trước tổng số bước. Tốc độ học η theo bước toàn cục s được định nghĩa như Công thức (3.7):

$$\eta(s) = \begin{cases} \eta_{\text{peak}} \cdot \frac{s}{S_w} & \text{nếu } s < S_w \quad (\text{khởi động}) \\ \eta_{\text{peak}} & \text{nếu } S_w \leq s < S_c \quad (\text{ổn định}) \\ \eta_{\text{peak}} \cdot \left(1 - \sqrt{\frac{s-S_c}{S_d}}\right) & \text{nếu } s \geq S_c \quad (\text{làm nguội}) \end{cases} \quad (3.7)$$

Trong đó S_w là mốc kết thúc khởi động, S_c là mốc bắt đầu làm nguội, và S_d là độ dài giai đoạn làm nguội. Pha *ổn định* giữ tốc độ học ở đỉnh trong phần lớn quá trình; pha *làm nguội* dùng dạng $1 - \sqrt{\cdot}$ vốn được Hägele và cộng sự [34] chứng minh là dạng làm nguội cho chất lượng hạ nguồn tốt nhất ở một ngân sách cho trước. Vì lịch WSD được điều khiển theo *bước toàn cục*, một phiên huấn luyện nối tiếp tiếp tục ở pha ổn định mà không bị khởi động lại đột ngột.

Khởi động lại tốc độ học. Một điểm kiểm tra đã được làm nguội về tốc độ học gần 0 gần như không thể cập nhật trọng số nếu huấn luyện tiếp mà không xử lý. Do đó, mỗi khi tiếp tục huấn luyện trên dữ liệu mới (ví dụ một pha làm nguội trên dữ liệu mới), tốc độ học được *khởi động lại* rồi làm nguội lại theo đúng khuyến nghị của Ibrahim và cộng sự [25].

Ngoài ra, bộ tối ưu AdamW được giữ *liên tục* giữa các phiên (mang theo các mô-men bậc nhất và bậc hai) với cặp tham số $\beta = (0,9; 0,95)$ theo công thức gốc của NeoBERT, để bộ tiền điều kiện của bộ tối ưu khớp với chế độ mà phần thân đã được huấn luyện.

3.7 Tổng kết phương pháp

Tóm lại, phương pháp xây dựng ViNeoBERT gồm ba giai đoạn: (1) khởi tạo lớp nhúng và lớp đầu ra bằng phép chiếu SALT theo từng token từ ViDeBERTa sang không gian NeoBERT, với tập neo được làm giàu bằng cặp dịch và độ chệch đầu ra khởi tạo theo tần suất; (2) căn chỉnh đóng băng để hai ma trận mới ổn định cùng phần thân; và (3) tiếp tục tiền huấn luyện thích nghi theo lịch WSD. So với SALT gốc, đề tài có ba khác biệt chính: *mở rộng tập neo bằng cặp dịch* (Mục 3.3), *áp dụng phép chiếu cho cả lớp đầu ra tách rời kèm khởi tạo độ chệch theo tần suất* (Mục 3.4), và *bổ sung giai đoạn căn chỉnh đóng băng* (Mục 3.5). Hiệu quả của các thành phần này được đánh giá trong Chương 4.

Chương 4

Thực nghiệm và Đánh giá

4.1 Môi trường và dữ liệu thực nghiệm

- Cấu hình phần cứng và phần mềm.
- Bộ dữ liệu tiếng Việt sử dụng để tinh chỉnh và đánh giá (Ví dụ: dữ liệu phân loại, hỏi đáp, STS).

4.2 Thiết lập các tham số huấn luyện (Hyperparameters)

- Batch size, learning rate, số epoch, tối ưu hóa (Optimizer).

4.3 Kịch bản đánh giá

- Các Baseline Models (ViDeBERTa gốc, phobert, v.v.).
- Các tiêu chí đánh giá (MTEB benchmark cho tiếng Việt, Độ chính xác, F1-score, Tốc độ hội tụ).

4.4 Kết quả và Thảo luận

- Hiệu năng trên các tác vụ hiểu ngôn ngữ (NLU).
- Khả năng xử lý ngữ cảnh dài (Long-context capability).
- So sánh thời gian và chi phí tính toán (Giảm thiểu do tái sử dụng trọng số).
- Phân tích lỗi (Error Analysis).

Chương 5

Kết luận và Hướng phát triển

5.1 Kết luận

Tóm lược sự thành công của việc áp dụng SALT để tạo ra Vietnamese NeoBERT.

5.2 Hạn chế của đề tài

Ví dụ: giới hạn về dữ liệu, phần cứng, khả năng áp dụng trên lĩnh vực đặc thù.

5.3 Hướng phát triển trong tương lai

Tiếp tục huấn luyện trên tập dữ liệu lớn hơn, mở rộng ứng dụng trên các bài toán sinh văn bản, v.v.

Danh mục công trình của tác giả

1. Tạp chí ABC
2. Tạp chí XYZ

Tài liệu tham khảo

Tiếng Anh

- [1] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K., “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of NAACL-HLT*, 2019, pp. 4171–4186.
- [2] Liu, Y., Ott, M., Goyal, N., *et al.*, “RoBERTa: A robustly optimized BERT pretraining approach,” *arXiv preprint arXiv:1907.11692*, 2019.
- [3] Dubey, A. *et al.*, “The Llama 3 herd of models,” *arXiv preprint arXiv:2407.21783*, 2024.
- [4] DeepSeek-AI, “DeepSeek-V3 technical report,” *arXiv preprint arXiv:2412.1943*, 2024.
- [5] Le Breton, L., Fournier, Q., El Mezouar, M., Morris, J. X., and Chandar, S., “NeoBERT: A next-generation BERT,” *arXiv preprint arXiv:2502.19587*, 2025.
- [6] Nguyen, D. Q. and Nguyen, A. T., “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 1037–1042.
- [7] Tran, C. D., Pham, N. H., Nguyen, A., Hy, T. S., and Vu, T., “ViDeBERTa: A powerful pre-trained language model for Vietnamese,” in *Findings of the Association for Computational Linguistics: EACL 2023*, 2023, pp. 1071–1078.

- [8] Lee, S., Hong, S., Moon, H., and Lim, H., “Semantic aware linear transfer by recycling pre-trained language models for cross-lingual transfer,” *Findings of the Association for Computational Linguistics: ACL 2025*, 2025, arXiv:2505.10945.
- [9] Vaswani, A., Shazeer, N., Parmar, N., *et al.*, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [10] Levine, Y., Wies, N., Sharir, O., Bata, H., and Shashua, A., “The depth-to-width interplay in self-attention,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:2006.12467, 2020.
- [11] Penedo, G., Malartic, Q., Hesslow, D., *et al.*, “The RefinedWeb dataset for Falcon LLM: Outperforming curated corpora with web data, and web data only,” *arXiv preprint arXiv:2306.01116*, 2023.
- [12] Su, J., Lu, Y., Pan, S., Murtadha, A., Wen, B., and Liu, Y., “RoFormer: Enhanced transformer with rotary position embedding,” *Neurocomputing*, vol. 568, 2024, arXiv:2104.09864.
- [13] Peng, B., Quesnelle, J., Fan, H., and Shippole, E., “YaRN: Efficient context window extension of large language models,” *arXiv preprint arXiv:2309.00071*, 2023.
- [14] Shazeer, N., “GLU variants improve transformer,” *arXiv preprint arXiv:2002.05202*, 2020.
- [15] Xiong, R., Yang, Y., He, D., *et al.*, “On layer normalization in the transformer architecture,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.
- [16] Zhang, B. and Sennrich, R., “Root mean square layer normalization,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:1910.07467, 2019.

- [17] Wettig, A., Gao, T., Zhong, Z., and Chen, D., “Should you mask 15% in masked language modeling?” In *Proceedings of the 17th Conference of the European Chapter of the ACL (EACL)*, 2023.
- [18] Dao, T., “FlashAttention-2: Faster attention with better parallelism and work partitioning,” in *International Conference on Learning Representations (ICLR)*, arXiv:2307.08691, 2024.
- [19] Ethayarajh, K., “How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019.
- [20] Ormazabal, A., Artetxe, M., Labaka, G., Soroa, A., and Agirre, E., “Analyzing the limitations of cross-lingual word embedding mappings,” in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2019, pp. 4990–4995.
- [21] Gao, J., He, D., Tan, X., Qin, T., Wang, L., and Liu, T.-Y., “Representation degeneration problem in training natural language generation models,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [22] Gururangan, S., Marasović, A., Swayamdipta, S., *et al.*, “Don’t stop pretraining: Adapt language models to domains and tasks,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.
- [23] Vries, W. de and Nissim, M., “As good as new. how to successfully recycle English GPT-2 to make models for other languages,” in *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, 2021.
- [24] Elhady, A., Agirre, E., and Artetxe, M., “Emergent abilities of large language models under continued pretraining for language adapta-

- tion,” in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, arXiv:2506.00288, 2025.
- [25] Ibrahim, A., Thérien, B., Gupta, K., *et al.*, “Simple and scalable strategies to continually pre-train large language models,” *Transactions on Machine Learning Research (TMLR)*, 2024, arXiv:2403.08763.
 - [26] Minixhofer, B., Paischer, F., and Rekabsaz, N., “WECHSEL: Effective initialization of subword embeddings for cross-lingual transfer of monolingual language models,” in *Proceedings of NAACL-HLT*, 2022, pp. 3992–4006.
 - [27] Dobler, K. and Melo, G. de, “FOCUS: Effective embedding initialization for monolingual specialization of multilingual models,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023.
 - [28] Martins, A. F. T. and Astudillo, R. F., “From softmax to sparsemax: A sparse model of attention and multi-label classification,” in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 2016.
 - [29] Liu, Y., Lin, P., Wang, M., and Schütze, H., “OFA: A framework of initializing unseen subword embeddings for efficient large-scale multilingual continued pretraining,” in *Findings of the Association for Computational Linguistics: NAACL 2024*, 2024.
 - [30] Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., *et al.*, “Marian: Fast neural machine translation in C++,” in *Proceedings of ACL 2018, System Demonstrations*, 2018.
 - [31] Bojanowski, P., Grave, E., Joulin, A., and Mikolov, T., “Enriching word vectors with subword information,” *Transactions of the Association for Computational Linguistics (TACL)*, vol. 5, pp. 135–146, 2017.

- [32] Grave, E., Bojanowski, P., Gupta, P., Joulin, A., and Mikolov, T., “Learning word vectors for 157 languages,” in *Proceedings of the 11th International Conference on Language Resources and Evaluation (LREC)*, 2018.
- [33] Hu, S., Tu, Y., Han, X., He, C., Cui, G., Long, X., *et al.*, “MiniCPM: Unveiling the potential of small language models with scalable training strategies,” *arXiv preprint arXiv:2404.06395*, 2024.
- [34] Hägele, A., Bakouch, E., Kosson, A., Ben Allal, L., Von Werra, L., and Jaggi, M., “Scaling laws and compute-optimal training beyond fixed training durations,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:2405.18392, 2024.
- [35] Hendrycks, D. and Gimpel, K., “Gaussian error linear units (GELUs),” 2016.
- [36] Warner, B., Chaffin, A., Clavié, B., *et al.*, “Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference,” *arXiv preprint arXiv:2412.13663*, 2024.
- [37] Nussbaum, Z., Morris, J. X., Duderstadt, B., and Mulyar, A., “Nomic embed: Training a reproducible long context text embedder,” *arXiv preprint arXiv:2402.01613*, 2024.
- [38] Loshchilov, I. and Hutter, F., “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, arXiv:1711.05101, 2019.
- [39] Loshchilov, I. and Hutter, F., “SGDR: Stochastic gradient descent with warm restarts,” in *International Conference on Learning Representations (ICLR)*, arXiv:1608.03983, 2017.

Phụ lục A

Phụ lục A

(Nội dung Phụ lục A được đặt tại đây)