

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN  
KHOA CÔNG NGHỆ THÔNG TIN

Võ Thành Phong

TĂNG CƯỜNG DỊCH MÁY MẠNG  
NEURAL ANH-VIỆT THÔNG QUA TÍCH  
HỢP ĐỒ THỊ TRI THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN  
CHƯƠNG TRÌNH CHÍNH QUY

Tp. Hồ Chí Minh, tháng 07/2024

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN  
KHOA CÔNG NGHỆ THÔNG TIN

Võ Thành Phong - 20120547

**TĂNG CƯỜNG DỊCH MÁY MẠNG  
NEURAL ANH-VIỆT THÔNG QUA TÍCH  
HỢP ĐỒ THỊ TRI THỨC**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN  
CHƯƠNG TRÌNH CHÍNH QUY

**GIÁO VIÊN HƯỚNG DẪN**

TS. Nguyễn Hồng Bửu Long

Tp. Hồ Chí Minh, tháng 07/2024

# Lời cảm ơn

Lời đầu tiên, tôi xin gửi lời cảm ơn sâu sắc đến thầy TS. Nguyễn Hồng Bửu Long. Thầy đã cho phép tôi thực hiện đề tài khóa luận này và đã dành nhiều thời gian, tận tâm hướng dẫn tôi trong suốt quá trình nghiên cứu. Những kiến thức sâu rộng và những lời chỉ dẫn quý báu của thầy đã giúp tôi không chỉ hoàn thành tốt khóa luận mà còn phát triển thêm kiến thức và kỹ năng trong lĩnh vực Học sâu nói chung và Xử lý ngôn ngữ tự nhiên nói riêng.

Tôi xin chân thành cảm ơn Trung tâm Ngôn ngữ học Tính toán (CLC) vì đã cung cấp cho tôi một môi trường nghiên cứu và các tài nguyên thuận lợi trong quá trình tôi thực hiện đề tài khóa luận của mình.

Đặc biệt, tôi xin bày tỏ lòng biết ơn sâu sắc tới Khoa Công nghệ thông tin vì đã cung cấp cho tôi một môi trường học tập và phát triển tuyệt vời. Tôi cũng muốn gửi lời cảm ơn đến tất cả các thầy cô đã tận tâm truyền đạt kiến thức và những bài học quý giá trong suốt quá trình học tập của tôi tại trường.

Tôi cũng xin gửi lời cảm ơn đến gia đình, bạn bè, và các anh chị khóa trên đã luôn đồng hành cùng tôi và giúp đỡ tôi trong suốt quá trình học tập và nghiên cứu tại trường. Chính những sự quan tâm và giúp đỡ này là những nguồn động lực to lớn để bản thân tôi luôn cố gắng phấn đấu hết mình hoàn thành thật tốt những mục tiêu mà mình đã đặt ra.

Một lần nữa, tôi chân thành bày tỏ lòng biết ơn đến tất cả những người đã giúp đỡ tôi trong quá trình thực hiện khóa luận tốt nghiệp của mình.

# Đề cương chi tiết



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN  
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

# TĂNG CƯỜNG DỊCH MÁY MẠNG NEURAL ANH-VIỆT THÔNG QUA TÍCH HỢP ĐỒ THỊ TRI THỨC

*(ENHANCING ENGLISH-VIETNAMESE NEURAL MACHINE  
TRANSLATION THROUGH KNOWLEDGE GRAPH  
INTEGRATION)*

## 1 THÔNG TIN CHUNG

Người hướng dẫn:

– TS. Nguyễn Hồng Bửu Long (Khoa Công nghệ Thông tin)

Sinh viên thực hiện:

– Võ Thành Phong (MSSV: 20120547)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 1/2024 đến 7/2024

## 2 NỘI DUNG THỰC HIỆN

### 2.1 Giới thiệu về đề tài

Ngày nay, các công nghệ dịch thuật tự động ngày càng được sử dụng phổ biến, qua đó giúp việc giao tiếp trên toàn cầu trở nên thuận lợi hơn bao giờ hết. Dù đã đạt được những bước tiến vượt bậc, quá trình dịch thuật, vốn dựa trên các mô hình học sâu, vẫn đối mặt với những thách thức đáng kể. Khó khăn lớn nhất nằm ở việc chuyển đổi ngữ nghĩa một cách chính xác giữa các ngôn ngữ khác nhau.

Một trong những thách thức lớn trong việc hiểu ngữ nghĩa đến từ chất lượng chưa tốt của các bản dịch đối với các thực thể (entity) xuất hiện trong quá trình huấn luyện mô hình. Để giải quyết vấn đề này, nghiên cứu này đề xuất việc tích hợp đồ thị tri thức (knowledge graph) vào quá trình dịch máy. Đồ thị tri thức là một cách biểu diễn của cơ sở tri thức (knowledge base) dưới dạng đồ thị. Cơ sở tri thức (KB), một kho dữ liệu lưu trữ thông tin về thế giới thực và các mối quan hệ giữa các thành phần, được sử dụng để bổ sung thông tin cho các thực thể trong câu, từ đó cải thiện chất lượng của bản dịch. Bằng cách áp dụng đồ thị tri thức, nghiên cứu này hướng tới việc nâng cao chất lượng bản dịch cho các thực thể trong câu, qua đó cải thiện chất lượng chung của quá trình dịch máy.

Đề tài nghiên cứu các kỹ thuật về việc: Trích xuất thực thể từ văn bản nguồn và ánh xạ chúng vào một đồ thị tri thức (KG) đã chọn lựa trước. Sau đó, thông tin về thực thể từ KG sẽ được tích hợp trực tiếp vào mô hình dịch máy, giúp tạo ra các bản dịch không chỉ chính xác hơn mà còn phong phú về mặt ngữ nghĩa. Điều này đặc biệt quan trọng đối với các cặp ngôn ngữ có những khác biệt lớn về cấu trúc ngữ pháp. Sự tích hợp của KG giúp cải thiện đáng kể sự hiểu biết về nghĩa của thực thể trong toàn bộ câu, qua đó nâng cao độ chính xác cả về ngữ nghĩa lẫn cấu trúc ngữ pháp trong bản dịch.



## 2.2 Mục tiêu đề tài

Trong quá trình cài đặt thực tế, việc sử dụng một đồ thị tri thức (KG) còn gặp nhiều khó khăn khác như:

- Kích thước của một KG (đề cập đến hai yếu tố: số lượng thực thể và số lượng quan hệ tồn tại trong KG đó).
- KG hỗ trợ đơn ngữ hay đa ngữ.
- Đặc biệt còn phải lưu tâm đến tính mới và tính bao quát của dữ liệu tồn tại trong KG.

Những tác vụ khác trong lĩnh vực Xử lý ngôn ngữ tự nhiên thường sử dụng kết quả từ KG theo dạng truy vấn trực tiếp tên của thực thể hoặc tên của quan hệ, chẳng hạn trong tác vụ **Hỏi đáp** (Question answering), việc truy vấn vào KG thường trả về kết quả là một tên thực thể rõ ràng nhằm giúp trả lời thành công cho câu hỏi đầu vào. Tuy nhiên, thông tin của thực thể từ KG được sử dụng cho các mô hình dịch máy chú trọng vào yếu tố ngữ nghĩa, và chính điều này yêu cầu một quá trình mã hóa cụ thể và thật sự hiệu quả từ dạng dữ liệu thô có cấu trúc sang dạng véc-tơ trong không gian đa chiều.

Do đó kết quả của đề tài không chỉ dừng lại ở việc cải thiện chất lượng dịch máy mà còn là quá trình tạo ra một hệ thống liên kết thực thể có hiệu quả từ dữ liệu dạng văn bản sang đồ thị tri thức (dữ liệu có cấu trúc).

## 2.3 Phạm vi của đề tài

Nội dung nghiên cứu chính: Phân tích sự ảnh hưởng của đồ thị tri thức đến chất lượng mô hình dịch máy mà cụ thể là mô hình sử dụng kiến trúc Transformer, kiến trúc nổi tiếng trong lĩnh vực Xử lý ngôn ngữ tự nhiên.

Đối tượng nghiên cứu:

- Các thuật toán cho việc nhúng đồ thị tri thức (Knowledge Graph Embedding algorithms).

- Kiến trúc Transformer cho tác vụ dịch máy.

Các tập dữ liệu dự kiến:


- IWSLT En-Vi: Bộ dữ liệu dịch máy trên cặp ngôn ngữ Anh-Việt.
- Các cơ sở tri thức đã được công bố trước đó.

## 2.4 Cách tiếp cận dự kiến


Đề tài nghiên cứu các phương pháp kết hợp véc-tơ và cơ chế chú ý (attention) giữa các véc-tơ biểu diễn cho các thực thể được trích xuất từ đồ thị tri thức (KG) thông qua các thuật toán nhúng đồ thị tri thức (Knowledge Graph Embedding algorithms) với ma trận nội véc-tơ biểu diễn cho câu đầu vào được tạo ra trong chính mô hình Transformer.

- Đối với phương pháp kết hợp véc-tơ: Sau khi các thực thể được trích xuất từ câu đầu vào ở ngôn ngữ nguồn (tiếng Anh), chúng sẽ được ánh xạ vào một ma trận các véc-tơ, cái mà được tạo ra nhờ vào việc áp dụng thuật toán nhúng đồ thị lên trên đồ thị tri thức được chọn, từ đó trích xuất được các véc-tơ tương ứng cho các thực thể. Ngay khi quá trình trích xuất các véc-tơ cho các thực thể hoàn thành, chúng sẽ được nối với ma trận nội véc-tơ biểu diễn cho câu đầu vào được tạo ra nhờ vào lớp nhúng (embedding layer) trong mô hình Transformer, hoặc thay thế trực tiếp các véc-tơ của các thực thể trong ma trận nhúng này. [Hình 1]
- Đối với phương pháp sử dụng cơ chế chú ý chéo: Các véc-tơ (được trích xuất từ ma trận là kết quả của việc áp dụng thuật toán nhúng đồ thị lên trên đồ thị tri thức được chọn) sẽ được tạo thành ma trận khóa (key) và ma trận giá trị (value) để thực hiện chú ý chéo với ma trận mã hóa cho câu đầu vào được tạo ra trong mô hình Transformer (việc này tương tự với quá trình chú ý chéo giữa thành phần mã hóa (encoder) và thành phần giải mã (decoder) trong kiến trúc Transformer). Kết quả của quá trình này sau đó sẽ được bỏ





Hình 1: Tổng quan về các phương pháp kết hợp véc-tơ



Hình 2: Tổng quan về phương pháp sử dụng chú ý chéo

sung lại vào ma trận nhúng đầu vào ban đầu trước khi truyền vào bộ mã hóa (encoder). [Hình 2]

## 2.5 Kết quả dự kiến của đề tài

Kết quả dự kiến mà chúng tôi mong muốn đạt được thông qua đề tài:

- Phân tích được việc ảnh hưởng của đồ thị tri thức lên chất lượng các bản dịch của mô hình dịch máy.
- Phân tích được tính hiệu quả của các phương pháp tính toán giữa các thành phần của mô hình Transformer và đồ thị tri thức.
- Bài báo khoa học trong nước hoặc quốc tế về chủ đề liên quan.

## 2.6 Kế hoạch thực hiện


| Thời gian                 | Nội dung                                                                                                                         |
|---------------------------|----------------------------------------------------------------------------------------------------------------------------------|
| 01/01/2024 đến 15/01/2024 | Khảo sát bài toán và các kiến thức liên quan.                                                                                    |
| 15/01/2024 đến 31/01/2024 | Đề xuất ý tưởng về các giải pháp giải quyết bài toán.                                                                            |
| 01/02/2024 đến 29/02/2024 | Tìm kiếm dữ liệu và các cơ sở tri thức phù hợp cho bài toán.                                                                     |
| 01/03/2024 đến 31/03/2024 | Xây dựng môi trường, framework, cài đặt thực nghiệm cho bài toán.                                                                |
| 01/04/2024 đến 15/04/2024 | Phân tích và đánh giá dựa trên các kết quả đạt được.                                                                             |
| 16/04/2024 đến 10/05/2024 | Viết 1 bài báo khoa học cho hội nghị hoặc tạp chí chuyên ngành trong nước và ngoài nước (mong muốn có kết quả trước khi bảo vệ). |
| 11/05/2024 đến 30/06/2024 | Viết báo cáo cho khóa luận tốt nghiệp.                                                                                           |




## Tài liệu

- [1] L. Doan, L. T. Nguyen, N. L. Tran, T. Hoang, and D. Q. Nguyen, “PhoMT: A High-Quality and Large-Scale Benchmark Dataset for Vietnamese-English Machine Translation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 4495–4503, 2021.
- [2] M. Ott, S. Edunov, A. Baevski, A. Fan, S. Gross, N. Ng, D. Grangier, and M. Auli, “fairseq: A fast, extensible toolkit for sequence modeling,” in *Proceedings of NAACL-HLT 2019: Demonstrations*, 2019.
- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [4] A. Joulin, E. Grave, P. Bojanowski, M. Nickel, and T. Mikolov, “Fast linear model for knowledge graph embeddings,” *arXiv preprint arXiv:1710.10881*, 2017.
- [5] X. Wang, T. Gao, Z. Zhu, Z. Zhang, Z. Liu, J. Li, and J. Tang, “Kepler: A unified model for knowledge embedding and pre-trained language representation,” *Transactions of the Association for Computational Linguistics*, vol. 9, pp. 176–194, 2021.

XÁC NHẬN  
CỦA NGƯỜI HƯỚNG DẪN  
(Ký và ghi rõ họ tên)

  
Nguyễn Hồng Bùi Lợi

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2024  
SINH VIÊN THỰC HIỆN  
(Ký và ghi rõ họ tên)

  
Võ Thành Phong

# Danh sách các từ viết tắt

| KÝ HIỆU    | TÊN TIẾNG ANH                                         |
|------------|-------------------------------------------------------|
| KG-Trans   | Knowledge Graph Transformer                           |
| KG-Trans-R | Knowledge Graph Transformer Replacing                 |
| EATT       | Entity-Aware Transformer Translation                  |
| EAEs       | Entity-Aware Embeddings                               |
| OOV        | Out Of Vocabulary                                     |
| BOW        | Bag of Words                                          |
| KG         | Knowledge Graph                                       |
| KB         | Knowledge Base                                        |
| KGEs       | Knowledge Graph Embeddings                            |
| IWSLT      | International Workshop on Spoken Language Translation |
| NLP        | Natural Language Processing                           |
| NER        | Named Entity Recognition                              |
| URL        | Uniform Resource Locator                              |
| URI        | Uniform Resource Identifier                           |
| BiCEL      | Bilingual Collective Entity Linking                   |
| NMT        | Neural Machine Translation                            |
| LOD        | Linked Open Data                                      |



# Mục lục

|                                                                                           |           |
|-------------------------------------------------------------------------------------------|-----------|
| Lời cảm ơn                                                                                | i         |
| Đề cương chi tiết                                                                         | ii        |
| Danh sách các từ viết tắt                                                                 | x         |
| Mục lục                                                                                   | xi        |
| Tóm tắt                                                                                   | xv        |
| <b>1 Tổng quan</b>                                                                        | <b>1</b>  |
| 1.1 Giới thiệu . . . . .                                                                  | 1         |
| 1.2 Mục đích nghiên cứu . . . . .                                                         | 2         |
| 1.3 Phạm vi nghiên cứu . . . . .                                                          | 3         |
| 1.4 Cấu trúc đề tài . . . . .                                                             | 4         |
| <b>2 Khảo sát các công trình nghiên cứu liên quan</b>                                     | <b>5</b>  |
| 2.1 Các mô hình chuỗi tuần tự . . . . .                                                   | 5         |
| 2.2 Các thuật toán nhúng đồ thị tri thức . . . . .                                        | 7         |
| 2.3 Nhận dạng thực thể trong dịch máy . . . . .                                           | 9         |
| 2.4 Hệ thống liên kết thực thể . . . . .                                                  | 9         |
| 2.5 Các nghiên cứu trước đây nỗ lực giải quyết các từ OOV và biểu diễn thực thể . . . . . | 11        |
| 2.5.1 Dịch máy mạng neural các từ hiếm với đơn vị từ phụ                                  | 11        |
| 2.5.2 Dịch máy sử dụng các công nghệ web giàu ngữ nghĩa                                   | 13        |
| 2.5.3 Tăng cường dịch máy mạng neural với KG đa ngữ .                                     | 14        |
| <b>3 Phương pháp</b>                                                                      | <b>17</b> |
| 3.1 Kiến trúc Transformer . . . . .                                                       | 17        |
| 3.1.1 Lớp nhúng và mã hóa vị trí . . . . .                                                | 19        |
| 3.1.2 Cơ chế tự chú ý của bộ mã hóa . . . . .                                             | 21        |

|          |                                                                                                            |           |
|----------|------------------------------------------------------------------------------------------------------------|-----------|
| 3.1.3    | Cơ chế tự chú ý đa đầu của bộ mã hóa (Multi-Head Self-Attention) . . . . .                                 | 24        |
| 3.1.4    | Bộ giải mã-Cơ chế tự chú ý đa đầu có mặt nạ . . . . .                                                      | 25        |
| 3.1.5    | Cơ chế chú ý chéo và lớp tuyến tính cuối cùng . . . . .                                                    | 26        |
| 3.2      | Thuật toán nhúng đồ thị tri thức Fast Linear . . . . .                                                     | 27        |
| 3.3      | Hệ thống liên kết thực thể . . . . .                                                                       | 31        |
| 3.4      | Các phương pháp mới được đề xuất nâng cao chất lượng dịch máy thông qua tích hợp đồ thị tri thức . . . . . | 32        |
| 3.4.1    | Nhóm các phương pháp đề xuất không làm thay đổi kiến trúc mô hình ban đầu . . . . .                        | 33        |
| 3.4.2    | Phương pháp EATT (Entity-Aware Transformer Translation) . . . . .                                          | 37        |
| <b>4</b> | <b>Cài đặt và thực nghiệm</b>                                                                              | <b>42</b> |
| 4.1      | Dữ liệu thực nghiệm . . . . .                                                                              | 42        |
| 4.2      | Cài đặt cấu hình . . . . .                                                                                 | 44        |
| 4.2.1    | Hệ thống liên kết thực thể . . . . .                                                                       | 44        |
| 4.2.2    | Nhúng đồ thị tri thức (KGEs) . . . . .                                                                     | 45        |
| 4.2.3    | Các phương pháp đề xuất . . . . .                                                                          | 45        |
| 4.3      | Kết quả thực nghiệm . . . . .                                                                              | 47        |
| 4.3.1    | Đánh giá dựa trên các độ đo đánh giá tự động . . . . .                                                     | 47        |
| 4.3.2    | Đánh giá độ tương đồng ngữ nghĩa sử dụng điểm SBERT . . . . .                                              | 49        |
| 4.3.3    | Đánh giá chất lượng dịch thực thể . . . . .                                                                | 51        |
| <b>5</b> | <b>Kết luận và hướng phát triển</b>                                                                        | <b>55</b> |
| 5.1      | Kết luận . . . . .                                                                                         | 55        |
| 5.2      | Hướng phát triển . . . . .                                                                                 | 56        |
|          | <b>Tài liệu tham khảo</b>                                                                                  | <b>57</b> |
| <b>A</b> | <b>Số liệu thống kê</b>                                                                                    | <b>61</b> |
| <b>B</b> | <b>Một số bản dịch đúng của các phương pháp đề xuất</b>                                                    | <b>63</b> |

# Danh sách hình

|      |                                                                                                                                                                                                                                                                                      |    |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1  | Mô hình chuỗi tuần tự với hàm tính toán được sử dụng là mô hình GRU. (Nguồn: <a href="https://phamdinhkhanh.github.io/2019/08/19/CorrectSpellingVietnamseTonePrediction.html">https://phamdinhkhanh.github.io/2019/08/19/CorrectSpellingVietnamseTonePrediction.html</a> ) . . . . . | 6  |
| 2.2  | Hệ thống liên kết thực thể đơn giản . . . . .                                                                                                                                                                                                                                        | 10 |
| 2.3  | Tổng quan về hai chiến lược tăng cường dịch máy mạng neural với KG đa ngữ (Nguồn: <a href="https://arxiv.org/pdf/1902.08816">https://arxiv.org/pdf/1902.08816</a> ) . . . . .                                                                                                        | 15 |
| 3.1  | Kiến trúc mô hình Transformer (Nguồn: <a href="https://arxiv.org/pdf/1706.03762">https://arxiv.org/pdf/1706.03762</a> ) . . . . .                                                                                                                                                    | 19 |
| 3.2  | Ví dụ về sự tự chú ý (Nguồn: <a href="https://pbcquoc.github.io/transformer/">https://pbcquoc.github.io/transformer/</a> ) . . . . .                                                                                                                                                 | 22 |
| 3.3  | Quá trình tính toán ma trận đầu ra của cơ chế tự chú ý . . . . .                                                                                                                                                                                                                     | 23 |
| 3.4  | Ví dụ đơn giản cho việc áp dụng mặt nạ lên chuỗi đầu vào của phía bộ giải mã . . . . .                                                                                                                                                                                               | 26 |
| 3.5  | Các thành phần trong cơ chế chú ý chéo . . . . .                                                                                                                                                                                                                                     | 27 |
| 3.6  | Ví dụ đơn giản minh họa đồ thị tri thức Wikidata5M . . . . .                                                                                                                                                                                                                         | 28 |
| 3.7  | Sinh mẫu dữ liệu huấn luyện cho mô hình Skip-gram . . . . .                                                                                                                                                                                                                          | 29 |
| 3.8  | Kiến trúc mạng Skip-gram . . . . .                                                                                                                                                                                                                                                   | 30 |
| 3.9  | Kiến trúc chung cho các phương pháp KG Transformer . . . . .                                                                                                                                                                                                                         | 36 |
| 3.10 | Sơ đồ tổng quan của phương pháp EATT (Entity-Aware Transformer Translation) với (a): Hệ thống liên kết thực thể, (b): Phương pháp EATT, (c): Cấu trúc chi tiết của Khối "Entity-Aware Attention" . . . . .                                                                           | 38 |
| 3.11 | Thành phần mạng Feed Forward trong Khối Chú ý nhận biết thực thể . . . . .                                                                                                                                                                                                           | 40 |
| 4.1  | Quá trình tính độ tương đồng ngữ nghĩa bằng mô hình BERT . . . . .                                                                                                                                                                                                                   | 50 |

|     |                                                                                                                                                         |    |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.2 | Quá trình tính độ tương đồng ngữ nghĩa bằng phương pháp SBERT (Nguồn: <a href="https://arxiv.org/pdf/1908.10084">https://arxiv.org/pdf/1908.10084</a> ) | 51 |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------|----|



# Danh sách bảng

|     |                                                                                                                                              |    |
|-----|----------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.1 | Số liệu thống kê về IWSLT EN-VI . . . . .                                                                                                    | 43 |
| 4.2 | Siêu tham số được sử dụng cho fastText . . . . .                                                                                             | 45 |
| 4.3 | Siêu tham số được sử dụng cho quá trình huấn luyện các phương pháp . . . . .                                                                 | 46 |
| 4.4 | Siêu tham số được sử dụng cho khối chú ý nhận biết thực thể                                                                                  | 46 |
| 4.5 | Kết quả thực nghiệm dựa trên các độ đo đánh giá tự động (kết quả tốt nhất được in đậm). . . . .                                              | 49 |
| 4.6 | Kết quả thực nghiệm trên tập dữ liệu Anh-Việt dựa trên sự tương đồng về mặt ngữ nghĩa sử dụng SBERT (kết quả tốt nhất được in đậm) . . . . . | 51 |
| 4.7 | So sánh chất lượng bản dịch giữa mô hình Transformer và các phương pháp đề xuất. . . . .                                                     | 52 |
| 4.8 | Chất lượng bản dịch trên các loại thực thể: PER, LOC, ORG, và MISC của ba phương pháp đề xuất và mô hình cơ sở                               | 52 |
| A.1 | Số liệu thống kê về Wikidata5M . . . . .                                                                                                     | 61 |
| A.2 | Số liệu thống kê về IWSLT EN-DE . . . . .                                                                                                    | 61 |
| A.3 | Số liệu thống kê về IWSLT EN-FR . . . . .                                                                                                    | 62 |
| A.4 | Số liệu thống kê về IWSLT EN-RO . . . . .                                                                                                    | 62 |
| B.1 | Ví dụ 1 . . . . .                                                                                                                            | 63 |
| B.2 | Ví dụ 2 . . . . .                                                                                                                            | 63 |
| B.3 | Ví dụ 3 . . . . .                                                                                                                            | 64 |
| B.4 | Ví dụ 4 . . . . .                                                                                                                            | 64 |

# Tóm tắt

Các công nghệ dịch thuật tự động đang ngày càng phát triển mạnh mẽ, mà cốt lõi của quá trình dịch thuật này chính là dựa trên sức mạnh của các mô hình học sâu. Nổi bật là mô hình Transformer, mô hình này ra mắt từ năm 2017 đến nay đã chứng minh được sức mạnh của mình trong tác vụ dịch máy. Tuy nhiên, vẫn còn những thách thức đáng kể, trong đó việc hiểu và chuyển đổi ngữ nghĩa một cách chính xác giữa các ngôn ngữ vẫn là một vấn đề nổi bật. Các thực thể xuất hiện trong câu, đặc biệt là các thực thể không được xác định chính xác, là một trong những nguyên nhân dẫn đến sự thiếu hiệu quả này. Để giải quyết vấn đề này, đề tài nghiên cứu việc tích hợp đồ thị tri thức (KG) vào mô hình Transformer để tạo ra các bản dịch chính xác hơn cho các thực thể, từ đó nâng cao chất lượng tổng thể của các bản dịch trong quá trình dịch máy. Cụ thể, chúng tôi đề xuất ba phương pháp như sau:

KG-Trans: Phương pháp đầu tiên thực hiện việc nối các véc-tơ biểu diễn cho các thực thể trong KG vào các nội véc-tơ (internal vectors) tương ứng được tạo ra trong kiến trúc Transformer.

KG-Trans-R: Phương pháp này là quá trình thay thế trực tiếp các nội véc-tơ của các thực thể bởi chính các véc-tơ tương ứng trong KG.

EATT: Phương pháp cuối cùng thực hiện cơ chế chú ý chéo (cross-attention) giữa các câu đầu vào (mà trong đó mỗi token đã được mã hóa thành các véc-tơ số) và các véc-tơ biểu diễn cho các thực thể trong KG.

Nghiên cứu tập trung cải thiện trên cặp ngôn ngữ Anh-Việt (En-Vi) và các phương pháp được đề xuất đã đạt được kết quả khả quan trên bộ dữ liệu IWSLT cho cặp ngôn ngữ này. Ngoài ra, chúng tôi còn mở rộng thực nghiệm trên các bộ dữ liệu cho ba cặp ngôn ngữ khác của IWSLT là Anh-Đức (En-De), Anh-Pháp (En-Fr), và Anh-Romanian (En-Ro). Các độ đo được chọn cho việc đánh giá gồm: BLEU, TER, GLEU, và SBERT.

# Chương 1

# Tổng quan

## 1.1 Giới thiệu

Ngày nay, các công nghệ dịch thuật tự động ngày càng được sử dụng phổ biến, qua đó giúp việc giao tiếp trên toàn cầu trở nên thuận lợi hơn bao giờ hết. Yếu tố chính giúp quá trình dịch thuật đạt được những tiến bộ vượt bậc như vậy chính là nhờ vào sức mạnh của các mô hình học sâu và các cơ chế tính toán bên trong chúng. Cơ chế tự chú ý (self-attention) được giới thiệu trong mô hình Transformer [26] đã làm thay đổi cách tiếp cận trong nhiều ứng dụng của lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP), đặc biệt là trong lĩnh vực dịch máy. Điều này mở ra cánh cửa cho những tiến bộ đáng kể trong lĩnh vực NLP sau này. Cơ chế tự chú ý cho phép mô hình xử lý một cách đồng thời tất cả các token trong câu, và đồng thời chú ý vào các thành phần khác trong câu, từ đó làm cho hiệu suất dịch máy được cải tiến một cách đáng kể. Mặc dù Transformer đã đạt được những thành công ấn tượng, nhưng vẫn còn một số thách thức cần được vượt qua, đặc biệt là vấn đề hiểu và phát sinh ngữ nghĩa chính xác trong ngôn ngữ. Một trong những khó khăn lớn nhất là xử lý các thực thể (entity) xuất hiện trong câu, đặc biệt là các thực thể khó xác định chính xác trong tập dữ liệu. Ví dụ, khi dịch câu "Lionel Messi is on fire now" từ tiếng Anh sang tiếng Việt, việc hiểu rằng Lionel Messi là một cầu thủ bóng đá là quan trọng để tạo ra một bản dịch giàu sắc thái như là "Lionel Messi đang thi đấu rất hay".

Những thách thức về các thực thể trong dữ liệu đầu vào đã được quan tâm ngay cả trước khi mô hình Transformer được công bố, tuy nhiên các nỗ lực nhằm giải quyết những khó khăn về các thực thể trước đây tập trung nhiều vào các lĩnh vực khác của NLP như Machine Reading [29] hay Question Answering [23]. Do đó, đề tài này tập trung nghiên cứu việc tích

hợp đồ thị tri thức (KG) vào mô hình Transformer để tạo ra các bản dịch chính xác hơn cho các thực thể, từ đó nâng cao chất lượng tổng thể của các bản dịch trong quá trình dịch máy. KG là một biểu diễn dạng đồ thị của cơ sở tri thức (KB), KB là một cơ sở dữ liệu lớn lưu trữ thông tin về các thành phần của một hoặc nhiều lĩnh vực trong thế giới thực và các mối quan hệ giữa các thành phần đó. Chúng tôi đề xuất các phương pháp tập trung vào việc biểu diễn các thông tin trong một KG, sau đó kết hợp những thông tin này cùng với các nội véc-tơ được tạo ra trong mô hình Transformer bằng nhiều cách khác nhau như phép nối, phép thế, cơ chế chú ý chéo. Việc kết hợp này nhằm kiểm tra sự hiệu quả của việc tạo ra các bản dịch cho các thực thể ngay sau khi đã có thông tin của chúng từ một đồ thị tri thức.

## 1.2 Mục đích nghiên cứu

Những tác vụ khác trong lĩnh vực NLP thường sử dụng kết quả từ đồ thị tri thức (KG) theo dạng truy vấn trực tiếp tên của thực thể hoặc tên của quan hệ, chẳng hạn trong tác vụ Hỏi đáp (Question answering), việc truy vấn vào KG thường trả về kết quả là một tên thực thể rõ ràng nhằm giúp trả lời thành công cho câu hỏi đầu vào. Tuy nhiên, đối với tác vụ dịch máy lại yêu cầu một cách biểu diễn khác cho thông tin của các thực thể, các thông tin này từ đồ thị tri thức được sử dụng vào mô hình dịch máy cần chú trọng vào yếu tố ngữ nghĩa và chính điều này yêu cầu một quá trình mã hóa cụ thể và thật sự hiệu quả từ dạng dữ liệu thô có cấu trúc sang dạng véc-tơ trong không gian đa chiều. Bên cạnh đó, việc tìm ra một KG vừa có tính mới vừa có tính bao quát về mặt dữ liệu là tốn nhiều công sức, trong thực tế việc tìm kiếm một KG phù hợp phải xem xét rất nhiều yếu tố chẳng hạn như: Kích thước của KG (đề cập đến hai yếu tố: số lượng thực thể và số lượng quan hệ tồn tại trong KG đó), KG hỗ trợ đơn ngữ hay đa ngữ, và một khía cạnh rất quan trọng đã được đề cập trước đó chính là việc ứng dụng thật sự hiệu quả các thông tin từ KG còn phụ thuộc vào việc chuyển đổi thông tin trong KG vào không gian véc-tơ một cách chính xác. Do đó đề tài không những là việc nghiên cứu việc tích hợp tri thức vào mô hình dịch máy như thế nào sao cho đạt được hiệu quả

tốt nhất mà còn là việc khảo sát nhiều KG khác nhau và nghiên cứu thuật toán nhúng đồ thị tri thức (KGEs) nhằm biểu diễn tri thức một cách đủ tốt vào không gian véc-tơ hay nói cách khác là nhúng một KG thành dạng véc-tơ trước khi được trích xuất làm thông tin cho quá trình dịch máy.

### 1.3 Phạm vi nghiên cứu

Nội dung nghiên cứu chính: Phân tích sự ảnh hưởng của đồ thị tri thức (KG) đến chất lượng mô hình dịch máy mà cụ thể là mô hình Transformer. Các thực thể được trích xuất từ văn bản nguồn và ánh xạ chúng vào một KG có sẵn, tiếp theo đó thông tin về các thực thể từ KG được tích hợp trực tiếp vào mô hình Transformer giúp tạo ra các bản dịch không chỉ chính xác hơn mà còn phong phú về mặt ngữ nghĩa. Điều này đặc biệt quan trọng đối với các cặp ngôn ngữ có khác biệt lớn về mặt cấu trúc ngữ pháp, cụ thể là cặp ngôn ngữ Anh-Việt, sự tích hợp của KG giúp cải thiện đáng kể sự hiểu biết về nghĩa của thực thể trong toàn bộ câu qua đó nâng cao chất lượng cả về nghĩa lẫn ngữ pháp cho bản dịch.

Đối tượng nghiên cứu chính:

- Thuật toán nhúng đồ thị tri thức Fast Linear: Đây là thuật toán nhúng đồ thị tri thức lấy ý tưởng tương tự BOW trong việc thực hiện nhúng từ (word embeddings).
- Cơ sở tri thức Wikidata5M: Xây dựng từ Wikidata do Wikimedia Foundation phát triển, Wikidata5M được thiết kế để hỗ trợ các nhiệm vụ liên quan đến hiểu biết và suy luận dựa trên tri thức.
- IWSLT En-Vi: Tập dữ liệu bao gồm các cặp câu dịch từ ngôn ngữ Anh sang ngôn ngữ Việt được tập hợp từ nhiều nguồn như: báo chí, các bài nói chuyện trên trang TED Talks, các bản ghi và phụ đề công khai thuộc nhiều lĩnh vực do các diễn giả trên TED Talks cung cấp.
- Mô hình Transformer được sử dụng cho tác vụ dịch máy.



## 1.4 Cấu trúc đề tài

Báo cáo này sẽ được chia thành 5 chương chính bao gồm:

- Chương 1 – Tổng quan: Giới thiệu về đề tài nghiên cứu bao gồm ngữ cảnh của đề tài, lý do chọn đề tài. Trình bày về mục đích nghiên cứu và phạm vi nghiên cứu của đề tài.
- Chương 2 – Khảo sát các công trình nghiên cứu liên quan đến đề tài đang nghiên cứu hiện tại, bao gồm: các mô hình chuỗi tuần tự (sequence to sequence models), các thuật toán nhúng đồ thị tri thức (KGEs algorithms), nhận dạng thực thể trong dịch máy (NER in machine translation), hệ thống liên kết thực thể (Entity Linking System), và các nghiên cứu trước đây đã nỗ lực giải quyết vấn đề về các từ OOV và biểu diễn thực thể trong tác vụ dịch máy.
- Chương 3 – Phương pháp: Trình bày chi tiết về cơ sở lý thuyết và kiến trúc của ba phương pháp được đề xuất. Chương này trình bày toàn bộ nội dung chính cho đề tài nghiên cứu, giúp người đọc hiểu rõ hơn về các phương pháp nâng cao chất lượng dịch máy bằng cách tích hợp đồ thị tri thức.
- Chương 4 – Cài đặt và thực nghiệm: Chương này tập trung mô tả về dữ liệu thực nghiệm được sử dụng, cách cài đặt và cấu hình thực tế cho các phương pháp đề xuất, và phân tích kết quả thực nghiệm đạt được.
- Chương 5 – Kết luận và hướng phát triển: Tổng kết các kết quả mà đề tài nghiên cứu đạt được, nhấn mạnh các đóng góp của nghiên cứu và đề xuất hướng phát triển cho chủ đề nâng cao chất lượng dịch máy thông qua tích hợp đồ thị tri thức.

## Chương 2

# Khảo sát các công trình nghiên cứu liên quan


### 2.1 Các mô hình chuỗi tuần tự

Mô hình chuỗi tuần tự (Sequence to Sequence model) [24] được Sutskever và cộng sự giới thiệu năm 2014, là một trong những tiếp cận phổ biến nhất trong dịch máy sử dụng mạng neural. Mô hình này bao gồm một mạng neural mã hóa (encoder) để biểu diễn câu nguồn thành một véc-tơ ngữ cảnh, và một mạng neural giải mã (decoder) để sinh ra câu đích từ véc-tơ ngữ cảnh đó. Encoder nhận đầu vào là chuỗi từ trong câu nguồn và biểu diễn chúng thành một véc-tơ ngữ cảnh. Quá trình này có thể thực hiện bằng cách sử dụng mạng RNN (Recurrent Neural Networks) và các biến thể của chúng như LSTM (Long-Short Term Memory) [5] hoặc GRU (Gated Recurrent Unit) [3], hoặc bằng cách sử dụng mạng Transformer [26]. Decoder nhận véc-tơ ngữ cảnh từ mạng mã hóa và sử dụng chúng để sinh ra chuỗi đầu ra. Quá trình này cũng có thể thực hiện bằng cách sử dụng các mạng RNN hoặc Transformer. Mỗi từ trong chuỗi đầu ra được sinh ra một cách tuần tự, với mỗi từ dựa trên từ trước đó trong chuỗi và véc-tơ ngữ cảnh (Hình. 2.1). Mô tả về mặt toán học như sau:

Đối với mạng mã hóa encoder: Nhận đầu vào là một chuỗi các ký tự hoặc từ  $(x_1, x_2, \dots, x_T)$  và biến đổi chúng thành một véc-tơ ngữ cảnh  $h$ :

- Lớp nhúng (Embedding Layer): Chuỗi đầu vào được nhúng vào một không gian liên tục, chức năng chính của lớp này là ánh xạ các từ hoặc ký tự trong văn bản đầu vào thành các vectơ số học trong một không gian liên tục:

$$e_t = \text{Embedding}(x_t) \quad (2.1)$$



Hình 2.1: Mô hình chuỗi tuần tự với hàm tính toán được sử dụng là mô hình GRU. (Nguồn: <https://phamdinhhkhanh.github.io/2019/08/19/CorrectSpellingVietnamseTonePrediction.html>)

- Lớp ẩn (Hidden Layer): Các véc-tơ nhúng được đưa qua lớp ẩn để tạo ra các trạng thái ẩn  $h_t$ . Có thể có nhiều lớp ẩn xếp chồng lên nhau và đầu ra của lớp phía trước sẽ đóng vai trò là đầu vào cho lớp ẩn kế tiếp, ngoài ra hàm tính toán  $f$  ở mỗi lớp có thể là đơn vị RNN cơ bản, LSTM, hoặc GRU:

$$h_t = f(e_t, h_{t-1}) \quad (2.2)$$

- Véc-tơ ngữ cảnh: Trạng thái ẩn cuối cùng của mạng mã hóa thường được sử dụng làm véc-tơ ngữ cảnh:

$$h = h_T \quad (2.3)$$

Đối với mạng giải mã decoder: Nhận véc-tơ ngữ cảnh  $h$  từ bộ mã hóa và từng bước tạo ra chuỗi đầu ra  $(y_1, y_2, \dots, y_{T'})$ :

- Trạng thái ẩn ban đầu của mạng giải mã thường được khởi tạo bằng véc-tơ ngữ cảnh từ mạng mã hóa:

$$s_0 = h \quad (2.4)$$

- Lớp nhúng: Chuỗi đầu ra trước đó được nhúng vào một không gian liên tục:

$$d_t = \text{Embedding}(y_{t-1}) \quad (2.5)$$

- Các véc-tơ nhúng cùng với trạng thái ẩn hiện tại được đưa qua lớp ẩn để tạo ra các trạng thái ẩn mới. Có thể có nhiều lớp ẩn xếp chồng lên nhau và đầu ra của lớp phía trước sẽ đóng vai trò là đầu vào cho lớp ẩn kế tiếp, ngoài ra hàm tính toán  $g$  ở mỗi lớp có thể là đơn vị RNN cơ bản, LSTM, hoặc GRU:

$$s_t = g(d_t, s_{t-1}) \quad (2.6)$$

- Lớp đầu ra (Output Layer): Trạng thái ẩn của mạng giải mã được biến đổi thành xác suất của các từ đầu ra qua một lớp softmax, trong đó  $W$  và  $b$  là các tham số cần học của mô hình:

$$o_t = \text{softmax}(W s_t + b) \quad (2.7)$$

- Chọn từ có xác suất cao nhất làm đầu ra tại mỗi thời điểm:

$$y_t = \text{argmax}(o_t) \quad (2.8)$$

## 2.2 Các thuật toán nhúng đồ thị tri thức

Nhúng đồ thị tri thức (KGEs) là quá trình biểu diễn các thực thể và mối quan hệ trong đồ thị tri thức (KG) dưới dạng các véc-tơ trong không gian nhiều chiều. KG là một biểu đồ có hướng được sử dụng để biểu diễn tri thức trong các hệ thống máy tính. Trong một KG, các thực thể được đại diện bằng các nút, các mối quan hệ giữa chúng được đại diện bằng các cạnh, và hai thực thể có liên quan với nhau thông qua một mối quan hệ được gọi là một bộ ba (triplet) hợp lệ. Việc biểu diễn một KG dưới dạng các vector giúp phản ánh được sự tương quan giữa các thực thể. Một số thuật toán đáng chú ý bao gồm:

- TransE [2] là một trong những thuật toán nhúng đồ thị tri thức đầu tiên. Giả định rằng mối quan hệ giữa hai thực thể được biểu diễn bằng một phép biến đổi tuyến tính từ thực thể đầu vào đến thực thể đầu ra. TransE đã đạt được kết quả tốt trong việc dự đoán quan hệ nhưng vẫn còn một số hạn chế sau đây: khó khăn trong việc xử lý

quan hệ đa hướng và quan hệ phức tạp, hạn chế về biểu diễn không gian. Xem xét về mặt toán học: gọi  $S$  là tập hợp tất cả các bộ ba hợp lệ,  $S'$  là tập hợp tất cả các bộ ba không hợp lệ,  $d$  là công thức tính khoảng cách có thể là Euclidean hoặc Manhattan,  $\gamma$  là siêu tham số của mô hình, hàm mất mát TransE được định nghĩa như sau:

$$L = \sum_{(h,r,t) \in S} \sum_{(h',r,t') \in S'} [\gamma + d(h+r, t) - d(h'+r, t')]_+ \quad (2.9)$$

- TransR [10] là một bước tiến lớn từ TransE. TransR giải quyết vấn đề của TransE bằng cách ánh xạ mỗi thực thể và mỗi quan hệ vào không gian con (subspace) của không gian véc-tơ, điều này cho phép TransR xử lý các quan hệ đa hướng và phức tạp một cách hiệu quả. Cụ thể hơn, mỗi thực thể trong KG được nhúng vào một không gian nhúng thực thể. Tuy nhiên, khi tham gia vào một quan hệ, thực thể cần được chuyển đổi sang một không gian nhúng khác phù hợp với quan hệ đó, do đó khi thực hiện thuật toán TransR người ta thường xây dựng thêm một ma trận đặc biệt  $M_r$  để thực hiện phép chuyển đổi này.  $M_r$  giúp điều chỉnh vectơ nhúng của thực thể để phù hợp với không gian nhúng của quan hệ  $r$ . Dù đã có cải tiến nhưng TransR vẫn còn vướng phải vấn đề biểu diễn không gian mà TransE để lại. Hàm mất mát TransR về cơ bản tương tự như TransE nhưng khác về hàm tính khoảng cách, hàm tính khoảng cách bây giờ được định nghĩa dựa trên công thức Euclidean như sau:

$$d(h, r, t) = \|M_r h + r - M_r t\|_2 \quad (2.10)$$

- TransD [7] mở rộng TransR bằng cách ánh xạ mỗi cặp thực thể và mỗi quan hệ vào không gian véc-tơ khác nhau. Điều này giúp TransD mô hình hóa mỗi quan hệ giữa các thực thể dựa trên bối cảnh của mỗi quan hệ đó, đẩy mức độ hiệu suất của thuật toán lên một tầm cao mới. Tuy nhiên, TransD có rất nhiều tham số làm cho việc huấn luyện mô hình rất khó tiếp cận do đòi hỏi khá nhiều tài nguyên, ngoài ra số lượng tham số quá lớn còn làm cho TransD có rủi ro cao

về tính quá khớp (overfitting). Hàm mất mát TransD được xây dựng tương tự TransR nhưng ma trận chuyển  $M$  được tính toán với một công thức phức tạp hơn nhiều so với TransR.

- ComplEx [25] là một mô hình phức tạp nhưng mạnh mẽ. ComplEx mô hình hóa các mối quan hệ bằng cách sử dụng số phức, cho phép việc biểu diễn các quan hệ đa hướng và phức tạp một cách linh hoạt và chính xác. Tuy nhiên việc huấn luyện ComplEx cũng cần một lượng tài nguyên đáng kể và để cho ComplEx đạt hiệu quả cao thì cần phải có một lượng dữ liệu huấn luyện đủ lớn.

Trong đề tài nghiên cứu này, chúng tôi sử dụng một thuật toán nhúng đồ thị tri thức có tên là Fast Linear [8] trong việc xây dựng KGEs cho KG của chúng tôi.


## 2.3 Nhận dạng thực thể trong dịch máy

Nhận dạng thực thể (NER) là một bước quan trọng trong xử lý ngôn ngữ tự nhiên, nhằm xác định và phân loại các thực thể có tên trong văn bản. Trong dịch máy có nhiều kỹ thuật được áp dụng để thực hiện NER như các bộ quy tắc, các mô hình máy học, các mô hình học sâu, .... Vào năm 2017, một nghiên cứu [28] sử dụng công cụ NER để trích xuất các cặp thực thể tương ứng giữa các câu văn bản trong ngôn ngữ nguồn và ngôn ngữ đích cho các bộ dữ liệu dịch máy. Sau khi các cặp thực thể được phát hiện, chúng sẽ được thay thế bằng thẻ của chính chúng để bước vào giai đoạn huấn luyện mô hình. Đến năm 2018, một phương pháp mới [9] cải tiến hơn so với việc thay thế các thực thể bằng thẻ bằng cách bổ sung luôn thông tin về loại thẻ của thực thể vào chính thực thể đó trước khi bước vào giai đoạn huấn luyện mô hình.

## 2.4 Hệ thống liên kết thực thể

Hệ thống liên kết thực thể (Entity Linking System) là một phần quan trọng của xử lý ngôn ngữ tự nhiên, nhằm mục đích liên kết các thực thể trong văn bản đến các đầu vào (entries) tương ứng trong một KG hoặc bộ





Hình 2.2: Hệ thống liên kết thực thể đơn giản

từ điển. Kiến trúc của một hệ thống liên kết thực thể có thể khác nhau tùy theo tác vụ và cách cài đặt hệ thống, nhưng nhìn chung một hệ thống liên kết thực thể sẽ bao gồm hai thành phần quan trọng đó chính là mô-đun nhận dạng thực thể (NER module) và mô-đun điều hướng thực thể (Entity Disambiguation module) (Hình. 2.2). Mô-đun nhận dạng thực thể sử dụng các mô hình học máy và học sâu như BiLSTM-CRF [12], BERT [4], RoBERTa [11], ... để nhận dạng thực thể trong văn bản bằng cách gán nhãn thể theo một số chuẩn đã được quy ước chẳng hạn như BIO, BILOU, .... Mô-đun điều hướng thực thể có vai trò xác định chính xác đầu vào (entry) tương ứng trong KG của mỗi thực thể trong văn bản nguồn sau khi đã được nhận dạng, ngoài ra khi có nhiều thực thể tiềm năng gần giống nhau thì việc điều hướng đến thực thể tương ứng chính xác nhất trong KG cũng là một vai trò quan trọng của mô-đun điều hướng nhằm giảm bớt sự mơ hồ của các thực thể. Có nhiều kỹ thuật khác nhau để cài đặt mô-đun điều hướng thực thể, ví dụ như so khớp chuỗi tuyệt đối, đánh dấu bằng các ID đặc biệt, hoặc liên kết bằng các liên kết url (url links).

Một vài nghiên cứu nổi bật trước đây về chủ đề xây dựng hệ thống liên kết thực thể:

- Spotlight system [13]: Hệ thống này sử dụng các nguồn tri thức lớn như DBpedia và Freebase để liên kết các thực thể trong văn bản với các đầu vào tương ứng trong KG.
- AIDA system [6]: Là một hệ thống liên kết thực thể được thiết kế

để hoạt động trên các đoạn văn bản dài và phức tạp.

- Đặc biệt là hệ thống do Moussallem đề xuất vào năm 2017 [16]: Là một hệ thống liên kết thực thể hỗ trợ ngữ liệu song ngữ, được tác giả gọi là BiCEL, hệ thống này nhằm mục đích tăng cường khả năng xử lý ngôn ngữ tự nhiên trong các môi trường đa ngôn ngữ. Hệ thống BiCEL nhận diện và liên kết các thực thể trong văn bản bằng cách sử dụng một bộ phân loại dựa trên học máy, như SVM hoặc CRF, kết hợp với việc xây dựng một KG song ngữ. Sau đó, thông tin từ cả hai ngôn ngữ được sử dụng để xác định các thực thể chung và liên kết chúng với các đầu vào tương ứng trong KG.

## **2.5 Các nghiên cứu trước đây nỗ lực giải quyết các từ OOV và biểu diễn thực thể**

Những thách thức về các từ OOV cũng như biểu diễn cho các thực thể trong dữ liệu đầu vào đã được quan tâm ngay cả trước khi mô hình Transformer được công bố, dưới đây là các nghiên cứu đã nỗ lực để giải quyết các vấn đề trên:

### **2.5.1 Dịch máy mạng neural các từ hiếm với đơn vị từ phụ**

Được Sennrich và Haddow [21] giới thiệu vào năm 2016, những đóng góp của công trình nghiên cứu này bao gồm:

- Chỉ ra rằng việc dịch máy mạng neural (NMT) là khả thi bằng cách mã hóa những từ hiếm gặp thành các đơn vị từ con nhỏ hơn, ngoài ra việc áp dụng các đơn vị nhỏ hơn của từ làm cho kiến trúc trở nên đơn giản hơn cũng như chất lượng dịch hiệu quả hơn khi áp dụng các phương pháp NMT truyền thống khác với một từ điển lớn hoặc có thêm một từ điển dự phòng.
- Nghiên cứu áp dụng thành công một thuật toán nén có tên là Byte-Pair Encoding được công bố năm 1994 để phân đoạn các từ thành các đơn vị biểu diễn nhỏ hơn. Thuật toán này cho phép biểu diễn một từ điển mở thành một từ điển có kích thước cố định gồm các

---

**Algorithm 1** Thuật toán học BPE

---

```
1: function GET_STATS(vocab)
2:   pairs = collections.defaultdict(int)
3:   for word, freq in vocab.items() do
4:     symbols = word.split()
5:     for i in range(len(symbols) - 1) do
6:       pairs[symbols[i], symbols[i+1]] += freq
7:   return pairs

8: function MERGE_VOCAB(pair, v_in)
9:   v_out = {}
10:  bigram = re.escape(' '.join(pair))
11:  p = re.compile(r'(?<\S)' + bigram + r'(!\S)')
12:  for word in v_in do
13:    w_out = p.sub("".join(pair), word)
14:    v_out[w_out] = v_in[word]
15:  return v_out
```

---

chuỗi ký tự có độ dài thay đổi. Nghĩa là thay vì phải lưu trữ tất cả các từ hoàn chỉnh trong từ điển, tác giả chỉ cần lưu trữ các chuỗi ký tự nhỏ (subwords) mà từ đó có thể tạo ra các từ hoàn chỉnh.

Cụ thể, thuật toán Byte-Pair Encoding hoạt động như sau: Đầu tiên, khởi tạo một từ điển ở mức các ký tự (characters), nghĩa là mỗi ký tự trong ngôn ngữ đều là một ký hiệu ban đầu trong từ vựng. Sau đó, mỗi từ được biểu diễn dưới dạng một chuỗi các ký tự kèm theo một ký hiệu kết thúc đặc biệt. Tiếp đến, đếm tất cả các cặp ký hiệu xuất hiện trong từ điển, thay thế mỗi lần xuất hiện của cặp ký hiệu phổ biến nhất bằng một ký hiệu mới, là sự kết hợp của hai ký hiệu đó. Ví dụ, nếu cặp ('A', 'B') là phổ biến nhất, chúng sẽ được thay thế bằng ký hiệu mới 'AB'. Mỗi lần hợp nhất tạo ra một ký hiệu mới đại diện cho một chuỗi ký tự n-gram. Ví dụ, nếu chúng ta kết hợp ký hiệu 'A' và 'B' để tạo thành 'AB', thì 'AB' trở thành một ký hiệu mới trong từ vựng. Cứ như vậy, các chuỗi ký tự n-grams hoặc toàn bộ từ xuất hiện thường xuyên cuối cùng sẽ được hợp nhất thành một ký hiệu duy nhất. Thuật toán 1 minh họa ví dụ hoạt động của thuật toán từ bộ từ điển đơn giản là dictionary = 'low', 'lowest', 'newer', 'wider', từ 'lower' không có trong từ điển ban đầu sẽ được phân

đoạn thành 'low er' trong bộ từ điển mới sau khi thuật toán hoàn thành.

### 2.5.2 Dịch máy sử dụng các công nghệ web giàu ngữ nghĩa

Nghiên cứu được thực hiện bởi Moussallem và cộng sự [14] vào năm 2018, nhiều kết quả đã được rút ra từ nghiên cứu này như sau:

- Nghiên cứu cung cấp một khảo sát toàn diện về việc sử dụng công nghệ Web ngữ nghĩa hiện đại trong lĩnh vực dịch máy.
- Phân loại nhiều phương pháp tiếp cận khác nhau, mỗi loại phương pháp đều được phân tích về cách thức tích hợp các công nghệ Web ngữ nghĩa để cải thiện hiệu suất và độ chính xác của dịch máy.

Các phương pháp chính được giới thiệu trong nghiên cứu bao gồm:

- Sử dụng Ontologies trong dịch máy: Một Ontology là một mô hình ngữ nghĩa mô tả các thực thể, khái niệm và các mối quan hệ giữa chúng trong một miền tri thức cụ thể. Ontologies thường được biểu diễn bằng ngôn ngữ OWL (Web Ontology Language) và có thể bao gồm các định nghĩa chính thức, phân loại, và các quy tắc logic. Ontologies cung cấp một cơ sở ngữ nghĩa phong phú giúp mô hình dịch máy hiểu rõ hơn về ngữ cảnh và ý nghĩa của từ ngữ. Điều này giúp giải quyết vấn đề đa nghĩa (polysemy) và tương đồng ngữ nghĩa (synonymy). Ví dụ: Từ "bank" có thể có nghĩa là "ngân hàng" hoặc "bờ sông". Một Ontology có thể cung cấp ngữ cảnh để phân biệt giữa các nghĩa khác nhau này dựa trên thông tin ngữ cảnh như các thực thể liên quan hoặc hành động liên quan, nếu ngữ cảnh nói về tài chính, "bank" sẽ được dịch là "ngân hàng".
- Liên kết Dữ liệu Mở (LOD): LOD là một tập hợp các thực tiễn để xuất bản và liên kết dữ liệu theo cách có cấu trúc trên web, sử dụng các chuẩn như RDF (Resource Description Framework) và URIs (Uniform Resource Identifiers). Khi dịch một văn bản đề cập đến một nhân vật lịch sử cụ thể, mô hình dịch máy có thể truy cập LOD để lấy thông tin chi tiết về nhân vật này từ các nguồn dữ liệu liên kết như DBpedia hoặc Wikidata. LOD có thể được sử dụng để

cung cấp ngữ cảnh bổ sung và thông tin chi tiết về các thực thể trong văn bản, giúp mô hình dịch máy đưa ra các bản dịch chính xác và có ý nghĩa hơn.


- Sử dụng SPARQL: SPARQL là một ngôn ngữ truy vấn được thiết kế đặc biệt cho việc truy vấn tên hoặc các thuộc tính có liên quan của một thực thể trong các cơ sở dữ liệu, các biểu đồ quan hệ chứa các bộ ba(triplet), hoặc cơ sở tri thức (KB), đặc biệt là các cơ sở tri thức lớn được biểu diễn bằng một siêu đồ thị, chẳng hạn như DBpedia, Wikipedia, hay Wikidata.

### 2.5.3 Tăng cường dịch máy mạng neural với KG đa ngữ

Trong chủ đề sử dụng đồ thị tri thức (KG) để tăng cường chất lượng cho mô hình dịch máy mạng neural thì nghiên cứu của Moussallem và cộng sự [15] công bố năm 2019 đã đạt được những kết quả đáng chú ý cho tác vụ dịch máy trên cặp ngôn ngữ Anh-Đức, những đóng góp chính của nghiên cứu bao gồm:

- Nghiên cứu đề xuất hai chiến lược khác nhau nhằm tích hợp KG vào trong mô hình mạng neural với mục đích tăng cường chất lượng bản dịch mà không làm thay đổi kiến trúc mạng (Hình. 2.3).
- Các chiến lược đạt kết quả cao hơn mô hình RNN truyền thống trên tập dữ liệu WLT English-German từ 2014 đến 2018 thông qua ba độ đo là BLEU [18], METEOR [1], chrF3 [19].

Công trình nghiên cứu sử dụng cơ sở tri thức (KB) là DBpedia, một KB được thiết kế để chuyển đổi dữ liệu phi cấu trúc từ Wikipedia thành dữ liệu có cấu trúc có thể được truy vấn và liên kết với các tập dữ liệu khác trên Web ngữ nghĩa. Cách thức hoạt động của DBpedia như sau: DBpedia trích xuất thông tin từ các hộp thông tin (infoboxes) của Wikipedia, cùng với các phần khác như danh sách, bản mẫu, và các đoạn văn bản để tạo ra các bản ghi dữ liệu có cấu trúc. Thông tin trích xuất được chuyển đổi thành định dạng RDF (Resource Description Framework), cho phép dễ dàng tích hợp và liên kết với các nguồn dữ liệu khác trên Web



Hình 2.3: Tổng quan về hai chiến lược tăng cường dịch máy mạng neural với KG đa ngữ (Nguồn: <https://arxiv.org/pdf/1902.08816>)

ngữ nghĩa. Cũng giống như đa số các cơ sở tri thức khác, một bộ ba (triplet) trong DBpedia gồm có ba thành phần là một chủ thể (subject), một quan hệ (relation), và một đối tượng (object), và chúng đều được lưu dưới dạng RDF. Một ví dụ về triplet liên quan đến thực thể Barack Obama có thể là:  $\langle \text{http://dbpedia.org/resource/BarackObama} \rangle$   $\langle \text{http://dbpedia.org/ontology/birthDate} \rangle$  "1961-08-04"xsd:date.

Trong chiến lược đào tạo đầu tiên, nhóm tác giả liên kết các thực thể được đặt tên trong văn bản nguồn và văn bản đích với một cơ sở tri thức đa ngữ tham chiếu bằng cách sử dụng hệ thống Định danh thực thể đa ngôn ngữ có sẵn. Sau đó, tác giả thêm các liên kết URI của các thực thể cùng với các token của thực thể tương ứng đó trong câu. Ví dụ, từ "Kiwi" có thể được chú thích là "Kiwi|dbr\_Kiwi" hoặc "dbr\_Kiwi\_(people)" tùy vào ngữ cảnh. Tương tự, từ "cancer" có thể được chú thích là "cancer|dbr\_Cancer", và bản dịch của từ có thể được tìm thấy trong phần tiếng Đức của cơ sở tri thức DBpedia (dbr\_Krebs\_(Medizin)). Sau khi tích hợp các URI, bước tiếp theo sẽ là nhúng cơ sở tri thức tham chiếu, DBpedia, bằng cách sử dụng thuật toán skip-gram cho toàn bộ các bộ ba trong DBpedia. Khi các nhúng KGEs được tạo ra, tác giả kết hợp các véc-tơ của chúng với các véc-tơ nhúng nội bộ của mô hình dịch máy mạng neural. Về mặt hình thức, giả sử các token từ văn bản nguồn và đích là các phần tử của một từ vựng cố định  $D$ , được sử dụng để huấn luyện một mô hình dịch máy mạng neural cụ thể. Các nhúng  $E'$  của  $K$  có thể được kết hợp cùng với các nhúng nội bộ  $E$  bằng một hàm kết hợp  $\text{concat}(E, E')$ , do đó tạo ra một vector mới  $E_c$ . Với sự thay đổi này, lớp đầu tiên của mạng thần

kinh hồi quy trở thành  $h_i^0 = f_{rnn}(WE_{cx_i}, Uh_{i-1}^0)$ .

Phương pháp thứ hai với ý tưởng chính là làm giàu hơn ngữ nghĩa cho cơ sở tri thức bằng một nỗ lực gán nhãn thủ công các thực thể có trong cơ sở tri thức. Cụ thể, nhóm tác giả sẽ bổ sung thêm các bộ ba mới mà trong đó chủ thể là các thực thể sẵn có trong cơ sở tri thức ban đầu nhưng đối tượng trong bộ ba sẽ là tên hoặc diễn giải cho thực thể đó. Ví dụ, bộ ba ban đầu trong DBpeida là  $\langle \text{NAACL}, \text{areaServed}, \text{USA} \rangle$  thì nhóm tác giả sẽ bổ sung thêm hai bộ ba như sau  $\langle \text{NAACL}, \text{label}, \text{North American Chapter of the Association for Computational Linguistics} \rangle$  và  $\langle \text{USA}, \text{label}, (\text{United States of America}) \rangle$ .



## Chương 3

# Phương pháp

Ở chương này, chúng tôi sẽ điểm qua kiến trúc mô hình Transformer, trình bày về thuật toán nhúng đồ thị tri thức Fast Linear, mô tả cách xây dựng hệ thống liên kết thực thể, và giới thiệu các phương pháp được đề xuất của chúng tôi nhằm nâng cao chất lượng dịch máy Anh-Việt thông qua tích hợp đồ thị tri thức.

### 3.1 Kiến trúc Transformer


Transformer là một kiến trúc mạng neural sâu được Vaswani và cộng sự [26] giới thiệu năm 2017, từ khi được công bố mô hình Transformer đã tạo ra một cuộc cách mạng cho nhiều tác vụ trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP) nói riêng và học sâu nói chung. Về mặt kiến trúc, Transformer cũng giống như mô hình chuỗi tuần tự đã được đề cập trước đó có hai thành phần chính là bộ mã hóa (Encoder) và bộ giải mã (Decoder) (Hình. 3.1). Khác với các mô hình truyền thống xử lý tính toán trên bộ mã hóa và bộ giải mã dựa vào tính toán hồi quy hoặc phép tích chập thì Transformer chỉ sử dụng cơ chế chú ý (attention) mà cụ thể là cơ chế tự chú ý (self-attention) và cơ chế chú ý chéo (cross-attention). Nhờ vào cơ chế chú ý mà mô hình Transformer có những ưu điểm nổi bật hơn so với các mô hình chuỗi tuần tự truyền thống như sau:

- Tính song song: Khi xử lý một câu đầu vào gồm nhiều từ thì mô hình Transformer không cần phải xử lý tuần tự theo thứ tự từ trái sang phải của câu bằng cơ chế hồi quy mà mô hình có thể tính toán đồng loạt song song cho tất cả các từ của câu.
- Xử lý chuỗi hai chiều: Transformer luôn xử lý câu đầu vào theo cả hai hướng của câu mà không cần phải xếp chồng thêm một lớp kiến

trúc nào khác lên trên, khác với mô hình RRN (Recurrent Neural Network) truyền thông khi xử lý câu đầu vào theo hai hướng thì mô hình này cần xếp chồng thêm một mô hình RNN khác xem xét chuỗi theo hướng ngược lại với lớp mô hình trước đó.

- Hiệu quả với dữ liệu dài: Cơ chế tự chú ý (self-attention) cho phép Transformer có thể mô hình hóa các mối quan hệ rất xa trong chuỗi dữ liệu tương đối dài, điều này hiệu quả hơn so với mạng RNN trước đây. Khi làm việc với các dữ liệu dài, RNN thường xảy ra hiện tượng "nút cổ chai" có nghĩa là những từ càng về cuối câu sẽ không nắm bắt được bất cứ ngữ nghĩa nào của những từ ở phía đầu câu. Nút cổ chai xảy ra do độ dốc (gradient) của hàm mất mát trong quá trình huấn luyện có thể trở nên rất nhỏ hoặc rất lớn khi lan truyền ngược qua nhiều bước thời gian, điều này dẫn đến việc cập nhật trọng số rất nhỏ hoặc rất lớn ảnh hưởng đến quá trình học tập của mô hình.
- Khả năng biểu diễn mạnh mẽ: Với cơ chế chú ý, tất cả các phần trong câu sẽ được xem xét lẫn nhau, và khi kết hợp nhiều khối chú ý lại với nhau (multi-head attention) thì những tính chất khác nhau về mặt ngữ pháp, cấu trúc của một câu sẽ đều được xem xét đến, chính điều này giúp tăng cường khả năng biểu diễn của mô hình cho dữ liệu đầu vào. Nói cách khác Cơ chế multi-head attention của mô hình Transformer giúp xử lý thông tin từ nhiều góc độ khác nhau, tăng cường khả năng biểu diễn ngữ cảnh phức tạp. Việc không phụ thuộc vào tuần tự của dữ liệu đầu vào giúp Transformer linh hoạt trong việc xử lý các chuỗi dữ liệu dài và đa dạng. Khả năng này cho phép Transformer vượt trội trong nhiều tác vụ NLP mà đặc biệt là dịch máy.

Các phần tiếp theo sau đây sẽ đi sâu vào cách hoạt động của các khối thành phần nhỏ cấu thành nên hai bộ phận chính là bộ mã hóa và bộ giải mã của mô hình Transformer.



Hình 3.1: Kiến trúc mô hình Transformer (Nguồn: <https://arxiv.org/pdf/1706.03762>)

### 3.1.1 Lớp nhúng và mã hóa vị trí

Lớp nhúng (Embedding layer) có tác dụng biến các từ thành các véc-tơ nhúng (embeddings) có số chiều cố định. Quá trình này gồm hai giai đoạn chính:

- **Biểu diễn từ:** Các từ trước hết được biểu diễn bằng một véc-tơ sử dụng một ma trận tham khảo (hay còn gọi là lookup table) có số dòng bằng kích thước của tập từ vựng và số cột sẽ là số chiều cố định cho việc biểu diễn, nhóm tác giả của mô hình Transformer sử dụng số chiều mặc định này là 512. Sau đó các từ trong câu được tìm kiếm trong ma trận này, và được nối với nhau thành các dòng của một ma trận hai chiều chứa ngữ nghĩa của từng từ riêng biệt.
- **Học từ sự đồng nghĩa:** Các từ có ngữ nghĩa tương tự sẽ có các véc-tơ nhúng gần nhau trong không gian vector. Điều này giúp mô hình hiểu được ngữ nghĩa của từ dựa trên ngữ cảnh của chúng.

Tuy nhiên, như đã đề cập trước đó, mô hình Transformer xử lý một

cách đồng thời tất cả các từ trong câu đầu vào do đó chỉ với việc nhúng các từ thành các véc-tơ thì mô hình sẽ không thể biết được thứ tự vị trí ban đầu của các từ trong câu, đó là lúc mã hóa vị trí được áp dụng để giải quyết vấn đề này. Mã hóa vị trí có tác dụng thêm vào các véc-tơ nhúng từ một thông tin về vị trí của từ đó trong câu. Ban đầu, một phương pháp đơn giản được đề xuất đó chính là sử dụng các chữ số tự nhiên liên tục 0, 1, 2, 3, ..., n để đánh dấu vị trí, nhưng phương pháp này rất dễ nhận thấy có hai hạn chế lớn như sau: Đầu tiên với những chuỗi đầu vào có độ dài quá lớn thì con số cuối cùng trong chuỗi có thể đạt một giá trị khá lớn và có thể gây ra sự thiên vị (bias) trong quá trình huấn luyện. Để giải quyết vấn đề vừa rồi ta sẽ thực hiện phép toán chia cho tổng số từ trong chuỗi đầu vào, nhưng việc này lại phát sinh một vấn đề hạn chế thứ hai chính là trong một khoản cố định mô hình sẽ không nắm bắt được số lượng từ có trong khoản đó.

Để giải quyết cả hai vấn đề trên, tác giả sử dụng công thức mã hóa có tên là 'sinusoidal' được biểu diễn bởi hai công thức sau:

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (3.1)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (3.2)$$

Trong đó:

- *pos*: Vị trí của từ trong câu (0, 1, 2, ..., n-1).
- *i*: Chiều của véc-tơ nhúng (0, 1, 2, ...,  $d_{model}/2 - 1$ ).
- $d_{model}$ : Kích thước của véc-tơ nhúng (embedding size).

Tính chất khoa học của công thức trên được thể hiện qua các yếu tố:

- Chu kỳ hóa: Các hàm sin và cos có tính chất chu kỳ, cho phép mô hình học được các mối quan hệ tuần hoàn và độ dài của chuỗi dữ liệu.
- Khả năng phân biệt vị trí: Bằng cách sử dụng cả sin và cos với các tần số khác nhau, các véc-tơ mã hóa vị trí có thể phân biệt rõ ràng giữa các vị trí khác nhau.

- Tính tương tự vị trí: Các vị trí gần nhau sẽ có các véc-tơ mã hóa vị trí tương tự nhau, giúp mô hình dễ dàng học được mối quan hệ giữa các từ gần kề.
- Tính hằng số: Các giá trị mã hóa vị trí là các giá trị cố định, không yêu cầu học thêm các trọng số, giúp giảm độ phức tạp của mô hình và tăng hiệu quả tính toán.

### 3.1.2 Cơ chế tự chú ý của bộ mã hóa


Cơ chế tự chú ý cho phép mỗi từ trong câu tập trung vào tất cả các từ khác trong câu, bao gồm cả chính từ đó. Điều này giúp mô hình hiểu ngữ cảnh toàn cục của câu bằng cách tính toán các trọng số (weights) giữa các từ. Ví dụ trong Hình. 3.2, khi từ "ông" được mã hóa, từ này sẽ chú ý vào tất cả các từ trong câu và các điểm chú ý (attention scores) của những từ càng có liên quan đến từ "ông" sẽ có giá trị cao hơn các từ ít liên quan khác, ví dụ từ "mặt trời" sẽ có điểm chú ý rất cao sau khi quá trình tự chú ý của từ "ông" kết thúc. Quá trình tính toán của cơ chế tự chú ý khá phức tạp và được chia thành nhiều giai đoạn.

Biến đổi đầu vào thành các thành phần liên quan: Ma trận truy vấn (Query-Q), ma trận khóa (Key-K), ma trận giá trị (Value-V), mỗi véc-tơ trong từng ma trận đảm nhận một vai trò riêng biệt cho quá trình tính toán trong cơ chế tự chú ý sau này. Cụ thể, các véc-tơ truy vấn chứa thông tin của từ được tìm kiếm hay so sánh, điều này tương tự như khi chúng ta cần tìm kiếm một thông tin nào đó và tạo ra một câu truy vấn cho chức năng tìm kiếm của Google. Các véc-tơ khóa lại giữ vai trò biểu diễn thông tin các từ được so sánh với từ cần tìm kiếm ở trên, tương tự với việc Google tìm các trang web để so sánh với truy vấn mà chúng ta đã dùng để tìm kiếm. Cuối cùng các véc-tơ giá trị sẽ thể hiện nội dung, ý nghĩa của các từ, trong ví dụ về tìm kiếm bằng Google thì véc-tơ giá trị sẽ có vai trò như là nội dung trang web được hiển thị cho người dùng sau khi tìm kiếm. Về mặt toán học:  $Q = XW^Q$ ,  $K = XW^K$ ,  $V = XW^V$ . Trong đó: X là ma trận đầu vào, trong đó mỗi hàng là véc-tơ nhúng của một từ.  $W^Q$ ,  $W^K$ ,  $W^V$  lần lượt là các ma trận trọng số để biến đổi đầu vào thành Q, K, và V.



Hình 3.2: Ví dụ về sự tự chú ý (Nguồn: <https://pbcquoc.github.io/transformer/>)

Bước tính ma trận đầu ra của cơ chế tự chú ý liên quan đến việc tính toán các điểm chú ý (attention scores) giúp mô hình xác định mức độ quan trọng giữa các từ như đã đề cập trước đó (Hình. 3.3). Điểm chú ý giữa một cặp từ được tính bằng cách lấy tích vô hướng (dot product) giữa truy vấn (query) của một từ và khóa (key) của các từ khác, thông thường để ổn định cho việc tính toán hơn thì kết quả của tích vô hướng này sau đó được chia cho căn bậc hai của số chiều của véc-tơ khóa. Sau khi đã kiểm tra mối tương quan giữa truy vấn và khóa thông qua việc tính điểm chú ý, tất cả các điểm chú ý sẽ được chuẩn hóa về đoạn  $[0-1]$  bằng hàm softmax với ý nghĩa càng tiến về 1 tức là truy vấn càng tương đồng về ngữ nghĩa hoặc có liên quan càng cao đến khóa, càng tiến về 0 thì giữa truy vấn và khóa càng không có mối tương quan nào. Sau khi đã có tất cả các điểm chú ý của tất cả các từ so với các từ khác trong câu, ma trận đầu ra (output) của cơ chế tự chú ý được tính toán bằng cách lấy tích vô hướng giữa ma trận các điểm chú ý và ma trận giá trị (value)  $V$  được tạo ra từ bước biến đổi đầu vào trước đó, việc tính toán này mang ý nghĩa rằng một từ trong câu sau khi hoàn thành cơ chế tự chú ý sẽ được biểu diễn bằng trung bình có trọng số của các giá trị của tất cả các từ trong câu (kể cả giá trị của chính bản thân từ đó). Điều này thể hiện rõ ràng mục đích chú ý lẫn nhau giữa các từ trong câu khi véc-tơ biểu diễn thông tin cho một từ không chỉ đơn thuần mang thông tin của từ đó mà còn bao gồm thông tin của tất cả các từ khác trong câu, điều này giúp cho mô hình Transformer có khả năng hiểu sâu sắc và chính xác hơn về ngữ nghĩa của từ ngữ, nắm bắt các mối quan hệ dài hạn và ngắn hạn hiệu quả hơn mô hình truyền thống trước đây.



Hình 3.3: Quá trình tính toán ma trận đầu ra của cơ chế tự chú ý

Biểu diễn về mặt toán học cho quá trình tính toán được thể hiện như sau:

$$\text{attentionScores}(Q, K) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \quad (3.3)$$

$$\text{output} = \text{attentionScores}V \quad (3.4)$$

Trong đó:

- $QK^T$  là tích vô hướng giữa ma trận truy vấn Q và ma trận khóa K.
- $\sqrt{d_k}$  là giá trị chuẩn hóa để tránh giá trị quá lớn, với  $d_k$  là chiều của véc-tơ khóa.
- softmax là hàm softmax được áp dụng để chuẩn hóa các điểm chú ý thành phân phối xác suất.
- attentionScoresV là tích vô hướng giữa ma trận các điểm chú ý và ma trận giá trị V.

### 3.1.3 Cơ chế tự chú ý đa đầu của bộ mã hóa (Multi-Head Self-Attention)

Một câu văn bản bằng ngôn ngữ tự nhiên luôn chứa rất nhiều kiểu quan hệ khác nhau giữa các từ trong câu. Chẳng hạn xem xét câu "Nhà hàng này cũng không quá tệ" cùng với ba kiểu quan hệ đơn giản như sau: chú ý đến từ kế trước của một từ, chú ý đến từ kế sau của một từ, và chú ý đến các từ có liên quan cao của một từ. Chỉ với các kiểu quan hệ đơn giản này nhưng cũng đã là một quá trình phân tích phức tạp mà mô hình cần phải giải quyết. Ví dụ từ "này" và từ "cũng" cho dù xem xét các từ đứng trước hay đứng sau chúng thì chúng đều không có ảnh hưởng đến ngữ nghĩa của các từ này, hoặc ngược lại chúng cũng sẽ không bị ảnh hưởng bởi các từ xung quanh. Mặt khác, ý nghĩa của từ "tệ" trong câu sẽ bị ảnh hưởng khác đi do sự xuất hiện của các từ "không" và "quá", từ "quá" sẽ có chức năng xác định độ chừng mực của từ "tệ" trong khi sự có mặt của từ "không" sẽ đảo ngược hoàn toàn ý nghĩa của từ "tệ". Trong một lần tính toán tự chú ý duy nhất thì mô hình không thể học tập hết tất cả các kiểu mối quan hệ trong câu, do đó để mở rộng khả năng này chúng ta sẽ thực hiện lặp lại nhiều lần quá trình tính toán cơ chế tự chú ý và quá trình này được gọi là tự chú ý đa đầu (multi-head self-attention), trong đó một quá trình tính toán cơ chế tự chú ý riêng lẻ được gọi là một đầu (head). Mỗi đầu sẽ sử dụng các ma trận trọng số khác nhau trong quá trình tính toán, cuối cùng kết quả từ các đầu này được kết hợp lại thông qua phép nối (concat) và nhân với một ma trận trọng số mới để tạo thành đầu ra với kích thước như ý muốn.

Biểu diễn về mặt toán học:

$$\text{head}_i = \text{attentionScores}(XW_i^Q, XW_i^K)XW_i^V \quad (3.5)$$

$$\text{multiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (3.6)$$

Trong đó:

- $W_i^Q, W_i^K, W_i^V$ : Các ma trận trọng số riêng cho mỗi đầu (head).
- $W^O$ : Ma trận trọng số để kết hợp kết quả từ các đầu.




Ngoài ra trong cấu trúc của bộ mã hóa, trước và sau mỗi khối tự chú ý còn kèm theo một lớp kết nối tắt (residual connection) và một lớp chuẩn hóa (normalization layer) có tác dụng giúp cho quá trình huấn luyện của mô hình nhanh hội tụ hơn và tránh mất mát thông tin trong toàn bộ quá trình huấn luyện mô hình, ví dụ việc thực hiện kết nối tắt giúp tăng khả năng bảo toàn thông tin về vị trí của các từ được mã hóa.

### 3.1.4 Bộ giải mã-Cơ chế tự chú ý đa đầu có mặt nạ

Cơ chế hoạt động và quá trình tính toán của bộ giải mã (decoder) hoàn toàn tương đồng so với bộ mã hóa (encoder) với một vài điểm khác biệt chính, cụ thể là việc sử dụng thêm kỹ thuật mặt nạ (masked) cho việc mã hóa đầu vào và cơ chế chú ý chéo (cross-attention). Trước hết chúng ta sẽ xem xét quá trình áp dụng kỹ thuật mặt nạ để mã hóa đầu vào về phía bộ giải mã. Trước khi bước vào quá trình tính toán cơ chế tự chú ý của bộ giải mã, một mặt nạ được áp dụng để che giấu các vị trí tương lai của chuỗi đầu vào, điều này rất quan trọng để đảm bảo rằng mô hình chỉ có thể "nhìn" các từ đã được xử lý trước đó khi dự đoán từ hiện tại. Việc che giấu này rất quan trọng để duy trì trật tự và sự mạch lạc của đầu ra, một lợi ích to lớn khác của việc sử dụng mặt nạ là có thể huấn luyện mô hình trong thời gian ngắn hơn nhiều, nếu tránh việc 'nhìn thấy tương lai' bằng cách sử dụng kỹ thuật hồi quy tuần tự truyền thống sẽ mất rất nhiều thời gian cho quá trình huấn luyện, chính vì vậy việc sử dụng mặt nạ vừa đảm bảo việc tính toán song song một cách đồng thời tương tự như bộ mã hóa vừa đảm bảo về mặt thời gian cho quá trình huấn luyện.

Mặt nạ là một ma trận vuông, trong đó mỗi phần tử xác định xem một từ tại vị trí hiện tại có thể "nhìn thấy" một từ ở vị trí khác hay không. Mặt nạ này thường được tạo bằng cách sử dụng giá trị 0 hoặc  $-\infty$  (âm vô cực) để chỉ định các vị trí được phép hoặc bị cấm. Việc đánh dấu các giá trị không được phép nhìn thấy bằng  $-\infty$  sẽ làm cho chúng được chuyển đổi thành 0 khi đi qua hàm softmax, bằng cách này, chúng ta loại trừ đi các mã thông báo trong tương lai trong chuỗi. Giả sử, chuỗi đầu vào với độ dài  $T$ , mặt nạ sẽ là một ma trận vuông kích thước  $T \times T$  với các giá trị được xác định như sau:



Hình 3.4: Ví dụ đơn giản cho việc áp dụng mặt nạ lên chuỗi đầu vào của phía bộ giải mã


- Các phần tử trên đường chéo chính và phía dưới đường chéo chính được đặt là 0, nghĩa là những từ này có thể nhìn thấy nhau.
- Các phần tử phía trên đường chéo chính được đặt là  $-\infty$ , nghĩa là những từ này không thể nhìn thấy nhau.

Hình. 3.4 minh họa ví dụ đơn giản cho việc áp dụng mặt nạ lên chuỗi đầu vào của phía bộ giải mã.

### 3.1.5 Cơ chế chú ý chéo và lớp tuyến tính cuối cùng

Khác với cấu tạo của bộ mã hóa khi tất cả các khối chú ý trong bộ mã hóa đều sử dụng cơ chế tự chú ý (self-attention) thì chỉ riêng khối chú ý đầu tiên của bộ giải mã là sử dụng cơ chế tự chú ý, tất cả các khối còn lại sẽ sử dụng cơ chế chú ý mới có tên là chú ý chéo (cross-attention). Về các bước tính toán thì cơ chế chú ý chéo hoàn toàn tương tự cơ chế tự chú ý, khác biệt chính đến từ việc các thành phần truy vấn Q, khóa K, và giá trị V sẽ khác nhau. Đối với các khối chú ý sử dụng cơ chế chú ý chéo thì K và V được đại diện bởi đầu ra của bộ mã hóa, truy vấn Q đến từ đầu ra của khối chú ý trước đó trong nội bộ cấu trúc của bộ giải mã (Hình. 3.5).

Giống với nhiều mô hình học sâu khác, đầu ra của mô hình thường sẽ đi qua một lớp tuyến tính và hàm softmax, trong đó lớp tuyến tính là một mạng feed-forward nhiều lớp với hàm kích hoạt thường là ReLU hoặc GeLU có tác dụng thay đổi kích thước kết quả đầu về kích thước phù hợp với định dạng dữ liệu hoặc yêu cầu của bài toán. Hàm softmax có tác dụng chuyển đổi các giá trị số thành phân phối xác suất trong đoạn [0-1]




Hình 3.5: Các thành phần trong cơ chế chú ý chéo

và phần tử nào trong bộ từ điển có giá trị xác suất cao nhất sẽ được chọn làm bản dịch ở ngôn ngữ đích của từ tương ứng ở ngôn ngữ nguồn.

### 3.2 Thuật toán nhúng đồ thị tri thức Fast Linear


Chúng tôi sử dụng cơ sở tri thức có tên Wikidata5M cho nghiên cứu của mình, cơ sở tri thức này được Wang và cộng sự [27] công bố năm 2021 là một tập dữ liệu lớn và phong phú, được sử dụng rộng rãi trong các nghiên cứu về trí tuệ nhân tạo, đặc biệt là trong lĩnh vực NLP. Mỗi thực thể trong Wikidata5M được biểu diễn bằng một dạng mã định danh gọi là Qid và mỗi quan hệ giữa 2 thực thể được biểu diễn bằng dạng mã gọi là Pid. Qid là viết tắt của "Query ID" hoặc "Qualifier ID" trong một số tài liệu, nhưng trong trường hợp của Wikidata, Qid đại diện cho ID của một thực thể nhất định, mỗi thực thể trong cơ sở tri thức Wikidata được gán một mã định danh duy nhất bắt đầu bằng chữ "Q", theo sau là một số nguyên (ví dụ: Q615 đại diện cho "Lionel Messi"). Pid là viết tắt của "Property ID" và sẽ biểu diễn cho các thuộc tính hoặc mối quan hệ (properties or relations) trong Wikidata, mỗi thuộc tính trong Wikidata



Hình 3.6: Ví dụ đơn giản minh họa đồ thị tri thức Wikidata5M


cũng được gán một mã định danh duy nhất bắt đầu bằng chữ "P", theo sau là một số nguyên (ví dụ: P19 đại diện cho "location of birth" có nghĩa là "nơi sinh"). Định dạng dữ liệu trong Wikidata5M cũng tương tự với hầu hết các cơ sở tri thức khác, mỗi dòng là một bộ ba (triplet) có dạng <chủ thể-s, quan hệ-r, đối tượng-o>, ví dụ: <Q615, P19, Q52535> tương ứng <Lionel Messi, location of birth, Rosario>, có nghĩa là Lionel Messi được sinh ra tại Rosario. Khi xem xét cơ sở tri thức Wikidata5M dưới dạng đồ thị, chúng ta có thể hình dung như là một đồ thị có các nút (nodes) và các cạnh (edges) thể hiện các thực thể và mối quan hệ giữa chúng. Trong cấu trúc này: Mỗi nút trong đồ thị đại diện cho một thực thể trong Wikidata5M, các thực thể này được biểu diễn bằng các định danh Qid duy nhất. Ví dụ, Q615 đại diện cho Lionel Messi, Q2 có thể là Earth (Trái Đất). Các cạnh trong đồ thị đại diện cho các mối quan hệ hoặc thuộc tính kết nối hai thực thể với nhau. Các mối quan hệ này được biểu diễn bằng các định danh Pid duy nhất. Với cấu tạo vừa được đề cập, đồ thị tri thức (KG) được xây dựng từ Wikidata5M (Hình. 3.6) có các đặc điểm đồ thị như sau:

- Đồ thị có hướng (Directed Graph): Các cạnh có hướng, nghĩa là chúng đi từ một thực thể nguồn đến một thực thể đích, thể hiện rõ ràng mối quan hệ giữa các thực thể.
- Đa dạng về mối quan hệ (Rich Relationships): Mỗi cạnh có một nhãn (label) đại diện cho loại mối quan hệ, tạo ra sự phong phú và chi tiết trong cách các thực thể tương tác với nhau.



Hình 3.7: Sinh mẫu dữ liệu huấn luyện cho mô hình Skip-gram

Chúng tôi sử dụng thuật toán Fast Linear [8] để nhúng cho các thực thể và các mối quan hệ trong KG của chúng tôi thành các véc-tơ biểu diễn thông tin trong một không gian ẩn đa chiều. Mô hình áp dụng thuật toán này được tác giả đặt tên là Fasttext và được lấy ý tưởng tương tự cách hoạt động của phương pháp BOW cổ điển trong việc thực hiện nhúng từ vựng. Trong phương pháp BOW, mỗi từ được biểu diễn dưới dạng một véc-tơ, và các véc-tơ này được học sao cho các từ có ý nghĩa tương tự sẽ có biểu diễn gần nhau trong một không gian véc-tơ đa chiều. Xem xét phương pháp BOW được thiết kế ở dạng mô hình skip-gram: Mô hình skip-gram học cách biểu diễn các từ trong không gian véc-tơ đa chiều bằng cách dự đoán các từ ngữ cảnh xung quanh thông qua một từ trung tâm được chọn trước, các từ ngữ cảnh của một từ trung tâm chính là các từ phía trước và phía sau của từ trung tâm đó, vậy giới hạn cho số lượng các từ ngữ cảnh được xác định như thế nào? Điều này phụ thuộc vào giá trị của siêu tham số 'kích thước cửa sổ trượt (window size)', giả sử giá trị này được đặt là hai tức sẽ là đối với mỗi từ trung tâm thì hai từ phía trước và hai từ phía sau sẽ là các từ ngữ cảnh mục tiêu cần được dự đoán. Hình. 3.7 sẽ minh họa cách thức sinh các mẫu dữ liệu huấn luyện từ câu đầu vào "The sun rises in East" với kích thước cửa sổ trượt được đặt là 2. Đối với kiến trúc của mô hình skip-gram, sẽ đơn giản là một mô hình mạng feed-forward với một lớp ẩn duy nhất và một lớp đầu ra đi qua một tính toán phân phối xác suất softmax. Hình. 3.8 minh họa kiến trúc mạng skip-gram với các thông số giả sử như sau: Kích thước từ vựng là 10000 từ, véc-tơ nhúng của



Hình 3.8: Kiến trúc mạng Skip-gram

từ có số chiều là 512, khi đó ma trận  $W$  hoặc  $W'$  sẽ là những tham số có thể học được trong quá trình huấn luyện và chúng cũng chính là kết quả đạt được của quá trình nhúng từ mà có thể được sử dụng trong các tác vụ khác sau này. Đối với thuật toán Fast Linear, chỉ làm việc với dữ liệu tồn tại trong Wikidata5M ở dạng bộ ba, tuy nhiên kích thước của một KG là rất lớn do đó bộ từ vựng được tạo từ các Qid và các Pid là lớn hơn nhiều so với bộ từ vựng cho tập dữ liệu của phương pháp BOW.

Khi làm việc với ngữ cảnh của một KG sẽ có chút khác biệt, với các bộ ba trong một KG thì mỗi thực thể hoặc mỗi quan hệ sẽ được biểu diễn dưới dạng một véc-tơ, mỗi chủ thể (subject)  $s$  đi kèm với một quan hệ  $r$  nào đó sẽ cho ra kết quả là một đối tượng (object)  $o$  tương ứng. Tức là Fasttext model sẽ chú trọng vào việc đồng xuất hiện giữa các thực thể và giữa các thực thể với các mối quan hệ giữa chúng. Nói cách khác, giả sử ta có một bộ ba như sau:  $\langle s, r, o \rangle$  thì kết quả của Fasttext model được mong muốn gần đúng với biểu thức sau:

$$s + r \approx o \quad (3.7)$$

Về mặt công thức lý thuyết, việc tối ưu hóa khi sử dụng mô hình Fasttext ngoài việc tối ưu khả năng hoàn thiện đồ thị tri thức (knowledge

graph completion) tương tự như hầu hết các thuật toán nhúng đồ thị tri thức khác đã áp dụng còn là việc tối ưu hóa theo công thức 3.8 dưới đây:

$$\frac{1}{N} \sum_{n=1}^N y_n \log(f(WVx_n)) \quad (3.8)$$

Trong đó:

- $W$  là ma trận trọng số cho bộ phân loại.
- $V$  đóng vai trò là bảng tra cứu cho từng mã thông báo riêng lẻ.
- $y_n$  là nhãn (0, 1) cho biết hai mã thông báo có cùng xuất hiện trong một bộ ba hay không.
- $x_n$  được gọi là dạng biểu diễn BOW đã được chuẩn hóa cho đầu vào thứ  $n$  trong tập dữ liệu huấn luyện, ví dụ với một bộ ba  $\langle s, r, o \rangle$  xét trên một kích thước cửa sổ trượt (window size) là 2 thì bộ ba này sẽ tạo ra ba mẫu gồm:  $\langle s, r \rangle$ ,  $\langle s, o \rangle$ ,  $\langle r, o \rangle$ . Công thức 3.9 sẽ biểu diễn dạng BOW đã được chuẩn hóa của mẫu  $\langle s, r \rangle$  như sau:

$$x_{\langle s, r \rangle} = \text{normalize}(\text{concat}(v_s, v_r)), (v_s, v_r \in V) \quad (3.9)$$

Về quá trình huấn luyện, tất cả các bộ ba trong Wikidata5M sẽ được dùng để sinh các mẫu dữ liệu huấn luyện cho quá trình huấn luyện mô hình fasttext, và cách sinh mẫu này tương tự cách sinh mẫu trong mô hình skip-gram. Sau khi tất cả các mẫu dữ liệu huấn luyện được sinh ra, chúng sẽ được truyền qua một bộ phân lớp gồm hai hàm mất mát (loss function) được xem xét: Hàm mất mát tiêu chuẩn tương tự như quá trình dự toán từ vựng trong mô hình skip-gram, và hàm mất mát dành cho việc dự đoán đối tượng  $o$  trong một bộ ba.

### 3.3 Hệ thống liên kết thực thể

Các thực thể cũng như các mối quan hệ đều được biểu diễn ở dạng id riêng của chúng, do đó quá trình liên kết thực thể (entity linking) cần được

thực hiện theo 2 bước: đầu tiên, chúng tôi xem xét qua từng câu trong tập dữ liệu và trích xuất các thực thể xuất hiện trong các câu văn bản đấy. Sau đó, chúng tôi so khớp các thực thể vào KG để lấy Qid tương ứng cho từng thực thể, quá trình này được thực hiện thông qua sự so khớp chuỗi tuyệt đối giữa thực thể được trích xuất trong câu với thực thể tồn tại trong KG. Để làm được bước so khớp chuỗi, chúng tôi phải thực hiện các bước tiền xử lý nhằm tạo ra các tập tin ánh xạ giữa Qid với tên trong thế giới thực của các thực thể và các Pid với tên trong thế giới thực của các mối quan hệ trên hệ thống của Wikipedia. Cụ thể, chúng tôi tải xuống một tập hợp tất cả các bí danh (tên trong thế giới thực) của tất cả các thực thể cũng như mối quan hệ tồn tại trong Wikidata5M, tập hợp này được tổng hợp thủ công từ thông tin được lưu trữ trên trang web Wikidata do đội ngũ *deepgraphlearning*<sup>1</sup> thực hiện. Trong tập hợp này, một thực thể không chỉ có một tên thực tế duy nhất mà đi kèm theo đó là một danh sách các tên thực tế phổ biến của thực thể đó. Chẳng hạn Q615 có danh sách các bí danh trong thế giới thực gồm {M10, Messi, messi, Lionel Messi, lionel messi, Messi Lionel, messi lionel, Lionel Andrés Messi, El Pulga}. Sau đó chúng tôi sử dụng ngôn ngữ lập trình để có thể tạo ra một cấu trúc dữ liệu dạng từ điển (dictionary) với các khóa là các bí danh, các giá trị là các Qid tương ứng với bí danh đó, từ điển này được dùng để so khớp chuỗi tuyệt đối đồng thời tra cứu Qid tương ứng với bí danh vừa được so sánh với thực thể được trích xuất trong câu. Việc có khả năng bao quát nhiều tên cho một Qid làm giảm sự mơ hồ của ngôn ngữ tự nhiên, chẳng hạn thứ tự tên xảy ra sự hoán đổi do cấu trúc ngữ pháp hoặc sự khác biệt về tên gọi đầy đủ và rút gọn ở những vùng miền, quốc gia khác nhau.

### **3.4 Các phương pháp mới được đề xuất nâng cao chất lượng dịch máy thông qua tích hợp đồ thị tri thức**

Khác với các công trình nghiên cứu trước đây về việc áp dụng đồ thị tri thức (KG) vào mô hình dịch máy, các mô hình này sử dụng KG để trích

---

<sup>1</sup><https://deepgraphlearning.github.io/project/wikidata5m>



xuất các thuộc tính về mặt ngôn ngữ, hoặc xây dựng một KG phức tạp mà ở đó KG là song ngữ (bilingual KG) hoặc đa ngữ (multilingual KG), mỗi thực thể có nhiều phiên bản ngôn ngữ khác nhau tồn tại bên trong KG. Các phương pháp của chúng tôi xem xét một KG đơn ngữ mà cụ thể là KG cho ngôn ngữ nguồn là tiếng Anh nhằm mục đích giảm bớt sự khó khăn cho việc tìm kiếm và xây dựng KG vừa đủ lớn vừa hỗ trợ nhiều ngôn ngữ, mặt khác Wikidata5M còn có tính bao quát thông tin khá tốt. Chúng tôi đề xuất ba phương pháp mới cho việc tích hợp KG vào quá trình dịch máy và được chia làm hai nhóm cụ thể như sau:

- Nhóm các phương pháp không làm thay đổi kiến trúc mô hình ban đầu: Trong nhóm này, chúng tôi đề xuất hai phương pháp tích hợp KG vào mô hình Transformer mà không làm thay đổi kiến trúc của mô hình nhưng vẫn có khả năng tăng cường chất lượng cho các bản dịch so với mô hình Transformer truyền thống.
- Phương pháp EATT (Entity-Aware Transformer Translation): Phương pháp này tích hợp KG vào mô hình Transformer bằng cách thực hiện thêm cơ chế chú ý chéo (cross-attention) giữa đầu vào của bộ mã hóa và các véc-tơ nhúng trong KG, cài đặt này thay đổi kiến trúc mô hình Transformer ban đầu tạo ra kiến trúc mới và vẫn có khả năng tăng cường chất lượng cho các bản dịch so với mô hình Transformer truyền thống.

### **3.4.1 Nhóm các phương pháp đề xuất không làm thay đổi kiến trúc mô hình ban đầu**

Trong quá trình nghiên cứu các phương pháp tăng cường chất lượng dịch máy thông qua việc tích hợp KG vào mô hình Transformer, chúng tôi nhận ra tầm quan trọng của việc kết hợp một cách hợp lý các véc-tơ biểu diễn thông tin của các thực thể trong KG vào các nội véc-tơ trong mô hình Transformer là vô cùng to lớn. Trước hết chúng tôi tiến hành một nhóm hai phương pháp kết hợp thông tin mà không làm thay đổi kiến trúc ban đầu của mô hình Transformer, chúng tôi gọi hai phương pháp đề xuất này với tên lần lượt là KG-Trans và KG-Trans-R.

Phương pháp đầu tiên KG-Trans: Phương pháp này được thiết kế nhằm tận dụng tri thức từ các đồ thị tri thức (KG) để cải thiện hiệu suất của mô hình Transformer trong dịch máy. Trong phương pháp này, quá trình thực hiện được chia thành nhiều bước cụ thể và chi tiết, bắt đầu từ việc trích xuất các thực thể từ câu nguồn trong quá trình huấn luyện. Ban đầu, các thực thể (entities) trong các câu nguồn được trích xuất bằng cách sử dụng kỹ thuật nhận diện thực thể (NER). Các thực thể này sau đó được ánh xạ vào các véc-tơ nhúng đã được xây dựng dựa trên KG (hay còn gọi là KGEs). Như đã trình bày chúng tôi sử dụng Wikidata5M để xây dựng KG trong nghiên cứu của mình, một trong những tập dữ liệu đồ thị tri thức lớn và phong phú nhất hiện nay, để thu thập các véc-tơ nhúng. Các véc-tơ này được mã hóa bởi mô hình Fasttext, mô hình nhúng KG theo cách gần giống với phương pháp BOW cho việc nhúng từ vựng, với khả năng biểu diễn các thực thể và các mối quan hệ vào một không gian đa chiều giàu ngữ nghĩa. Sau khi các thực thể được ánh xạ vào KGEs, các véc-tơ nhúng thu được sẽ được tích hợp vào mô hình Transformer. Quá trình tích hợp này diễn ra bằng cách thực hiện phép nối (concatenation) các véc-tơ nhúng thu được từ KGEs với các nội véc-tơ (internal vectors) được tạo ra ngẫu nhiên trong kiến trúc Transformer. Việc nối thêm này giúp mô hình có thêm thông tin ngữ nghĩa từ các thực thể, từ đó cải thiện khả năng hiểu và dịch các câu chứa nhiều thực thể phức tạp.

Cơ sở khoa học của phương pháp KG-Trans dựa trên việc kết hợp thông tin thông qua phép nối (concatenation), việc lựa chọn sử dụng phép nối dựa trên các cơ sở như sau:


- Bổ sung thông tin ngữ nghĩa: Các nội véc-tơ trong mô hình Transformer được khởi tạo ngẫu nhiên và được huấn luyện để học từ dữ liệu, nhưng ban đầu chúng không mang thông tin ngữ nghĩa cụ thể. Khi thực hiện phép nối, các véc-tơ nhúng từ KGEs mang thông tin ngữ nghĩa phong phú từ Wikidata5M sẽ được kết hợp trực tiếp với các nội véc-tơ này, nhằm mục đích mong muốn mô hình có thể giải quyết các câu chứa các thực thể đặc thù một cách tốt hơn.
- Bảo toàn cấu trúc học của Transformer: Việc chỉ ảnh hưởng đến bước chuẩn bị các véc-tơ nhúng đầu vào vừa có tác dụng bổ sung

thông tin vừa có tác dụng không làm tăng số lượng tham số cần học của mô hình, giúp hạn chế tiêu tốn tài nguyên cho quá trình huấn luyện. Điều này cho phép mô hình duy trì được hiệu suất khi phải đối mặt với các bộ dữ liệu có kích thước lớn.

- Khả năng xử lý đa chiều: Việc Transformer có thể xử lý các véc-tơ biểu diễn cho các từ trong câu không theo quy luật hồi quy tuần tự làm cho việc tăng số chiều từ các véc-tơ thông tin tri thức bổ sung không làm ảnh hưởng đáng kể đến quá trình tính toán về mặt thời gian lẫn độ phức tạp.

Tuy nhiên, phương pháp KG-Trans có thể gặp phải khó khăn với những thực thể mà trong tập dữ liệu được mô tả theo quá nhiều bí danh khác nhau. Và khi một bí danh không có trong bộ từ vựng sẽ được áp dụng thuật toán BPE để biểu diễn thành các đơn vị nhỏ hơn từ, điều này ảnh hưởng đến khả năng lấy thông tin về thực thể từ KG. Do đó, chúng tôi đề xuất phương pháp thứ hai, KG-Trans-R, với mong muốn có thể vượt qua khó khăn nêu trên. Phương pháp KG-Trans-R không chỉ giúp mô hình hoạt động tốt hơn khi dữ liệu được áp dụng thuật toán BPE cho bước tiền xử lý, mà còn tăng tốc quá trình dịch bằng cách thay thế hoàn toàn các nội véc-tơ ngẫu nhiên bằng các véc-tơ nhúng từ KGEs.

Phương pháp thứ hai KG-Trans-R: Phương pháp được thiết kế nhằm giải quyết hạn chế của phương pháp trước đó để lại. Quá trình thực hiện KG-Trans-R bắt đầu bằng việc liên kết các thực thể được nhận diện trong các câu văn bản ở ngôn ngữ nguồn với các thực thể tương ứng trong KG để lấy các Qid của chúng. Các Qid này là các mã định danh duy nhất cho mỗi thực thể trong Wikidata, đảm bảo tính nhất quán và chính xác khi ánh xạ các thực thể. Ví dụ, Messi sẽ được gán mã Q615 và Rosario sẽ được gán mã Q52535. Điều này có nghĩa rằng câu "Messi was born in Rosario" sau khi được đánh dấu sẽ trở thành "Q615 was born in Q52535". Sau khi đánh dấu, các Qid sẽ được ánh xạ vào KGEs đã được xây dựng nhờ vào mô hình Fasttext như đã trình bày trước đó để lấy các véc-tơ nhúng mang thông tin tri thức cho các thực thể tương ứng. Khác với phương pháp KG-Trans, trong phương pháp KG-Trans-R, các véc-tơ nhúng từ KGEs sẽ thay thế hoàn toàn các nội véc-tơ ngẫu nhiên trong kiến trúc Transformer.



Hình 3.9: Kiến trúc chung cho các phương pháp KG Transformer

Cách tiếp cận này có các lợi thế khoa học rõ ràng như sau:


- Lợi thế đầu tiên tương tự như phương pháp trước đó khi vừa có thể cung cấp thông tin cho mô hình Transformer nhưng vẫn đảm bảo tính toàn vẹn về mặt cấu trúc cho mô hình.
- Bắt đầu quá trình huấn luyện hiệu quả hơn: Bằng cách thay thế hoàn toàn các nội véc-tơ giúp loại bỏ yếu tố ngẫu nhiên và thiếu thông tin. Các véc-tơ nhúng từ KGEs chứa đựng thông tin tri thức cụ thể, giúp mô hình có nền tảng ngữ nghĩa ngay từ đầu.
- Đảm bảo tính nhất quán: Việc sử dụng các Qid làm mã định danh cho các thực thể giúp duy trì tính nhất quán và chính xác khi các thực thể này được dịch giữa các ngôn ngữ. Điều này đặc biệt quan trọng khi dịch các văn bản có chứa nhiều thực thể đặc biệt hoặc thực thể có nhiều tên gọi và biến thể ngữ nghĩa khác nhau.
- Cải thiện hiệu quả khi áp dụng BPE: Hạn chế việc kích thước từ vựng quá lớn và nhiều bí danh bị hạn chế bằng cách phân thành các đơn vị nhỏ hơn mức từ.

Hình. 3.9 thể hiện sơ đồ kiến trúc chung của hai phương pháp mà chúng tôi đề xuất, thành phần "aggregation module" thực hiện việc tích hợp thông tin từ KGEs vào mô hình Transformer. Cụ thể, phương pháp đầu tiên sử dụng kỹ thuật nối (concatenation) để kết hợp các véc-tơ (được biểu diễn bằng các ô vuông màu đỏ), trong khi phương pháp thứ hai sử dụng kỹ thuật thay thế (replacing) để hoàn toàn thay thế các véc-tơ ngẫu nhiên (được biểu diễn bằng các ô vuông màu vàng). Sự khác biệt này phản ánh tính đa dạng trong việc tích hợp thông tin ngữ nghĩa từ KGEs vào mô hình, từ đó nâng cao hiệu suất và độ chính xác của mô hình dịch máy.

### 3.4.2 Phương pháp EATT (Entity-Aware Transformer Translation)

Hai phương pháp KG-Trans và KG-Trans-R mà chúng tôi đã trình bày đều tận dụng tri thức từ đồ thị tri thức (KG) để cải thiện chất lượng của mô hình Transformer trong dịch máy. Mặc dù cả hai phương pháp đều có những cải tiến nhất định cho quá trình dịch, nhưng chúng vẫn còn đối mặt với những hạn chế nhất định và chưa mang tính đột phá về việc tương tác với thông tin tồn tại trong KG. Để tiếp tục nâng cao hiệu suất và khai thác triệt để tiềm năng của tri thức từ KG, chúng tôi đề xuất một phương pháp mới thay đổi kiến trúc của mô hình Transformer được đặt tên là EATT. Về mặt tổng quan, phương pháp mới này sẽ tập trung vào việc triển khai cơ chế chú ý chéo (cross-attention) giữa các câu đầu vào và các véc-tơ biểu diễn cho các thực thể trong KG. Cơ chế chú ý chéo sẽ cho phép mô hình không chỉ dựa vào thông tin nội bộ từ các từ ngữ trong câu đầu vào mà còn tận dụng tri thức từ các thực thể trong KG để tạo ra các biểu diễn ngữ nghĩa phong phú và chính xác hơn. Mỗi token trong câu đầu vào sẽ được mã hóa thành các véc-tơ số và sẽ thực hiện cơ chế chú ý chéo với các véc-tơ biểu diễn của các thực thể trong KG (hay chính là KGEs), giúp mô hình học được các mối quan hệ phức tạp và ngữ cảnh ngữ nghĩa từ cả hai nguồn dữ liệu (Hình. 3.10).

Đầu tiên về mặt liên kết thực thể, chúng tôi vẫn sử dụng hệ thống đã được sử dụng từ hai phương pháp được giới thiệu trước đó. Sau khi các thực thể trong câu văn bản đầu vào được nhận diện, chúng sẽ được ánh xạ



Hình 3.10: Sơ đồ tổng quan của phương pháp EATT (Entity-Aware Transformer Translation) với (a): Hệ thống liên kết thực thể, (b): Phương pháp EATT, (c): Cấu trúc chi tiết của Khối "Entity-Aware Attention"

vào KG để trích xuất các véc-tơ nhúng tri thức tương ứng với các thực thể đó, các véc-tơ nhúng này sẽ tham gia vào quá trình thực hiện cơ chế chú ý chéo với các nội véc-tơ, chính là các véc-tơ mà mô hình Transformer mã hóa cho các token trong câu đầu vào. Giả sử xem xét lớp nhúng (embedding layer) của mô hình Transformer tạo ra các nội véc-tơ đầu vào có chiều là 512 và KGEs cũng sử dụng số chiều là 512, với câu "Lionel Messi was born in Rosario" thì ma trận nội véc-tơ đầu vào sẽ có kích thước là  $6 \times 512$  (Khối "Input Embedding" màu đỏ ở mục (b) trong Hình. 3.10). Hai thực thể "Lionel Messi" và "Rosario" sau khi được nhận diện sẽ được hệ thống liên kết thực thể ánh xạ đến KG nhằm trích xuất các véc-tơ nhúng tri thức tương ứng với hai thực thể đó trong KG, khi đó thành phần "KGEs" màu xanh lá ở mục (b) trong Hình. 3.10 có kích thước là  $2 \times 512$ . Cơ chế chú ý chéo giữa hai thành phần "Input Embedding" và "KGEs" sẽ được thực hiện trong một khối có tên là Khối Chú ý nhận biết thực thể (Entity-Aware Attention Block) trước khi tạo thành đầu vào hoàn chỉnh đi vào bộ mã hóa (encoder) của mô hình Transformer.

Cấu trúc của Khối Chú ý nhận biết thực thể (Entity-Aware Attention Block) bao gồm hai thành phần con lần lượt là Khối Chú ý chéo đa đầu (Multi-Head Cross Attention Block) và một mạng neural tuyến tính Feed Forward, sau mỗi hai thành phần này là một lớp kết nối tắt và chuẩn hóa giúp tăng hiệu suất của quá trình huấn luyện. Với khối chú ý chéo đa đầu,

chúng tôi kế thừa tương tự cấu trúc của khối chú ý chéo trong thành phần bộ giải mã của mô hình Transformer, khác biệt đến từ các thành phần sẽ lần lượt đóng các vai trò là truy vấn Q, khóa K, và giá trị V. Việc các thành phần đóng các vai trò như vừa đề cập có thể được diễn giải về mặt thực tế như sau: Câu văn bản ban đầu chứa các thực thể cần được học hỏi, do đó câu này đóng vai trò mang các thông tin cần truy vấn để yêu cầu KG cung cấp các tri thức cần thiết để giải đáp các truy vấn này. Các véc-tơ nhúng mã hóa tri thức từ KG sẽ vừa đóng vai trò là khóa, được sử dụng để so sánh đâu là thông tin của thực thể trong KG tương ứng với các thực thể truy vấn, vừa đóng vai trò là các giá trị tri thức mà KG cung cấp trở lại cho mô hình Transformer trong quá trình học hỏi. Đặt  $Q = \text{Input Embedding}$ ,  $K = \text{KGEs}$ ,  $V = \text{KGEs}$ , biểu diễn về mặt toán học cho quá trình chú ý chéo đơn đầu giữa "Input Embedding" và "KGEs" được trình bày như sau:

$$\text{output} = \text{softmax} \left( \frac{QK^T}{\sqrt{d_k}} \right) V \quad (3.10)$$


Trong đó:

- $QK^T$  là tích vô hướng giữa ma trận truy vấn Q và ma trận khóa K.
- $d_k$  là chiều của véc-tơ khóa.

Cơ chế đa đầu cũng được kế thừa tương tự cách hoạt động trong bộ giải mã của mô hình Transformer, tính toán đa đầu sẽ là quá trình ghép nối tất cả các kết quả riêng rẽ từ các đầu (head) và nhân với một ma trận trọng số mới để tạo thành đầu ra với kích thước như ý muốn.

Mạng tuyến tính Feed Forward được thiết kế với cấu trúc như sau: một lớp ẩn (không tính lớp đầu vào và lớp đầu ra) với hàm kích hoạt (activation function) được sử dụng trong lớp ẩn này là hàm ReLu (Rectified Linear Unit), số chiều của lớp ẩn sẽ gấp bốn số chiều của lớp đầu vào, và số chiều của lớp đầu ra tương tự như số chiều của lớp đầu vào (Hình. 3.11). Công thức 3.11 biểu diễn tính toán toán học cho thành phần mạng Feed Forward:

$$\text{FF}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (3.11)$$



Hình 3.11: Thành phần mạng Feed Foward trong Khối Chú ý nhận biết thực thể

Trong đó:

- FF: Đầu ra của thành phần mạng.
- $W_1, W_2, b_1, b_2$ : Các tham số có thể học của mạng.

Tác dụng của thành phần mạng Feed Foward giúp khối Chú ý nhận biết thực thể xử lý các thông tin mới vừa thu được từ khối con chú ý chéo trước đó, mô tả đơn giản về mặt hình thức thì hai quá trình này có thể được liên tưởng như sau: chú ý chéo - "Hãy thu thập các thông tin mới từ tri thức được tích hợp", mạng tuyến tính - "Hãy suy nghĩ và xử lý các thông tin mới thu thập được này". Ngoài ra trong cấu trúc của khối Chú ý nhận biết thực thể, sau mỗi thành phần con còn kèm theo một lớp kết nối tắt (residual connection) và một lớp chuẩn hóa (normalization layer) có tác dụng tối ưu quá trình huấn luyện, cụ thể, chúng giúp cho quá trình huấn luyện của khối nhanh hội tụ hơn và tránh mất mát thông tin trong toán bộ quá trình huấn luyện sau này.

Gọi kết quả đầu ra của khối Chú ý nhận biết thực thể là EAEs (Entity-Aware Embeddings), EAEs sẽ không được truyền trực tiếp vào bộ mã hóa (encoder) mà kết quả này được cộng với "Input Embedding" ban đầu sau đó kết quả mới vừa được tạo ra sẽ là đầu vào hoàn chỉnh cuối cùng đi vào



bộ mã hóa của mô hình Transformer. Chúng tôi thực hiện thêm một phép cộng mà không sử dụng trực tiếp kết quả EAEs làm đầu vào hoàn chỉnh vì lý do sau thu được trong quá trình thực nghiệm như sau: Khi sử dụng trực tiếp EAEs làm đầu vào cho bộ mã hóa thì các bản dịch được tạo ra có độ dài rất ngắn hơn so với độ dài các bản dịch của mô hình Transformer nguyên mẫu ban đầu, hay các bản dịch của hai phương pháp KG-Trans và KG-Trans-R mà chúng tôi đã giới thiệu trước đó. Điều này có thể là do kết quả của khối Chú ý nhận biết thực thể tượng trưng cho việc mỗi token trong câu đầu vào ban đầu sẽ "chú ý" đến những thực thể trong câu được bổ sung thông tin từ KG, từ đó làm bản dịch có thiên hướng chỉ tập trung vào dịch lại các thực thể từ ngôn ngữ nguồn sang ngôn ngữ đích làm cho bản dịch có độ dài tương đối hạn chế và có thể xuất hiện những thực thể lạ trong bản dịch. Việc thực hiện thêm phép cộng sẽ thể hiện mục đích bổ sung thông tin thực thể cho dữ liệu đầu vào trước khi được truyền vào bộ mã hóa của mô hình Transformer, đặc biệt là các thông tin này được học tập một cách chi tiết từ cơ chế chú ý chéo.

## Chương 4

# Cài đặt và thực nghiệm

Chương này sẽ tập trung vào các phần sau đây: mô tả về dữ liệu thực nghiệm, chi tiết về cách cài đặt và cấu hình cho các phương pháp mới mà chúng tôi đề xuất, phân tích các kết quả thực nghiệm mà nghiên cứu đạt được.

### 4.1 Dữ liệu thực nghiệm

Đề tài nghiên cứu này tập trung cải thiện chất lượng dịch máy mạng neural trên cặp ngôn ngữ Anh-Việt và bộ dữ liệu chúng tôi sử dụng có tên là IWSLT En-Vi. Bộ dữ liệu IWSLT được cung cấp trong hội nghị hằng năm International Workshop on Spoken Language Translation, bộ dữ liệu IWSLT trong hội nghị được tổng hợp cho nhiều cặp ngôn ngữ khác nhau, và trong đó IWSLT En-Vi là một tập hợp các cặp câu dịch giữa ngôn ngữ nguồn là tiếng Anh và ngôn ngữ đích là tiếng Việt. IWSLT En-Vi được sử dụng phổ biến trong các nghiên cứu về tác vụ dịch máy Anh-Việt nhờ vào các ưu điểm nổi bật vốn có chẳng hạn như: chất lượng dữ liệu cao, đa dạng về ngữ cảnh và chủ đề, kích thước đủ lớn để huấn luyện mô hình, và có một cộng đồng nghiên cứu rộng lớn.

Các câu văn bản trong tập dữ liệu IWSLT En-Vi được tổng hợp từ các nguồn chính sau đây:

- TED Talks: TED Talks là các bài thuyết trình ngắn gọn, thường kéo dài từ 5 đến 20 phút, được trình bày bởi các chuyên gia và những người có ảnh hưởng trong nhiều lĩnh vực khác nhau trong hội nghị TED (được thành lập năm 1984).
- Văn bản chính phủ và tài liệu công khai: Một phần dữ liệu trong tập IWSLT đến từ các tài liệu chính phủ, báo cáo chính sách, và các tài

liệu công khai khác. Đây thường là các văn bản chính thức, có ngôn ngữ chuẩn mực và được công bố minh bạch.

- Báo chí, các diễn đàn online và blog: IWSLT En-Vi có chứa các câu được sắp xếp thành một đoạn hội thoại và những đoạn hội thoại này được tổng hợp thủ công từ các diễn đàn online hoặc các blog có sẵn trên các nền tảng xã hội, ngoài ra những mẫu tin thời sự đến từ tin tức trong các bài báo hoặc các văn bản tin tức được cập nhật trong đời sống hằng ngày.

Nhờ vào tính đa dạng về nguồn gốc mà bộ dữ liệu cũng đảm bảo về số lượng thực thể cho quá trình nghiên cứu. Bảng 4.1 thể hiện các số liệu thống kê liên quan đến số lượng thực thể tồn tại trong bộ dữ liệu IWSLT En-Vi.

Bảng 4.1: Số liệu thống kê về IWSLT EN-VI

| <b>Thuộc tính</b>                 | <b>Tập huấn luyện</b> | <b>Tập xác thực</b> | <b>Tập kiểm tra</b> |
|-----------------------------------|-----------------------|---------------------|---------------------|
| Tổng số câu                       | 133317                | 1553                | 1268                |
| Tổng số câu có thực thể           | 25721                 | 208                 | 262                 |
| Tổng số thực thể                  | 36566                 | 264                 | 382                 |
| Tổng số thực thể không lặp        | 7967                  | 161                 | 196                 |
| Số lượng thực thể tối đa trên câu | 14                    | 8                   | 6                   |

Chúng tôi cũng cho thấy tính tổng quát của nghiên cứu của mình bằng cách mở rộng đánh giá kết quả trên các bộ dữ liệu IWSLT cho các cặp ngôn ngữ khác, cụ thể là 3 cặp ngôn ngữ: Anh-Đức (En-De), Anh-Pháp (En-Fr), và Anh-Romanian (En-Ro). Các số liệu thống kê cho ba bộ dữ liệu của ba cặp ngôn ngữ vừa nêu, cùng với các số liệu thống kê cho cơ sở tri thức Wikidata5M liên quan đến số lượng thực thể, số lượng quan hệ, số lượng bộ ba, sẽ được chúng tôi cung cấp ở phần Phụ lục.

## 4.2 Cài đặt cấu hình

### 4.2.1 Hệ thống liên kết thực thể

Chúng tôi tận dụng sự hỗ trợ tuyệt vời của ngôn ngữ lập trình Python <sup>1</sup> khi làm việc với kiểu dữ liệu chuỗi (string) cho việc xây dựng hệ thống liên kết thực thể của mình. Cụ thể, bước so khớp chuỗi tuyệt đối trở nên vô cùng tiện lợi nhờ vào toán tử so sánh bằng '==', Python cho phép lập trình so sánh trực tiếp hai chuỗi chỉ bằng một phép toán so sánh đơn giản, điều này đặc biệt thuận lợi cho việc so sánh hai chuỗi có kích thước khá dài một cách nhanh chóng và hiệu quả. Bên cạnh đó, tính bất biến và tính duy nhất nghiêm ngặt của kiểu dữ liệu được dùng làm khóa trong cấu trúc dữ liệu từ điển (dictionary) của Python là một ưu điểm lớn, dẫn đến quyết định sử dụng ngôn ngữ này cho việc thiết kế cấu trúc dữ liệu từ điển để lưu trữ các cặp "khóa"- "giá trị" tương ứng cho các cặp "bí danh"- "Qid". Đối với bước trích xuất các thực thể tồn tại trong câu dữ liệu đầu vào, chúng tôi sử dụng cài đặt của thư viện spaCy <sup>2</sup>, thư viện spaCy là một trong những công cụ hàng đầu cho việc trích xuất thực thể (NER) trong xử lý ngôn ngữ tự nhiên (NLP) nhờ vào nhiều ưu điểm nổi bật sau đây:

- Thư viện được thiết kế để tối ưu hóa hiệu suất và tốc độ, giúp xử lý văn bản nhanh chóng ngay cả với khối lượng dữ liệu lớn.
- Mô hình trích xuất thực thể của spaCy đạt độ chính xác rất cao trên ngôn ngữ tiếng Anh nhờ vào sự kết hợp phức tạp bên trong giữa nhiều lớp mạng tích chập (CNNs) và mạng hồi quy (RNNs).
- Hỗ trợ nhận diện và phân loại rất nhiều loại thực thể khác nhau như tên người, tổ chức, địa điểm, ngày tháng, số thứ tự, đơn vị tiền tệ, và nhiều loại thực thể khác.
- Thư viện spaCy có một bộ cú pháp rõ ràng và trực quan, việc thiết kế theo kiểu hướng đối tượng làm cho việc tương tác với thực thể cũng như các thuộc tính khác của thực thể cũng trở nên dễ dàng hơn. Ví

---

<sup>1</sup><https://www.python.org/>

<sup>2</sup><https://github.com/explosion/spaCy>

dụ, để thêm một thuộc tính mới chưa có trước đó cho một thực thể, spaCy hỗ trợ thao tác này chỉ với việc gọi phương thức `.set()`, hoặc để xem các từ lân cận của một thực thể chỉ cần gọi đến phương thức `.nbor(steps)` có sẵn của thư viện.

#### 4.2.2 Nhúng đồ thị tri thức (KGEs)

Đối với việc xây dựng các nhúng đồ thị tri thức (KGEs) bằng thuật toán Fast Linear, chúng tôi sử dụng cách cài đặt của thư viện `fastText` <sup>3</sup>. Bảng 4.2 trình bày chi tiết các giá trị của các siêu tham số được sử dụng trong công trình nghiên cứu này.

Bảng 4.2: Siêu tham số được sử dụng cho `fastText`

| Siêu tham số      | Giá trị              |
|-------------------|----------------------|
| Kiểu mô hình      | Cbow                 |
| Số chiều          | 512                  |
| Kích thước cửa sổ | 2                    |
| Hàm mất mát       | Hierarchical softmax |
| Tỷ lệ học         | 0.01                 |
| Epochs            | 100                  |

#### 4.2.3 Các phương pháp đề xuất

Chúng tôi tận dụng cách cài đặt của khung làm việc `fairseq` <sup>4</sup> cho phần cài đặt mô hình Transformer trong cả ba phương pháp được đề xuất KG-Trans, KG-Trans-R, và EATT, cũng như phần cài đặt cho khối Chú ý nhận biết thực thể (Entity-Aware Attention Block) trong phương pháp EATT của chúng tôi. Bảng 4.3 thể hiện các giá trị siêu tham số được sử dụng trong quá trình huấn luyện cho mô hình Transformer truyền thống cũng như cho cả ba phương pháp. Bảng 4.4 thể hiện các giá trị siêu tham số được sử dụng cho khối Chú ý nhận biết thực thể liên quan đến hai thành phần con là khối chú ý chéo và mạng Feed Forward. Ngoài ra trong quá

<sup>3</sup><https://github.com/facebookresearch/fastText>

<sup>4</sup><https://github.com/facebookresearch/fairseq>

trình tin chỉnh của mình, chúng tôi cũng đã áp dụng kỹ thuật tìm kiếm lưới (grid search) cho một vài siêu tham số nhất định nhằm tìm ra bộ siêu tham số tối ưu cho các phương pháp được đề xuất của chúng tôi. Cụ thể như sau: kích thước nhúng của mô hình (model embedding size) = {512, 1024}, tỷ lệ học (learning rate) = {3e-4, 5e-4, 7e-4}, hằng số mượt nhân (label smoothing constant) = {0, 0.1, 0.2}.

Bảng 4.3: Siêu tham số được sử dụng cho quá trình huấn luyện các phương pháp

| <b>Siêu tham số</b>        | <b>Transformer</b> | <b>KG-Trans</b> | <b>KG-Trans-R</b> | <b>EATT</b> |
|----------------------------|--------------------|-----------------|-------------------|-------------|
| Số lớp mã hóa              | 6                  | 6               | 6                 | 6           |
| Số lớp giải mã             | 6                  | 6               | 6                 | 6           |
| Số đầu chú ý               | 8                  | 8               | 8                 | 8           |
| Kích thước nhúng           | 512                | 512             | 512               | 512         |
| Số chiều mạng Feed Forward | 2048               | 2048            | 2048              | 2048        |
| Tỷ lệ học                  | 5e-4               | 3e-4            | 5e-4              | 5e-4        |
| Dropout                    | 0.3                | 0.3             | 0.3               | 0.3         |
| Hằng số mượt nhân          | 0.2                | 0.2             | 0.2               | 0.2         |
| Kích thước lô (tokens)     | 8000               | 8000            | 8000              | 8000        |
| Epochs                     | 30                 | 30              | 30                | 30          |

Bảng 4.4: Siêu tham số được sử dụng cho khối chú ý nhận biết thực thể

| <b>Siêu tham số</b>        | <b>Giá trị</b> |
|----------------------------|----------------|
| Số khối chú ý chéo         | 1              |
| Số đầu chú ý               | 8              |
| Kích thước nhúng           | 512            |
| Số chiều mạng Feed Forward | 2048           |

## 4.3 Kết quả thực nghiệm

### 4.3.1 Đánh giá dựa trên các độ đo đánh giá tự động

Trong phần này, chúng tôi tập trung đánh giá kết quả trên cặp ngôn ngữ chính là Anh-Việt (En-Vi). Ngoài ra, để kiểm tra tính tổng quát của các phương pháp được đề xuất, chúng tôi mở rộng đánh giá trên ba cặp ngôn ngữ khác là Anh-Đức (En-De), Anh-Pháp (En-Fr), và Anh-Romanian (En-Ro). Việc này giúp chúng tôi xác định được tính hiệu quả và khả năng áp dụng rộng rãi của các phương pháp đề xuất, đảm bảo rằng các phương pháp này không chỉ hiệu quả trong một ngữ cảnh cụ thể mà còn có thể thích ứng với các cặp ngôn ngữ khác nhau. Các kết quả của chúng tôi dựa trên các độ đo đánh giá tự động, bao gồm BLEU, TER, và GLEU:

- BLEU( $\uparrow$ ) [18]: Độ đo tiêu chuẩn để đánh giá văn bản được dịch tự động bằng máy dựa trên số lượng từ và cụm từ khớp với các bản dịch tham chiếu. BLEU hoạt động theo cách so sánh các n-gram (các chuỗi từ liên tiếp) của bản dịch máy với n-gram của một hoặc nhiều bản dịch tham chiếu. Mục tiêu là xác định mức độ trùng khớp giữa bản dịch máy và bản dịch tham chiếu qua các n-gram này. Các n-gram có thể là các từ đơn (unigram), cặp từ (bigram), bộ ba từ (trigram), và bộ bốn từ (4-gram).
- TER( $\downarrow$ ) [22]: Độ đo đo lường mức độ chỉnh sửa cần thiết để thay đổi bản dịch tự động sao cho phù hợp với bản dịch tham chiếu. TER tính toán số lượng chỉnh sửa tối thiểu cần thiết để biến đổi một câu được dịch tự động bởi máy thành câu tham chiếu tương ứng. Các loại chỉnh sửa bao gồm: Thay thế từ (thay một từ trong bản dịch máy bằng từ tương ứng trong bản dịch tham chiếu), chèn từ (thêm một từ cần thiết vào bản dịch máy để khớp với bản dịch tham chiếu), xóa từ (xóa một từ không cần thiết trong bản dịch máy để phù hợp với bản dịch tham chiếu), di chuyển cụm từ (di chuyển một hoặc nhiều cụm từ trong bản dịch máy để đạt được sự sắp xếp chính xác như trong bản dịch tham chiếu).
- GLEU( $\uparrow$ ) [17]: Độ đo này là một biến thể cải tiến từ BLEU, độ đo

này nhạy cảm hơn BLEU về mặt ý nghĩa và tính trôi chảy của bản dịch tự động. GLEU dựa trên nguyên lý so sánh n-gram giữa bản dịch tự động bằng máy và bản dịch tham chiếu, tương tự như BLEU, nhưng với một số cải tiến để giảm thiểu các vấn đề như quá phạt hoặc thiếu phạt trong đánh giá các bản dịch.

Đánh giá chất lượng bản dịch máy bằng cách kết hợp nhiều độ đo mang lại cái nhìn toàn diện và chính xác hơn về hiệu suất của các mô hình. Mỗi độ đo có những ưu điểm và nhược điểm riêng, do đó, việc sử dụng đồng thời nhiều độ đo như BLEU, TER, và GLEU giúp đảm bảo rằng các khía cạnh khác nhau của chất lượng bản dịch đều được xem xét. Sự kết hợp này giúp cân bằng các yếu tố ngữ nghĩa, và độ trôi chảy, từ đó phản ánh tốt hơn hiệu suất tổng thể của mô hình dịch máy. Hơn nữa, việc đánh giá qua nhiều tiêu chí giúp phát hiện và khắc phục các hạn chế của từng độ đo riêng lẻ, tạo ra một hệ thống đánh giá toàn diện và đáng tin cậy hơn. Trong nghiên cứu của chúng tôi, việc áp dụng ba độ đo đồng thời đã giúp chúng tôi có được cái nhìn chi tiết hơn về chất lượng bản dịch, từ đó đánh giá mức độ hiệu quả của các phương pháp được đề xuất.

Các kết quả được trình bày trong Bảng 4.5, với các giá trị in đậm biểu thị hiệu suất tốt nhất cho các phương pháp đạt được trên tập dữ liệu đó. Các mũi tên cho biết trường hợp điểm cao hơn ( $\uparrow$ ) hay thấp hơn ( $\downarrow$ ) là tốt hơn. Kết quả cho thấy sự khác biệt về hiệu suất giữa các mô hình trên các cặp ngôn ngữ khác nhau. Nhìn chung, các biến thể của KG-Trans có xu hướng hoạt động tốt hơn một chút so với mô hình Transformer cơ sở. Cụ thể, mô hình KG-Trans tạo ra kết quả tốt hơn so với mô hình Transformer cơ sở trên tập dữ liệu chính Anh-Việt (En-Vi), mô hình KG-Trans đạt điểm BLEU, TER, và GLEU đều tốt hơn so với mô hình Transformer cơ sở. Kết quả tương tự cũng đạt được trên các cặp ngôn ngữ khác, riêng trường hợp đánh giá trên tập dữ liệu Anh-Đức (En-De) cho kết quả kém hơn mô hình cơ sở một chút trên độ đo GLEU. Đối với mô hình KG-Trans-R, trên tập dữ liệu dịch từ tiếng Anh sang tiếng Việt (En-Vi), mô hình cũng đã đạt các điểm số tốt hơn ở tất cả các độ đo so với mô hình Transformer cơ sở. Xu hướng tương tự cũng được quan sát thấy trên các cặp ngôn ngữ còn lại, khác biệt đối với tập dữ liệu tiếng Anh sang tiếng Pháp (En-Fr), mô




hình KG-Trans-R đạt điểm TER kém hơn một chút so với mô hình cơ sở. Đáng chú ý nhất, là các kết quả thu được, khi thực hiện đánh giá bằng phương pháp EATT của chúng tôi, so với mô hình Transformer cơ sở và hai phương pháp được đề xuất trước đó, phương pháp EATT của chúng tôi vượt trội hoàn toàn trên tất cả ba độ đo, với hiệu suất có sự khác biệt rõ rệt, chứng minh sự cải tiến đáng kể so với các phương pháp còn lại.

Bảng 4.5: Kết quả thực nghiệm dựa trên các độ đo đánh giá tự động (kết quả tốt nhất được in đậm).

| MODELS      | DATASET | GLEU(↑)      | TER(↓)       | BLEU(↑)      |
|-------------|---------|--------------|--------------|--------------|
| Transformer | EN-VI   | 33.58        | 52.89        | 29.35        |
| KG-Trans    | EN-VI   | 33.65        | 52.57        | 29.36        |
| KG-Trans-R  | EN-VI   | 33.76        | 52.76        | 29.64        |
| EATT        | EN-VI   | <b>34.04</b> | <b>52.44</b> | <b>30.00</b> |
| Transformer | EN-DE   | 32.49        | 56.52        | 26.30        |
| KG-Trans    | EN-DE   | 32.37        | 56.37        | 26.42        |
| KG-Trans-R  | EN-DE   | 32.36        | 56.43        | 26.53        |
| EATT        | EN-DE   | <b>32.51</b> | <b>55.86</b> | <b>26.68</b> |
| Transformer | EN-FR   | 42.56        | 44.83        | 39.77        |
| KG-Trans    | EN-FR   | 43.09        | 44.46        | 40.27        |
| KG-Trans-R  | EN-FR   | 42.88        | 45.02        | 39.93        |
| EATT        | EN-FR   | <b>43.25</b> | <b>44.25</b> | <b>40.41</b> |
| Transformer | EN-RO   | 20.63        | 68.77        | 16.10        |
| KG-Trans    | EN-RO   | 21.73        | 67.30        | 16.72        |
| KG-Trans-R  | EN-RO   | 21.27        | 66.80        | 16.97        |
| EATT        | EN-RO   | <b>22.02</b> | <b>65.33</b> | <b>18.01</b> |

#### 4.3.2 Đánh giá độ tương đồng ngữ nghĩa sử dụng điểm SBERT


SBERT (Sentence-BERT) [20] là một phương pháp biểu diễn văn bản dựa trên mô hình BERT (Bidirectional Encoder Representations from Transformers) nhằm cải thiện việc đo lường sự tương đồng ngữ nghĩa giữa các câu. SBERT đã được phát triển để mô hình hóa các câu sao cho những câu có ý nghĩa tương đương về mặt ngữ nghĩa sẽ có biểu diễn vector gần nhau trong không gian vector. Điểm mấu chốt của SBERT là sử dụng kiến trúc mô hình BERT, nhưng với các cải tiến để tối ưu hóa quá trình học biểu diễn văn bản. Đối với mô hình BERT, việc tính độ tương đồng ngữ



Hình 4.1: Quá trình tính độ tương đồng ngữ nghĩa bằng mô hình BERT

ngĩa giữa hai câu văn bản thực chất khá tương đồng với bài toán phân loại nhị phân sử dụng BERT, quá trình tính toán độ tương đồng về mặt ngữ nghĩa được thực hiện như sau: Trước hết, các token trong hai câu sẽ được nhúng mã hóa (embedding), sau đó véc-tơ nhúng này được truyền vào một kiến trúc gồm mô hình BERT và mạng Feed Forward kèm với hàm tính toán sigmoid trước khi cho ra kết quả cuối cùng. Điểm kết quả nhận được cuối cùng sẽ nằm trong đoạn  $[0, 1]$  thể hiện mức độ tương đồng về mặt ngữ nghĩa của hai câu cần đánh giá ban đầu (Hình. 4.1). Cách tiếp cận này mất rất nhiều thời gian cho việc tính toán khi làm việc trên các tập dữ liệu lớn và chứa các mẫu câu khá dài.

SBERT giải quyết vấn đề này bằng cách tin chỉnh một cách riêng lẻ và song song từng câu trong cặp câu ban đầu cần được đánh giá. Ngoài ra, trong phương pháp tính toán độ tương đồng về mặt ngữ nghĩa sử dụng SBERT thì tác giả đã thay thế mạng Feed Forward bằng một lớp gộp trung bình (mean pooling) để trích xuất các véc-tơ biểu diễn đầu ra, cuối cùng các véc-tơ này được tính toán độ tương đồng dựa vào hàm tương đồng cosine để thể hiện mức độ tương đồng về mặt ngữ nghĩa giữa hai câu văn bản. Điểm số thu được nằm trong đoạn  $[-1, 1]$ , với giá trị càng âm thể



Hình 4.2: Quá trình tính độ tương đồng ngữ nghĩa bằng phương pháp SBERT (Nguồn: <https://arxiv.org/pdf/1908.10084>)

hiện mức độ tương đồng ngữ nghĩa càng bé, và ngược lại. Hình. 4.2 biểu diễn quá trình tính toán vừa nêu với "pooling" đại diện cho lớp gộp trung bình, "cosine-sim" đại diện cho hàm tương đồng cosine.

Bảng 4.6 thể hiện điểm trung bình tương đồng về mặt ngữ nghĩa trên toàn bộ tập kiểm tra (test) của bộ dữ liệu Anh-Việt (En-Vi) giữa các bản dịch tự động và các bản dịch tham chiếu.

Bảng 4.6: Kết quả thực nghiệm trên tập dữ liệu Anh-Việt dựa trên sự tương đồng về mặt ngữ nghĩa sử dụng SBERT (kết quả tốt nhất được in đậm)

| Phương pháp | SBERT trung bình |
|-------------|------------------|
| Transformer | 0.825            |
| KG-Trans    | 0.835            |
| KG-Trans-R  | 0.835            |
| EATT        | <b>0.840</b>     |

### 4.3.3 Đánh giá chất lượng dịch thực thể

Trong phần này chúng tôi sẽ tiến hành đánh giá chất lượng riêng cho các bản dịch thực thể trên tập dữ liệu Anh-Việt, việc đánh giá được thực hiện dựa trên quá trình kiểm tra số lượng thực thể được dịch sai của cả ba

phương pháp được đề xuất cũng như của mô hình Transformer cơ sở. Bên cạnh đó chúng tôi cũng sẽ phân tích số lượng thực thể được dịch sai trong từng loại thực thể cụ thể, bao gồm: Tên người (PER), Địa điểm (LOC), Tổ chức (ORG), và Các loại khác (MISC).

Bảng 4.7 thể hiện số lượng thực thể bị dịch sai của mô hình Transformer cơ sở và ba phương pháp đề xuất, lưu ý rằng chúng tôi xem xét trên cơ sở số lượng các thực thể không trùng nhau.

Bảng 4.7: So sánh chất lượng bản dịch giữa mô hình Transformer và các phương pháp đề xuất.

| Mô hình     | Số bản dịch đúng | Số bản dịch sai |
|-------------|------------------|-----------------|
| Transformer | 161              | 35              |
| KG-Trans    | 176              | 20              |
| KG-Trans-R  | 179              | 17              |
| EATT        | 181              | 15              |

Bảng 4.8 thể hiện số lượng bản dịch đúng và sai của từng loại thực thể vừa được đề cập khi áp dụng các phương pháp được đề xuất và mô hình Transformer cơ sở.

Bảng 4.8: Chất lượng bản dịch trên các loại thực thể: PER, LOC, ORG, và MISC của ba phương pháp đề xuất và mô hình cơ sở

| Loại | Transformer |     | KG-Trans |     | KG-Trans-R |     | EATT |     |
|------|-------------|-----|----------|-----|------------|-----|------|-----|
|      | Đúng        | Sai | Đúng     | Sai | Đúng       | Sai | Đúng | Sai |
| PER  | 31          | 11  | 36       | 6   | 38         | 4   | 38   | 4   |
| LOC  | 57          | 11  | 61       | 7   | 62         | 6   | 63   | 5   |
| ORG  | 53          | 4   | 55       | 2   | 55         | 2   | 55   | 2   |
| MISC | 20          | 9   | 24       | 5   | 24         | 5   | 25   | 4   |

Kết quả cho thấy, các thực thể thuộc loại tên người và tên tổ chức có xu hướng được dịch chính xác hơn các thực thể thuộc các loại còn lại khi so sánh số lượng bản dịch sai của từng loại trong ba phương pháp được đề xuất. Khi so sánh số lượng bản dịch được cải tiến giữa ba phương pháp được đề xuất so với mô hình Transformer cơ sở, thì các thực thể thuộc

loại tên người và tên địa điểm cho số lượng bản dịch được cải tiến là nhiều nhất. Và phương pháp EATT của chúng tôi vẫn tiếp tục cho thấy sự vượt trội khi đạt được số lượng bản dịch đúng là nhiều nhất. Nhìn chung, những trường hợp mà các phương pháp được đề xuất chưa thể giải quyết được do gặp phải những khó khăn sau đây:

- Giới hạn kích thước của từ điển: Cụ thể, khi việc bắt đầu quá trình xử lý dữ liệu để xây dựng từ điển cho phía ngôn ngữ nguồn, do hạn chế về kích thước mà một số thực thể và Qid của chúng sẽ bị mã hóa lại thành <unk> token. Ví dụ, các thực thể trong tập test của chúng tôi như 'Remi', 'Iwate Prefecture', 'Max Little' và các Qid tương ứng của chúng bị mã hóa thành <unk> token sau quá trình xử lý dữ liệu. Chính việc giới hạn kích thước từ vựng này cũng là nguyên nhân dẫn đến những trường hợp giải quyết của hai biến thể KG-Trans là khác nhau. Đơn cử cho trường hợp này là thực thể Sam khi được thay thế bằng Qid cho phương pháp KG-Trans-R lại không bị mã hóa thành ký tự đặc biệt <unk> do đó phương pháp KG-Trans-R lại có thể giải quyết được thực thể này. Chính việc mã hóa này đã làm cho nhiều thực thể không được học và dịch chuẩn xác, kể cả trong mô hình Transformer cơ sở.
- Số lượng bộ ba (triplets) chứa thực thể là quá ít trong đồ thị tri thức: Ví dụ: thực thể 'Mercury' trong tiếng Việt phải có nghĩa là 'Thủy ngân' đã bị dịch nhầm thành 'Mộc tinh' do số lượng bộ ba chứa thực thể này trong Wikidata5M chỉ là 100 trong tổng số hơn 21.000.000 bộ ba. Thực thể tên xe 'Odyssey' đã bị dịch nhầm do số lượng bộ ba chứa thực thể này chỉ vỏn vẹn là 40. Thực thể 'Tunisian' đã bị dịch sai thành nhiều nghĩa khác nhau trong các bản dịch do số bộ ba chứa thực thể này trong Wikidata5M chỉ vỏn vẹn là 1.
- Sự nhập nhàn về biểu diễn tên người: Một thực thể tên người thường được biểu diễn bằng nhiều cách khác nhau cho cùng một Qid trong Wikidata5M, ví dụ thực thể 'Richard Branson' còn được biểu diễn dưới dạng 'Richard' cho cùng một Qid, do đó bản dịch chúng tôi nhận được lại là 'Richard' cho phương pháp thay thế KG-Trans-R và

phương pháp EATT, riêng đối với phương pháp KG-Trans lại không dịch chính xác cho thực thể này.

- Hạn chế cuối cùng chính là hạn chế trong chính các phương pháp mà chúng tôi đã đề xuất: Mặc dù không gặp phải những lý do vừa nêu nhưng các bản dịch vẫn không đạt được chất lượng như ý muốn: Ví dụ, đối với hai phương pháp KG-Trans và KG-Trans-R, thực thể 'Hindu' lại được dịch sai thành tên quốc gia 'Ấn Độ' trong tiếng Việt, thực thể 'Kazakhstan' bị dịch sai thành nhiều tên quốc gia khác nhau trong các bản dịch của KG-Trans và KG-Trans-R. Tuy nhiên, các thực thể này lại được dịch hoàn chỉnh bởi phương pháp EATT. Một số trường hợp ví dụ khác mà cả ba phương pháp của chúng tôi đều không thể dịch chính xác: thực thể 'Latino' bị dịch sai thành 'người gốc Phi', tên người 'Christchurch' bị dịch sai thành tên địa điểm 'Virginia', tên người 'Gaddafi' bị dịch sai thành nhiều nghĩa khác nhau, hay các thực thể như thực thể 'Lybian' và thực thể địa điểm 'Albany' đã hoàn toàn bị bỏ qua trong cả ba phương pháp.

Ngoài ra, chúng tôi còn phát hiện một chi tiết rất thú vị từ tập dữ liệu mà chúng tôi sử dụng, thực thể 'Atlantic Ocean' đã bị dịch sai từ đầu trong các bản dịch tham chiếu thành 'Thái Bình Dương' và mô hình Transformer cũng từ đó cho ra kết quả dịch sai của thực thể này. Tuy nhiên, cả ba phương pháp của chúng tôi đều cho kết quả dịch của thực thể trên chính xác là 'Đại Tây Dương'.

Ở chương Phụ lục B, chúng tôi sẽ cung cấp một số ví dụ về các bản dịch giữa mô hình Transformer cơ sở và các phương pháp được đề xuất để người đọc có cái nhìn tổng quan về sự khác biệt giữa các bản dịch này.

## Chương 5

# Kết luận và hướng phát triển

### 5.1 Kết luận

Với động lực nghiên cứu đề ra, chúng tôi đã đề xuất ba phương pháp mới được chia làm hai nhóm nhằm giải quyết bài toán tăng cường chất lượng dịch máy mạng neural Anh-Việt thông qua tích hợp đồ thị tri thức. Cụ thể, nhóm phương pháp đầu tiên tích hợp tri thức từ đồ thị vào mô hình Transformer cho tác vụ dịch máy nhưng không làm thay đổi cấu trúc vốn có của mô hình. Trong nhóm này, chúng tôi đề xuất hai phương pháp có tên là KG-Trans và KG-Trans-R, hai phương pháp thực hiện việc tích hợp các véc-tơ nhúng từ đồ thị tri thức vào mô hình Transformer lần lượt thông qua phép nối và phép thay thế. Các phép toán này vừa có tác dụng không làm thay đổi kiến trúc mô hình vừa có tác dụng bổ sung thông tin về các thực thể được học từ đồ thị tri thức, mà các thực thể này tương ứng với các thực thể được trích xuất từ đầu vào ban đầu. Nhóm phương pháp thứ hai đề xuất một phương pháp có tên là EATT, phương pháp này làm thay đổi kiến trúc sẵn có của mô hình Transformer bằng cách bổ sung một thành phần được đặt tên là khối Chú ý nhận biết thực thể. Khối này có tác dụng thực hiện cơ chế chú ý chéo giữa các nội véc-tơ nhúng của mô hình Transformer với các véc-tơ nhúng của các thực thể trong đồ thị tri thức. Kết quả của khối này sau đó được bổ sung lại cho đầu vào của bộ mã hóa để tạo thành đầu vào hoàn chỉnh trước khi tiến hành quá trình dịch thuật.

Kết quả thực nghiệm trên tập dữ liệu cho cặp ngôn ngữ chính là Anh-Việt cho thấy cả ba phương pháp được đề xuất đều hoạt động tốt hơn mô hình truyền thống trên các độ đo đánh giá tự động, cũng như độ đo về mức độ tương đồng ngữ nghĩa. Với ba độ đo đánh giá tự động là BLEU, TER, và GLEU, các biến thể của nhóm phương pháp KG-Trans cho thấy xu

hướng hoạt động tốt hơn mô hình cơ sở đôi chút trên cả ba độ đo, riêng với phương pháp EATT vượt trội hơn hẳn với hiệu suất được cải tiến rõ ràng. Ngoài ra, để kiểm tra tính tổng quát của các phương pháp được đề xuất, chúng tôi mở rộng đánh giá trên ba cặp ngôn ngữ khác là Anh-Đức, Anh-Pháp, và Anh-Romanian. Các biến thể trong nhóm KG-Trans vẫn có xu hướng hoạt động tốt nhưng không chiếm ưu thế hoàn toàn trên tất cả các độ đo. Trong khi đó phương pháp EATT vẫn đạt kết quả tốt nhất trên tất cả các độ đo cho tất cả các cặp ngôn ngữ.

Kết quả khả quan cũng được nhận thấy trong trường hợp sử dụng điểm SBERT so sánh mức độ tương đồng ngữ nghĩa giữa các bản dịch tự động và các bản dịch tham chiếu. Cả ba phương pháp đều cho điểm số cao hơn mô hình Transformer cơ sở, với kết quả tốt nhất thuộc về phương pháp EATT. Ngoài ra, khi khảo sát chất lượng dịch cho các thực thể, các phương pháp của chúng tôi cũng cho ra số lượng bản dịch sai ít hơn mô hình cơ sở, trong đó các thực thể thuộc loại tên riêng, loại tên địa điểm, và loại tên tổ chức có xu hướng được dịch đúng nhiều nhất.

## 5.2 Hướng phát triển

Với các hướng phát triển tiếp theo, chúng tôi đề xuất các ý tưởng bao gồm việc sử dụng kiến trúc HyperGraph Transformer và tích hợp đồ thị tri thức ở mức tài liệu. HyperGraph Transformer là một mô hình cải tiến của Transformer, tận dụng cấu trúc siêu đồ thị để mã hóa thông tin, trong cấu trúc siêu đồ thị các bộ ba không chỉ được suy luận độc lập mà chúng còn liên kết với nhau, tạo thành các chuỗi suy luận kéo dài. Điều này cho phép mô hình không chỉ học tốt thông tin tri thức về thực thể mà còn là những ngữ cảnh xung quanh thực thể tồn tại bên trong đồ thị tri thức. Một hướng phát triển quan trọng khác là tích hợp đồ thị tri thức ở mức tài liệu để không chỉ dịch chính xác các thực thể mà còn các thuật ngữ hiếm gặp trong văn bản. Bằng cách phân tích tài liệu và tích hợp các thông tin từ đồ thị tri thức liên quan, hệ thống dịch máy có thể truy cập và sử dụng các kiến thức chuyên sâu về các thuật ngữ và khái niệm đặc biệt. Điều này đặc biệt hữu ích khi áp dụng vào các lĩnh vực chuyên ngành, nơi các thuật ngữ hiếm gặp thường xuyên xuất hiện và yêu cầu sự hiểu biết sâu sắc.



# Tài liệu tham khảo

## Tiếng Anh

- [1] Banerjee, Satanjeev and Lavie, Alon. “METEOR: An automatic metric for MT evaluation with improved correlation with human judgments”. In: *Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization*. 2005, pp. 65–72.
- [2] Bordes, Antoine et al. “Translating embeddings for modeling multi-relational data”. In: *Advances in neural information processing systems* 26 (2013).
- [3] Chung, Junyoung et al. “Empirical evaluation of gated recurrent neural networks on sequence modeling”. In: *arXiv preprint arXiv:1412.3555* (2014).
- [4] Devlin, Jacob et al. “Bert: Pre-training of deep bidirectional transformers for language understanding”. In: *arXiv preprint arXiv:1810.04805* (2018).
- [5] Hochreiter, Sepp and Schmidhuber, Jürgen. “Long short-term memory”. In: *Neural computation* 9.8 (1997), pp. 1735–1780.
- [6] Hoffart, Johannes et al. “Robust disambiguation of named entities in text”. In: *Proceedings of the 2011 conference on empirical methods in natural language processing*. 2011, pp. 782–792.
- [7] Ji, Guoliang et al. “Knowledge graph embedding via dynamic mapping matrix”. In: *Proceedings of the 53rd annual meeting of the association for computational linguistics and the 7th international joint conference on natural language processing (volume 1: Long papers)*. 2015, pp. 687–696.

- [8] Joulin, Armand et al. “Fast linear model for knowledge graph embeddings”. In: *arXiv preprint arXiv:1710.10881* (2017).
- [9] Li, Zhongwei et al. “Named-entity tagging and domain adaptation for better customized translation”. In: *Proceedings of the seventh named entities workshop*. 2018, pp. 41–46.
- [10] Lin, Yankai et al. “Learning entity and relation embeddings for knowledge graph completion”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 29. 1. 2015.
- [11] Liu, Yinhan et al. “Roberta: A robustly optimized bert pretraining approach”. In: *arXiv preprint arXiv:1907.11692* (2019).
- [12] Luo, Ling et al. “An attention-based BiLSTM-CRF approach to document-level chemical named entity recognition”. In: *Bioinformatics* 34.8 (2018), pp. 1381–1388.
- [13] Mendes, Pablo N et al. “Evaluating dbpedia spotlight for the tac-kbp entity linking task”. In: *Proceedings of the TAC-KBP 2011 Workshop*. Vol. 116. 2011, pp. 118–120.
- [14] Moussallem, Diego, Wauer, Matthias, and Ngomo, Axel-Cyrille Ngonga. “Machine translation using semantic web technologies: A survey”. In: *Journal of Web Semantics* 51 (2018), pp. 1–19.
- [15] Moussallem, Diego et al. “Augmenting neural machine translation with knowledge graphs”. In: *arXiv preprint arXiv:1902.08816* (2019).
- [16] Moussallem, Diego et al. “MAG: A multilingual, knowledge-base agnostic and deterministic entity linking approach”. In: *Proceedings of the 9th Knowledge Capture Conference*. 2017, pp. 1–8.
- [17] Mutton, Andrew et al. “GLEU: Automatic evaluation of sentence-level fluency”. In: *Proceedings of the 45th Annual Meeting of the Association of Computational Linguistics*. 2007, pp. 344–351.
- [18] Papineni, Kishore et al. “Bleu: a method for automatic evaluation of machine translation”. In: *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*. 2002, pp. 311–318.

- [19] Popović, Maja. “chrF: character n-gram F-score for automatic MT evaluation”. In: *Proceedings of the tenth workshop on statistical machine translation*. 2015, pp. 392–395.
- [20] Reimers, Nils and Gurevych, Iryna. “Sentence-bert: Sentence embeddings using siamese bert-networks”. In: *arXiv preprint arXiv:1908.10084* (2019).
- [21] Sennrich, Rico, Haddow, Barry, and Birch, Alexandra. “Neural Machine Translation of Rare Words with Subword Units”. In: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Ed. by Erk, Katrin and Smith, Noah A. Berlin, Germany: Association for Computational Linguistics, Aug. 2016, pp. 1715–1725. DOI: 10.18653/v1/P16-1162. URL: <https://aclanthology.org/P16-1162>.
- [22] Snover, Matthew et al. “A study of translation edit rate with targeted human annotation”. In: *Proceedings of the 7th Conference of the Association for Machine Translation in the Americas: Technical Papers*. 2006, pp. 223–231.
- [23] Sun, Haitian et al. “Open domain question answering using early fusion of knowledge bases and text”. In: *arXiv preprint arXiv:1809.00782* (2018).
- [24] Sutskever, Ilya, Vinyals, Oriol, and Le, Quoc V. “Sequence to sequence learning with neural networks”. In: *Advances in neural information processing systems* 27 (2014).
- [25] Trouillon, Théo et al. “Complex embeddings for simple link prediction”. In: *International conference on machine learning*. PMLR. 2016, pp. 2071–2080.
- [26] Vaswani, Ashish et al. “Attention is all you need”. In: *Advances in neural information processing systems* 30 (2017).
- [27] Wang, Xiaozhi et al. “KEPLER: A unified model for knowledge embedding and pre-trained language representation”. In: *Transactions of the Association for Computational Linguistics* 9 (2021), pp. 176–194.

- [28] Wang, Yuguang et al. “Sogou neural machine translation systems for WMT17”. In: *Proceedings of the Second Conference on Machine Translation*. 2017, pp. 410–415.
- [29] Yang, Bishan and Mitchell, Tom. “Leveraging Knowledge Bases in LSTMs for Improving Machine Reading”. In: *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Ed. by Barzilay, Regina and Kan, Min-Yen. Vancouver, Canada: Association for Computational Linguistics, July 2017, pp. 1436–1446. DOI: 10.18653/v1/P17-1132. URL: <https://aclanthology.org/P17-1132>.

## Chương A

# Số liệu thống kê

Trong phần phụ lục này, chúng tôi sẽ cung cấp Các số liệu thống kê cho ba bộ dữ liệu của ba cặp ngôn ngữ Anh-Đức (En-De), Anh-Pháp (En-Fr), Anh-Romanian (En-Ro), cùng với các số liệu thống kê cho cơ sở tri thức Wikidata5M.

Bảng A.1: Số liệu thống kê về Wikidata5M

| Số lượng thực thể | Số lượng quan hệ | Số lượng bộ ba |
|-------------------|------------------|----------------|
| 4813491           | 825              | 21354359       |

Bảng A.2: Số liệu thống kê về IWSLT EN-DE

| Thuộc tính                        | Tập huấn luyện | Tập xác thực | Tập kiểm tra |
|-----------------------------------|----------------|--------------|--------------|
| Tổng số câu                       | 209522         | 3889         | 5078         |
| Tổng số câu có thực thể           | 42015          | 601          | 909          |
| Tổng số thực thể                  | 59284          | 828          | 1225         |
| Tổng số thực thể không lặp        | 11154          | 440          | 587          |
| Số lượng thực thể tối đa trên câu | 44             | 8            | 8            |

Bảng A.3: Số liệu thống kê về IWSLT EN-FR

| <b>Thuộc tính</b>                 | <b>Tập huấn luyện</b> | <b>Tập xác thực</b> | <b>Tập kiểm tra</b> |
|-----------------------------------|-----------------------|---------------------|---------------------|
| Tổng số câu                       | 236653                | 3888                | 5599                |
| Tổng số câu có thực thể           | 47498                 | 613                 | 1024                |
| Tổng số thực thể                  | 67172                 | 842                 | 1390                |
| Tổng số thực thể không lặp        | 12172                 | 444                 | 652                 |
| Số lượng thực thể tối đa trên câu | 44                    | 8                   | 8                   |

Bảng A.4: Số liệu thống kê về IWSLT EN-RO

| <b>Thuộc tính</b>                 | <b>Tập huấn luyện</b> | <b>Tập xác thực</b> | <b>Tập kiểm tra</b> |
|-----------------------------------|-----------------------|---------------------|---------------------|
| Tổng số câu                       | 133333                | 914                 | 1678                |
| Tổng số câu có thực thể           | 25068                 | 161                 | 206                 |
| Tổng số thực thể                  | 34969                 | 229                 | 290                 |
| Tổng số thực thể không lặp        | 7607                  | 146                 | 159                 |
| Số lượng thực thể tối đa trên câu | 41                    | 7                   | 6                   |

## Chương B

# Một số bản dịch đúng của các phương pháp đề xuất

Trong phần phụ lục này, chúng tôi minh họa một số ví dụ cho các bản dịch đúng của các phương pháp được đề xuất so với mô hình Transformer truyền thống.

Bảng B.1: Ví dụ 1

|             |                                                      |
|-------------|------------------------------------------------------|
| SRC         | I am helping the North Korean people.                |
| REF         | Tôi đang giúp người Bắc Triều Tiên.                  |
| Transformer | Tôi đang giúp <b>người Hàn Quốc</b> .                |
| KG-Trans    | Tôi đang giúp đỡ <b>những người Bắc Triều Tiên</b> . |
| KG-Trans-R  | Tôi đang giúp <b>người Bắc Triều Tiên</b> .          |
| EATT        | Tôi đang giúp đỡ <b>những người Bắc Triều Tiên</b> . |

Bảng B.2: Ví dụ 2

|             |                                                          |
|-------------|----------------------------------------------------------|
| SRC         | I started this as a tryout in Western Australia.         |
| REF         | Tôi bắt đầu điều này bằng việc thử sức ở Tây Úc.         |
| Transformer | Tôi bắt đầu điều này khi thử ở <b>miền Tây</b> .         |
| KG-Trans    | Tôi bắt đầu điều này khi thử ở <b>miền Tây nước Úc</b> . |
| KG-Trans-R  | Tôi bắt đầu điều này khi thử ở <b>miền Tây nước Úc</b> . |
| EATT        | Tôi đã bắt đầu điều này ở <b>miền Tây nước Úc</b> .      |

Bảng B.3: Ví dụ 3

|             |                                                                       |
|-------------|-----------------------------------------------------------------------|
| SRC         | We might produce the next George Washington Carver.                   |
| REF         | Có thể ta sẽ sản sinh ra George Washington Carver tiếp theo.          |
| Transformer | Chúng ta có thể sản xuất ra <b>George Stone lo lắng.</b>              |
| KG-Trans    | Chúng ta có thể tạo ra <b>George Washington Carver tiếp theo.</b>     |
| KG-Trans-R  | Có thể tạo ra <b>tiếp theo của George Washington.</b>                 |
| EATT        | Chúng ta có thể sản xuất ra <b>những tiếp theo của George Carver.</b> |

Bảng B.4: Ví dụ 4

|             |                                                                                       |
|-------------|---------------------------------------------------------------------------------------|
| SRC         | This is South Central: liquor stores, fast food, vacant lots.                         |
| REF         | Đây là vùng Trung Nam: cửa hàng rượu, đồ ăn nhanh, đất hoang.                         |
| Transformer | Đây là <b>Trung tâm: các cửa hàng đóng kín, đồ ăn nhanh, bỏ đi rất nhiều.</b>         |
| KG-Trans    | Đây là <b>vùng Trung tâm Phía Nam: cửa hàng nước ngọt, đồ ăn nhanh, vùng trống.</b>   |
| KG-Trans-R  | Đây là <b>vùng Trung tâm Phía Nam: cửa hàng nước ngọt, đồ ăn nhanh, vùng trống.</b>   |
| EATT        | Đây là <b>Trung tâm Phía Nam: trang cửa hàng, thức ăn nhanh, bỏ trống rất nhiều .</b> |